

自律走行車ステアリングのためのデータ駆動型 モデル予測制御の応用

1st Jiarui Zhang

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
zjr0915@tongji.edu.cn*

2nd Aijing Kong

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
ajkong@tongji.edu.cn*

3 Yu Tang 中国自動車
技術研究所有限公司、
重慶、中国 tangyu@cae
ri.com.cn

4th Zhichao Lv

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
lvzhichao@tongji.edu.cn*

5th Lulu Guo

*Department of Control Science
and Engineering
Tongji University
Shanghai, China
guoll21@tongji.edu.cn*

6th Peng Hang*

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
hangpeng@tongji.edu.cn*

要旨-自律走行技術の発展に伴い、車両制御に対する要求が高まっており、MPCは産学双方で広く研究されているテーマとなっている。車両の運動学や力学に基づく既存のMPC制御法には、モデリングが困難、パラメータが多い、非線形性が強い、計算コストが高いなどの課題がある。これらの問題を解決するために、本論文では既存のデータ駆動MPC制御法を適応し、自律走行車のステアリング制御に適用する。本手法は、複雑な車両システムのモデリングを必要とせず、比較的低い計算時間と小さな誤差で軌道追跡を実現する。CarSim-Simulinkシミュレーションにより、特定のシナリオにおけるアルゴリズムの制御効果を検証し、PIDおよび車両運動学MPCとの比較分析を行い、車両ステアリング制御におけるアルゴリズムの実現可能性と優位性を確認した。

索引用語-データ駆動制御、自律走行車ステアリング、モデル予測制御、経路追従

I. INTRODUCTION

現在、自律走行は成熟し、徐々に世間の目に迫っている。多くのインターネットや自動車製造業が、自律走行技術の研究にますます力を注いでおり、その中で

本研究の一部は、上海科学イノベーション基金(No. 23DZ1203400)、2023年上海科学技术革新行動計画下ベルト・路上協力プログラム(23210750500)、中国国家自然科学基金(52302502)、プロジェクト番号KFZ2408の下インテリジェントグリーンビークル・モビリティ国家重点実験室、CASTによる若手エリート科学者支援プログラム(2022QNRC001)、中央大学基礎研究基金の支援を受けた。イズ

*Corresponding author.

は、交通渋滞の改善、交通事故の減少、経済的利益の向上に大きく貢献している[1], [2]。Mastinuらは、ドライバーが車両の制御を失う理由とシナリオを分析した。彼らは、激しい車線変更、突風、その他の外乱の後、ドライバーは意図した行動を回復することができず、交通安全上の危険をもたらす可能性がある指摘した[3]。さらに、Ahangarらは、交通事故による死者数が増加の一途をたどっており、多くの事故がドライバーの疲労や注意散漫に起因していることを発見した[4]。さらに、道路交通からの二酸化炭素排出が、人間の二酸化炭素排出総量に占める割合も増加している[5]。そのため、自律走行技術に関する研究が急務である。

自律走行車は、知覚、予測、計画、意思決定、制御を含む複数のモジュールで構成される。その中でも制御は最も重要なモジュールの一つであり、制御手法は常に重要な研究対象であった。自律走行制御の分野では、PIDや適応制御などが広く産業で利用されており、システムの数学的モデリングを必要とせず、車両の状態や基準軌道を用いて最適な制御量を得ることができる[6], [7]。しかし、学術的には、モデル予測制御(MPC)が広く研究されているテーマである。1978年にRichaletらによって初めて提案され[8]、MPCはその後、様々な制御シナリオや制御対象に合わせて様々な修正を加えて進化してきた[9]-[11]。

しかし、一般的なMPCでは、制御されたシステムの精密なモデリングが必要である。

Application of Data-driven Model Predictive Control for Autonomous Vehicle Steering

1st Jiarui Zhang

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
zjr0915@tongji.edu.cn*

2nd Aijing Kong

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
ajkong@tongji.edu.cn*

3rd Yu Tang

*China Automotive Engineering
Research Institute Co., Ltd.,
Chongqing, China
tangyu@caeri.com.cn*

4th Zhichao Lv

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
lvzhichao@tongji.edu.cn*

5th Lulu Guo

*Department of Control Science
and Engineering
Tongji University
Shanghai, China
guoll21@tongji.edu.cn*

6th Peng Hang*

*Department of Traffic Engineering &
Key Laboratory of
Road and Traffic Engineering,
Ministry of Education
Tongji University
Shanghai, China
hangpeng@tongji.edu.cn*

Abstract—With the development of autonomous driving technology, there are increasing demands for vehicle control, and MPC has become a widely researched topic in both industry and academia. Existing MPC control methods based on vehicle kinematics or dynamics have challenges such as difficult modeling, numerous parameters, strong nonlinearity, and high computational cost. To address these issues, this paper adapts an existing Data-driven MPC control method and applies it to autonomous vehicle steering control. This method avoids the need for complex vehicle system modeling and achieves trajectory tracking with relatively low computational time and small errors. We validate the control effectiveness of the algorithm in specific scenario through CarSim-Simulink simulation and perform comparative analysis with PID and vehicle kinematics MPC, confirming the feasibility and superiority of it for vehicle steering control.

Index Terms—data-driven control, autonomous vehicle steering, model predictive control, path tracking

I. INTRODUCTION

Currently, autonomous driving has matured and is gradually coming into the public eye. Numerous internet and vehicle manufacturing companies are investing increasing efforts into researching autonomous driving technology, which

has significantly contributed to improving traffic congestion, reducing traffic accidents, and enhancing economic benefits [1], [2]. Mastinu et al. analyzed the reasons and scenarios in which drivers lose control of the vehicle. They pointed out that after severe lane changes, gusts of wind, or other disturbances, drivers might be unable to regain the intended actions, potentially posing traffic safety hazards [3]. Moreover, Ahangar et al. found that the number of fatalities due to road traffic accidents is continually rising, with many accidents resulting from driver fatigue and distraction [4]. Additionally, the proportion of carbon dioxide emissions from road traffic in the total human carbon dioxide emissions is also increasing [5]. Therefore, research on autonomous driving technology is urgently needed.

Autonomous vehicles are composed of multiple modules, including perception, prediction, planning, decision-making, and control. Among them, control is one of the most critical modules, and the control methods have always been a key research focus. In the field of autonomous driving control, PID and adaptive control, etc. are widely used in the industry, which do not require mathematical modeling of the system, and the optimal control quantity can be obtained using the vehicle's state and reference trajectory [6], [7]. In academia, however, Model Predictive Control (MPC) is a widely researched topic. First proposed by Richalet et al. in 1978 [8], MPC have since evolved with various modifications to suit different control scenarios and controlled objects [9]–[11].

However, general MPC require precise modeling of the controlled system. Currently, most MPC methods for autonomous

This work was supported in part by the Shanghai Scientific Innovation Foundation (No.23DZ1203400), the Belt and Road Cooperation Program under the 2023 Shanghai Action Plan for Science, Technology and Innovation (23210750500), the National Natural Science Foundation of China (52302502), the State Key Laboratory of Intelligent Green Vehicle and Mobility under Project No. KFZ2408, the Young Elite Scientists Sponsorship Program by CAST (2022QNRC001), and the Fundamental Research Funds for the Central Universities.

*Corresponding author.

現在、自律走行ステアリング制御のためのMPC手法のほとんどは、車両運動学または力学モデルに基づいている[12], [13]。車両運動学モデルは、パラメータが少なく、構造も単純であるが、自律走行車を2輪モデルに単純化するため、実際の車両状況から大きく逸脱し、制御精度が低くなる。一方、車両ダイナミクスモデルは、より多くのパラメータを含み、実験によるパラメータキャリブレーションが必要であり、また、モデルの強い非線形性は、高い最適化計算コストにつながる。そのため、研究者は、煩雑なモデリングプロセスを回避し、システム特性解析[14]やコントローラ設計[15]～[17]のためにデータを直接使用する方法を検討し始めている。

現在、データ駆動型MPCが広く研究されている。この制御方法は、従来のMPCアルゴリズムで要求されるシステムの精密なモデル化を回避し、高い制御精度を維持しながら計算時間を短縮する。既存の車両制御問題に対処するため、本論文では既存のデータ駆動MPCを研究し、車両システムの特徴を統合することで、車両ステアリング制御に適用し、本手法の実現可能性を検証する。本論文の貢献は以下のように示される：

1. [18]–[21]の研究に基づき、データ駆動型モデル予測制御法を自律走行車の操舵制御に適用する。
2. 自律走行車の操舵へのDDMPCの適用可能性をシミュレーション実験により検証し、他のアルゴリズムと比較することで、本アルゴリズムの優位性を実証した。

本稿の残りの部分は以下のように構成されている。セクションIIでは、我々の研究課題を簡単に紹介し、WillemsのLemmaについて議論する。セクションIIIでは、DDMPCに関する既存の研究を紹介する。これに基づき、本アルゴリズムを自律走行制御に適用できるように、若干の修正を加える。セクションIVでは、CarSimとSimulinkのシミュレーション実験により提案アルゴリズムの有効性を検証し、PIDと車両運動学MPCアルゴリズムとの比較分析を行う。最後に、セクションVで結論を述べる。

II. 問題提起

自律走行車技術の開発は、効率的で信頼性の高い制御アルゴリズムに依存している。MPCの利点は、車両モデルと基準軌道に基づいて、限られた予測ホライズン内で高精度の制御入力を計算する能力にある。その結果、MPCは正確な車両モデルに依存することが多いが、従来の車両モデル、特に動的モデルのモデリングとパラメータキャリブレーションは非常に困難になる。さらに、車両モデルは多くのパラメータを持ち、強い非線形性を持つことが多いため、最適化の際にかなりの計算時間を消費する可能性がある。ほとんどの学者や技術者は線形化によってこの問題に取り組んでいるが、これはしばしばモデルの精度の低下につながる。

Jeremyは、システム同定のためのデータベースの手法であるWillemsのレンマ[22]に基づき、

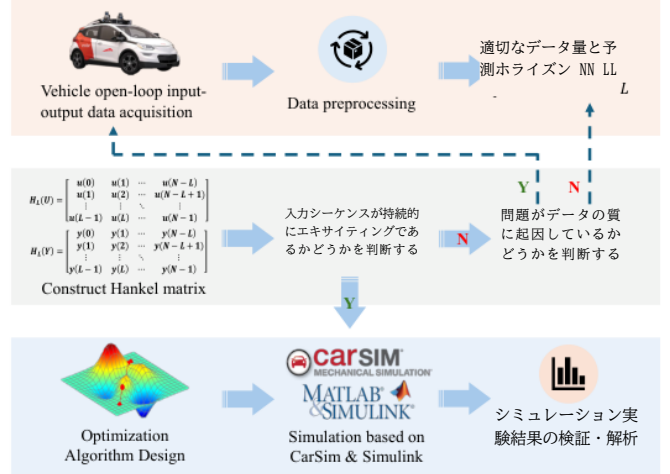


図1. AVステアリング制御のためのDDMPCのアルゴリズム適用プロセス。

Data-enabled Predictive Controlと呼ばれるアルゴリズムフレームワークを最初に提案し、空中ロボット工学に適用した[18]。その後、Berberichらは、ロバストなデータ駆動MPC制御法を設計した[19]–[21]。この方法は、システムのオフライン入力軌跡データから構築されたハンケル行列を、複雑なシステムモデルの置き換えに直接利用し、システムの将来の状態を予測し、それによって最適な制御入力を計算することができる。Luらは、この方法を用いて、データ駆動型の車両識別を完了させ、車両の横方向安定性制御のためのDDMPCコントローラを設計した[23]。その後、多くの学者がこの方法を拡張し、適用している[24], [25]。

我々は、[18]と[19]によって提案されたデータ駆動MPCアルゴリズムを自律走行車のステアリング制御に適用することによって、この基礎を構築し、図1に示すようなアルゴリズム適用フローチャートを提供する。

III. APPLICATION OF DDMPC FOR AUTONOMOUS VEHICLE STEERING

A. ウィレムスの定理と応用

ここでは、まず[18]と[19]によるWillemsのLemmaの説明と応用を復習する。あるシステムの動的挙動が、式(1)で表される次のような入出力関係で記述されているとする。

$$y(t) = G(u(t)) \quad (1)$$

ここで、 $u(t) \in U \sim \mathbb{R}^m$ は時刻 t におけるシステム入力であり、 m は入力次元である； $y(t) \in Y \sim \mathbb{R}^p$ は時刻 t におけるシステム出力であり、 p は出力次元である； $G(\cdot)$ はシステム動作モデルであり、一般に伝達関数または状態空間方程式で表される。

システムに入力 U のセットを適用し、それに対応して出力 Y のセットを生成する。収集されたオープンループ入出力データは、式2の2組のベクトルとして表現される。

driving steering control are based on vehicle kinematics or dynamics models [12], [13]. Vehicle kinematics models have fewer parameters and simple structures, but they simplify the autonomous vehicle into a two-wheel model, which significantly deviates from the actual vehicle situation and results in low control precision. On the other hand, vehicle dynamics models contain more parameters and require parameter calibration through experiments, and also the strong nonlinearity of the models leads to high optimization computational costs. Therefore, researchers have begun considering how to avoid the cumbersome modeling process and directly use data for system characteristics analysis [14] and controller design [15]–[17].

Currently, Data-driven MPC becomes widely researched. This control method avoids the precise modeling of system, as required by traditional MPC algorithms, and reduces computational time while maintaining high control accuracy. To address existing vehicle control problems, this paper studies the existing Data-driven MPC and, by integrating vehicle system characteristics, applies it to vehicle steering control and verifies the feasibility of this method. The contributions of this paper are presented as follows:

1. Based on the research of [18]–[21], a Data-driven Model Predictive Control method is applied to autonomous vehicle steering control.
2. The feasibility of the application of DDMPC to autonomous vehicle steering was verified through simulation experiments, and the superiority of this algorithm was demonstrated by comparing it with other algorithms.

The rest of the paper is organized as follows. Section II provides a brief introduction to our research problem and discusses Willems' Lemma. In Section III, we introduce the existing research on DDMPC. Based on this, we make minor modifications to make the algorithm applicable to autonomous vehicle control. In Section IV, we validate the effectiveness of the proposed algorithm through CarSim and Simulink simulation experiments and conduct a comparative analysis with PID and vehicle kinematics MPC algorithms. Finally, conclusions are drawn in Section V.

II. PROBLEM STATEMENT

The development of autonomous vehicle technology relies on efficient and reliable control algorithms. The advantage of MPC lies in its ability to calculate high-precision control inputs within a limited prediction horizon, based on the vehicle model and reference trajectory. Consequently, MPC often depends on accurate vehicle models, but modeling and parameter calibration of traditional vehicle models—especially dynamic models—become extremely challenging. Additionally, vehicle models often have many parameters and strong nonlinearity, which may consume a significant amount of computational time during optimization. Most scholars and engineers address this issue by linearization, but this often leads to a decrease in model accuracy.

Based on the Willems's lemma, which is a data-based method for system identification [22], Jeremy first proposed an




Fig. 1. Algorithm application process of the DDMPC for AV steering control.

algorithmic framework called Data-enabled Predictive Control and applied it on aerial robotics [18]. Thereafter, Berberich et al. designed a robust Data-driven MPC control method [19]–[21]. This method can directly use the Hankel matrix constructed from offline input-output trajectory data of the system to replace complex system models, predicting future states of the system and thereby calculating the optimal control inputs. Lu et al. used this method to complete the data-driven identification of vehicle and designed a DDMPC controller for vehicle lateral stability control [23]. Subsequently, many scholars have expanded and applied this method [24], [25].

We build on this foundation by applying the data-driven MPC algorithm proposed by [18] and [19] to steering control of autonomous vehicles and provide the algorithm application flowchart, as shown in Fig. 1.

III. APPLICATION OF DDMPC FOR AUTONOMOUS VEHICLE STEERING

A. Willems' Lemma and Application

Here, we first review the description and application of Willems' Lemma by [18] and [19].

Suppose the dynamic behavior of a system is described by the following input-output relationship expressed by Eq. 1.

$$y(t) = G(u(t)) \quad (1)$$

where $u(t) \in U \subset \mathbb{R}^m$ is the system input at time t , with m being the input dimension; $y(t) \in Y \subset \mathbb{R}^p$ is the system output at time t , with p being the output dimension; $G(\cdot)$ is the system behavior model, generally represented by a transfer function or state-space equations.

Apply a set of inputs U to the system, which correspondingly generates a set of outputs Y . The collected open-loop input-output data are represented as two sets of vectors in Eq. 2.

$$\begin{aligned} U &= [u(0), u(1), \dots, u(N-1)] \\ Y &= [y(0), y(1), \dots, y(N-1)] \end{aligned} \quad (2)$$

ここで、Nはデータセットの数であり、このパラメータの選択は、その後のデータ駆動MPCの設計に直接影響する。

収集した入出力データを処理する。主に、データクレンジング、連続性チェック、ノイズ除去などが含まれる。次に、データをハンケル行列に拡張する。結果として得られる次数Lのハンケル行列は、式3および式4のようになる。

$$H_L(U) = \begin{bmatrix} u(0) & u(1) & \cdots & u(N-L) \\ u(1) & u(2) & \cdots & u(N-L+1) \\ \vdots & \vdots & \ddots & \vdots \\ u(L-1) & u(L) & \cdots & u(N-1) \end{bmatrix} \quad (3)$$

$$H_L(Y) = \begin{bmatrix} y(0) & y(1) & \cdots & y(N-L) \\ y(1) & y(2) & \cdots & y(N-L+1) \\ \vdots & \vdots & \ddots & \vdots \\ y(L-1) & y(L) & \cdots & y(N-1) \end{bmatrix} \quad (4)$$

ここで、LはMPCアルゴリズムの基本予測地平である。入力行列 $H_L(U)$ に対して、入力列 U が持続励起の要件を満たすかどうかを以下の定義に基づいて決定する。

[18]、[19]の定義：入力列 U は、この入力列から構成される次数Lのハンケル行列 $H_L(U)$ のランクが式5を満たす場合にのみ、次数Lの持続的励起である。

$$\text{rank}[H_L(U)] = mL \quad (5)$$

これは、入力シーケンスがシステムのすべてのダイナミックモードを励起するのに十分豊かであることを意味する。この定義に基づき、入出力ハンケル行列と、システム出力を予測するための研究対象システムとの関係をさらに探ることができる。

WillemsのLemma [22]: $U, Y = \{u_k, y_k\}_{k=0}^{N-1}$ がシステムGから測定されたN個の入出力データの集合であり、Uが次数L + nの持続的に励起されるとき、 $\{\bar{u}_k, u_k\}_{k=0}^{L-1}$ は、式6を満たす $\alpha \in \mathbb{R}^{L-1}$ が存在する場合に限り、 $\{U, Y\}$ に基づく将来のL個の時間ステップに対するシステムGの予測入出力シーケンスである。6.

$$\begin{bmatrix} H_L(U) \\ H_L(Y) \end{bmatrix} \alpha = \begin{bmatrix} \bar{u} \\ \bar{y} \end{bmatrix} \quad (6)$$

ここで、nは制御されたシステムの状態数である。先に述べた持続励起の定義によれば、長さNの入力系列Uから構成される次数L+nのハンケル行列 $H_{L+n}(U)$ のランクは式7を満たさなければならない。

$$\text{rank}[H_{L+n}(U)] = m(L+n) \quad (7)$$

したがって、既知の過去の入出力データがあれば、最適な α が見つければ、上記のレンマを用いてシステムの将来の入出力を予測することができる。このレンマは、システムモデルの導出(さらにはシステムの特定の形式に関する知識)を回避し、システムによって生成されたオープンループデータから動的挙動情報を直接得ることを可能にする新しいアプローチを提供するため、システム同定とデータ駆動制御の分野で大きな関心を集めている[18]-[21]。これは、入力信号がある持続的な励起条件を満たすとき、事前に収集された既知の入出力データセグメントから構築されたハンケル行列は、システムの動的特性を暗黙的に表し、線形結合によって基本予測水平線Lのシステムの任意の入出力軌道を表現するために使用できるからである。

B. 車両操舵制御のためのDDMPC

Willemsのレンマに基づき、既存の研究ではMPCロール最適化と組み合わせてDDMPC最適化モデルを設計しており[18]、[19]、本小節では式8に示すように車両ステアリング制御に適応させ、式12とする。

$$\begin{aligned} J_L(\bar{u}(t), \bar{y}(t)) &= \sum_{k=0}^{L-1} \|\bar{y}_k(t) - y_k^r(t)\|_Q^2 \\ &+ \|\bar{u}_k(t) - u_k^r(t)\|_R^2 + \lambda \|\alpha(t)\|_2^2 \end{aligned} \quad (8)$$

ここで、 $y_k^r(t)$ と $u_k^r(t)$ は、現在の状態からk時間ステップ先の時刻tにおけるシステムの期待出力と入力を表し、 $Q \in \mathbb{R}^{p \times p}$ と $R \in \mathbb{R}^{m \times m}$ は対称正定値行列である。自律走行制御の文脈では、 $y_k^r(t)$ は、k時間ステップ先の現在時刻tにおける車両の位置と状態の軌跡点情報に対応し、安全性と快適性の観点から、 $u_k^r(t)$ は一般にゼロベクトルに設定され、望ましい制御動作が可能な限り最小化されるべきことを示す。Willemsのレンマに基づき、ハンケル行列を用いて Δ と \bar{u} を記述し、システムの状態を制約することで、以下の最適化問題に対する等式と不等式制約方程式を形成する。

$$\begin{bmatrix} H_n(U) \\ H_n(Y) \end{bmatrix} \alpha(t) = \begin{bmatrix} u_{-n}(t) \\ y_{-n}(t) \end{bmatrix} \quad (9)$$

$$\begin{bmatrix} H_L(U) \\ H_L(Y) \end{bmatrix} \alpha(t) = \begin{bmatrix} \bar{u}(t) \\ \bar{y}(t) \end{bmatrix} \quad (10)$$

$$\begin{bmatrix} \alpha_{\min} \\ u_{\min} \\ y_{\min} \end{bmatrix} \leq \begin{bmatrix} \alpha(t) \\ \bar{u}(t) \\ \bar{y}(t) \end{bmatrix} \leq \begin{bmatrix} \alpha_{\max} \\ u_{\max} \\ y_{\max} \end{bmatrix} \quad (11)$$

$$\bar{u}_k(t) \in U, \quad \bar{y}_k(t) \in Y, \quad k \in \mathbb{I}_{[0, L-1]} \quad (12)$$

ここで、 $u_{-n}(t)$ と $y_{-n}(t)$ は、それぞれ時刻tの前のn個の時間ス

$$\begin{aligned} U &= [u(0), u(1), \dots, u(N-1)] \\ Y &= [y(0), y(1), \dots, y(N-1)] \end{aligned} \quad (2)$$

where N is the number of data sets, and the selection of this parameter will directly influence the subsequent design of the Data-driven MPC.

Process the collected input-output data, which mainly includes data cleansing, continuity checking and noise removal, etc. Then, extend the data into Hankel matrices. The resulting order L Hankel matrix is as Eq. 3 and Eq. 4.

$$H_L(U) = \begin{bmatrix} u(0) & u(1) & \cdots & u(N-L) \\ u(1) & u(2) & \cdots & u(N-L+1) \\ \vdots & \vdots & \ddots & \vdots \\ u(L-1) & u(L) & \cdots & u(N-1) \end{bmatrix} \quad (3)$$

$$H_L(Y) = \begin{bmatrix} y(0) & y(1) & \cdots & y(N-L) \\ y(1) & y(2) & \cdots & y(N-L+1) \\ \vdots & \vdots & \ddots & \vdots \\ y(L-1) & y(L) & \cdots & y(N-1) \end{bmatrix} \quad (4)$$

where L is the basic prediction horizon of the MPC algorithm. For the input matrix $H_L(U)$, we determine whether the input sequence U satisfies the requirement of persistent excitation based on the following definition.

Definition in [18], [19]: The input sequence U is order L persistently exciting if and only if the rank of the order L Hankel matrix $H_L(U)$ constructed from this input sequence satisfies the Eq. 5.

$$\text{rank}[H_L(U)] = mL \quad (5)$$

This means that the input sequence is rich enough to excite all dynamic modes of the system. Based on this definition, we can further explore the relationship between the input-output Hankel matrix and the system under study for predicting system outputs.

Willems' Lemma [22]: If $\{U, Y\} = \{u_k, y_k\}_{k=0}^{N-1}$ is a set of N input-output data measured from system G , and U is order $L+n$ persistently exciting, then $\{\bar{u}_k, \bar{y}_k\}_{k=0}^{L-1}$ are the predicted input-output sequences of system G for the future L time steps based on $\{U, Y\}$, if and only if there exists an $\alpha \in \mathbb{R}^{N-L+1}$ that satisfies Eq. 6.

$$\begin{bmatrix} H_L(U) \\ H_L(Y) \end{bmatrix} \alpha = \begin{bmatrix} \bar{u} \\ \bar{y} \end{bmatrix} \quad (6)$$

where n is the number of states of the controlled system. According to the previously given definition of persistent excitation, the rank of the order $L+n$ Hankel matrix $H_{L+n}(U)$ constructed from the input sequence U of length N must satisfy the Eq. 7.

$$\text{rank}[H_{L+n}(U)] = m(L+n) \quad (7)$$

Therefore, with known historical input-output data, if an optimal α can be found, we can use the above lemma to predict the system's future inputs and outputs. This lemma is of great interest in the fields of system identification and data-driven control because it provides a new approach that allows us to bypass the derivation of the system model (and even the knowledge of the specific form of the system) and directly obtain dynamic behavior information from the open-loop data generated by the system [18]–[21]. This is because, when the input signal meets certain persistent excitation conditions, the Hankel matrix constructed from a pre-collected known input-output data segment implicitly represents the system's dynamic characteristics and can be used to represent any input-output trajectory of the system of the basic prediction horizon L through linear combinations.

B. DDMPC for Vehicle Steering Control

Based on Willems' lemma, existing research combined it with MPC roll optimization and designed the DDMPC optimization model [18], [19], and we adapt it in this subsection for vehicle steering control as shown in Eq. 8 to Eq. 12.

$$\begin{aligned} J_L(\bar{u}(t), \bar{y}(t)) &= \sum_{k=0}^{L-1} \|\bar{y}_k(t) - y_k^r(t)\|_Q^2 \\ &\quad + \|\bar{u}_k(t) - u_k^r(t)\|_R^2 + \lambda \|\alpha(t)\|_2^2 \end{aligned} \quad (8)$$

where $y_k^r(t)$ and $u_k^r(t)$ represent the expected output and input of the system at time t for k time steps ahead from the current state; $Q \in \mathbb{R}^{p \times p}$ and $R \in \mathbb{R}^{m \times m}$ are symmetric positive definite matrices. In the context of autonomous driving control, $y_k^r(t)$ corresponds to the trajectory point information of the vehicle's position and state at the current time t extended k time steps ahead; $u_k^r(t)$, from the perspective of safety and comfort, is generally set to be a zero vector, indicating that the desired control action should be minimized as much as possible. Based on Willems' lemma, we describe \bar{y} and \bar{u} using the Hankel matrix and constrain the system state, thereby forming the equality and inequality constraint equations for the following optimization problem.

$$\begin{bmatrix} H_n(U) \\ H_n(Y) \end{bmatrix} \alpha(t) = \begin{bmatrix} u_{-n}(t) \\ y_{-n}(t) \end{bmatrix} \quad (9)$$

$$\begin{bmatrix} H_L(U) \\ H_L(Y) \end{bmatrix} \alpha(t) = \begin{bmatrix} \bar{u}(t) \\ \bar{y}(t) \end{bmatrix} \quad (10)$$

$$\begin{bmatrix} \alpha_{\min} \\ u_{\min} \\ y_{\min} \end{bmatrix} \leq \begin{bmatrix} \alpha(t) \\ \bar{u}(t) \\ \bar{y}(t) \end{bmatrix} \leq \begin{bmatrix} \alpha_{\max} \\ u_{\max} \\ y_{\max} \end{bmatrix} \quad (11)$$

$$\bar{u}_k(t) \in U, \quad \bar{y}_k(t) \in Y, \quad k \in \mathbb{I}_{[0, L-1]} \quad (12)$$

In this context, Eq. 9 represents the initial constraint, where $u_{-n}(t)$ and $y_{-n}(t)$ denote the actual control inputs and outputs

テップに対するシステムの実際の制御入力と出力を表す。この制約は、システムの実際の動的挙動を利用して、予測結果が実際のシステムの挙動と密接に一致するように、決定変数 $\alpha(t)$ を制約することを目的とする。

式10は、Datadriven MPCアルゴリズムにおけるWillemsのレンマの適用である。ハンケル行列を用いてシステムの入出力を予測し、この最適化問題の等式制約として機能する。予測されたシステム出力 $\Delta(t)$ を基準軌道 $y_k^*(t)$ と比較することで、最適制御系列 $\bar{u}(t)$ が得られる。

式(11)は、決定変数に対する上界制約と下界制約を表している。一般的なシステムとは異なり、自律走行制御の文脈では、制御入力 $\bar{u}(t)$ に対する制約は、制御入力に通常、加速度または前輪の操舵角であるため、特に重要である。一般的に、安全性と快適性の両方の観点から、 $\bar{u}(t)$ の範囲を制限する必要がある。ここで選ばれた予測ホライズンは $L+n$ であるべきであり、これはオープンループ入力シーケンスが $L+2n$ の次数であることを必要とする。さらに、開ループデータから構成されるハンケル行列は、式13を満たす次数 $L+n$ でなければならない。

$$H_{L+n}(\cdot) = \begin{bmatrix} H_n(\cdot) \\ H_L(\cdot) \end{bmatrix} \quad (13)$$

この時点で、車両ステアリング制御のためのDDMPCフレームワークを得た。時刻 t における最適化問題式8～式12を解くだけで、最適制御シーケンス $\bar{u}_1(t)$ (本研究では左右の前輪角の値である)の最初の制御入力を自律走行車に適用して、現在時刻の制御を完了させることができる。

IV. 実験と結果

アルゴリズムの有効性を検証するため、CarSimとSimulinkソフトウェアを用いてシミュレーション実験を行った。CarSimは、車両実験によく使われるシミュレーションプラットフォームであり、実世界のシナリオで車両の動作を現実的に再現できる正確な車両ダイナミクスモデルを提供する。シミュレーション実験は、アルゴリズムの設計と同じロジックに従って、オープンループデータ収集とクローズドループアルゴリズムシミュレーション検証の2段階に分けられる。

CarSimでは、オープンループのデータ収集とアルゴリズムシミュレーション検証のためのテスト車両として、D-Class Sedan車両モデルが選択される。具体的なパラメータを表1に示す。

TABLE I
Bシミュレーションに使用した車両の基本的なパラメータ

Basic Vehicle Parameters	Parameter Value	Unit
Sprung mass	1370	kg
Wheelbase	2910	mm
Height for animator	1380	mm
アニメーターの幅	2162	mm
Yaw inertia	2315.3	kg-m ²

A. オープンループデータ収集

CarSimでは、オープンループのデータ収集のためのテスト環境を設定した。この環境は、入力シーケンスが車両の動的特性を活性化するのに十分なりッチさを確保するために、可能な限り多くのステアリングシナリオを含むべきである。

出力変数として、車両の水平座標 X と垂直座標 Y がグローバル座標系で選択され、車両の方位角 ϕ も選択される。コントロール変数として、左前輪の操舵角 δ_L と右前輪の操舵角 δ_R を選択する。したがって、車両の開ループ入出力シーケンスは、式14と式15のように表すことができる。

$$u(k) = \begin{bmatrix} \delta_L(k) \\ \delta_R(k) \end{bmatrix}, \quad k = 0, 1, \dots, N-1 \quad (14)$$

$$y(k) = \begin{bmatrix} x(k) \\ y(k) \\ \phi(k) \end{bmatrix}, \quad k = 0, 1, \dots, N-1 \quad (15)$$

車両の速度が一定でないため、収集した生データの疎な部分を補間する必要がある。さらに、データのクリーニングや異常値除去など、データの前処理が必要である。最終的なデータ量は $N = 646$ である。

B. Simulation Experiments

車両システムをモデル化する必要がないため、ここではシステム次数 n は未知である。したがって、システムの次数に上限 v を割り当て、アルゴリズムで n を代入するために $v = 6$ とする。さらに、基本予測地平 $L = 24$ とし、予測地平 $L + v = 30$ とする。重み行列は $Q = I_p$, $R = 10^{-2} - I_m$, $\lambda = 1 - 10^{-3}$ とする。車両の安全性と快適性の要求を満たすため、 $u_{min} = -1.5^\circ$, $u_{max} = +1.5^\circ$ とした。また、 $\alpha(t)$ と $\Delta(t)$ は拘束せず、車速は36km/h程度に保つ。

シミュレーション実験ケースとして、図2に示すデュアルレーンスイッチングシナリオを選択した。さらに、PIDと車両運動学MPC制御アルゴリズムを同じシナリオで使用した実験を行い、データ駆動MPC実験の結果との比較分析を行い、車両ステアリング制御への適用の利点を実証する。




図2. デュアルレーンスイッチングシナリオの模式図。

of the system for n time steps before time t , respectively. This constraint aims to use the actual dynamic behavior of the system to constrain the decision variable $\alpha(t)$, ensuring that the prediction results closely match the actual system behavior.

Eq. 10 is the application of Willems' lemma in the Data-driven MPC algorithm. It uses the Hankel matrix to predict the system's input-output, serving as the equality constraint of this optimization problem. By comparing the predicted system output $\bar{y}(t)$ with the reference trajectory $y_k^r(t)$, the optimal control sequence $\bar{u}(t)$ is obtained.

Eq. 11 represents the upper and lower bounds constraints on the decision variables. Unlike general systems, in the context of autonomous driving control, constraints on the control input $\bar{u}(t)$ are particularly critical because the control inputs are typically acceleration or front wheel steering angles. We generally need to limit the range of $\bar{u}(t)$ from the perspectives of both safety and comfort. It is worth noting that the prediction horizon chosen here should be $L+n$, which requires the open-loop input sequence to be order $L+2n$ persistently exciting [19]. Additionally, the Hankel matrix constructed from the open-loop data should be of order $L+n$, satisfying Eq. 13.

$$H_{L+n}(\cdot) = \begin{bmatrix} H_n(\cdot) \\ H_L(\cdot) \end{bmatrix} \quad (13)$$

At this point, we have obtained the DDMPC framework for vehicle steering control. We only need to solve the optimization problem Eq. 8 to Eq. 12 at time t , and apply the first control input of the optimal control sequence $\bar{u}_1(t)$ (In this study, it is the left and right front wheel angle values) to the autonomous vehicle to complete the control at the current time.

IV. EXPERIMENTS AND RESULTS

To verify the effectiveness of the algorithm, simulation experiments are conducted based on CarSim and Simulink softwares. CarSim is a commonly used simulation platform for vehicle experiments, providing precise vehicle dynamics models which can realistically reproduce vehicle operations in real-world scenarios. The simulation experiments are divided into two stages: open-loop data collection and closed-loop algorithm simulation verification, following the same logic as the design of algorithm.

In CarSim, a D-Class Sedan vehicle model is selected as the test vehicle for open-loop data collection and algorithm simulation verification. The specific parameters are shown in Table. I.

TABLE I
BASIC PARAMETERS OF THE VEHICLE USED FOR SIMULATION TESTS

Basic Vehicle Parameters	Parameter Value	Unit
Sprung mass	1370	kg
Wheelbase	2910	mm
Height for animator	1380	mm
Width for animator	2162	mm
Yaw inertia	2315.3	kg·m ²

A. Open-Loop Data Collection

In CarSim, we set up a test environment for open-loop data collection. This environment should include as many steering scenarios as possible to ensure that the input sequence is sufficiently rich to activate the dynamic characteristics of the vehicle.

The vehicle's horizontal coordinate X and vertical coordinate Y are chosen in the global coordinate system, as well as the vehicle's heading angle ϕ , as the output variables. The left front wheel steering angle δ_L and the right front wheel steering angle δ_R are selected as the control variables. Thus, the vehicle's open-loop input-output sequence can be expressed as Eq. 14 and Eq. 15.

$$u(k) = \begin{bmatrix} \delta_L(k) \\ \delta_R(k) \end{bmatrix}, \quad k = 0, 1, \dots, N-1 \quad (14)$$

$$y(k) = \begin{bmatrix} x(k) \\ y(k) \\ \phi(k) \end{bmatrix}, \quad k = 0, 1, \dots, N-1 \quad (15)$$

Due to the non-constant speed of the vehicle, it is necessary to interpolate the sparser parts of the collected raw data. Additionally, the data needs to be preprocessed, including data cleaning and outlier removal. The final amount of data obtained is $N = 646$.

B. Simulation Experiments

Since we do not need to model the vehicle system, the system order n is unknown here. Therefore, we assign an upper bound v to the system order, and set $v = 6$ to substitute for n in the algorithm. Additionally, we set the basic prediction horizon $L = 24$, making the prediction horizon $L + v = 30$. The weight matrices are set as $Q = I_p$, $R = 10^{-2} \cdot I_m$, and $\lambda = 1 \cdot 10^{-3}$. To meet the vehicle's safety and comfort requirements, we set $u_{\min} = -1.5^\circ$ and $u_{\max} = +1.5^\circ$. Besides, We don't bind $\alpha(t)$ and $\bar{y}(t)$, and keep the vehicle speed around 36 km/h.

A dual-lane switching scenario shown in Fig. 2 is selected as the simulation experiment case. Additionally, the experiments are conducted using PID and vehicle kinematics MPC control algorithms in the same scenario and the comparative analysis is performed with the results of the Data-driven MPC experiments to demonstrate the advantages of the application of it in vehicle steering control.




Fig. 2. Schematic diagram of a dual-lane switching scenario.




図3. データ駆動型MPC、PID、運動学MPCの軌跡と基準線。

C. 結果解析

図4は、DDMPCの制御下での左右の前輪のステアリング角度の経時変化を示している。見てわかるように、左右の前輪の操舵角の傾向はほぼ同じで、激しい変動はなく滑らかに変化し、 -5° から $+5^{\circ}$ のままである。これは、このアルゴリズムが、過度に積極的なステアリング操作をすることなく、安定した車線変更を可能にし、車両の安定性と快適性を確保していることを示している。さらに、DDMPCは旋回シナリオに迅速に対応できるため、緊急車線変更時の車両制御の安全性を確保することができる。

DDMPCのステアリング制御の実用性を検証するため、PIDや車両運動学MPCアルゴリズムと比較した。図3と図5は、同じシナリオにおける3つのアルゴリズムの大域的な軌跡とトラッキングエラーを示している。3つのアルゴリズムとも、ある誤差範囲内で軌道追跡を実現できる。しかし、車両運動学MPCとPIDアルゴリズムは、曲線から直線への遷移の間、車両の軌道からのずれを示すのに対し、DDMPCはこの遷移の間、ステアリング角度の迅速な応答を保証し、車両が希望の軌道を連続的にたどることを可能にする。さらに、図5に示すように、DDMPCの誤差変動幅は比較的小さく、概ね -0.1 m ~ 0.2 m の範囲にとどまり、外れ値はほとんどないことから、深刻な偏差はほとんどないことがわかる。

図6から、DDMPCの計算時間はデータ量 N と予測水平線 $L + v$ にのみ関係し、システムの複雑さには関係しないため、DDMPCの計算時間は車両運動学MPCのほぼ半分であることが観察される。これは、 N 、 L 、 v に適切な値を選択することで、計算時間を最小にしながら制御精度を確保できることを示している。

V. CONCLUSION

本研究では、[18]~[21]で提案された既存のデータ駆動型モデル予測制御法を研究し、自律走行車のステアリング制御に適用した。我々の実験により、このアルゴリズムが基準軌道を追跡するための安定した前輪角度制御を達成できることが実証され、従来のMPCアルゴリズムと比較して、制御誤差と計算時間を効果的に削減することができた。実験セクションの効果の詳細については、<https://john0915aaa.github.io/DDMPC-for-AV-steering/>を参照してください。

今後の課題としては、アルゴリズムのロバスト性とリアルタイム適応性を向上させ、多様な運転条件下での有効性をさらに向上させることに重点を置く。




図4. フロントホイールステアリング




Fig. 3. Trajectories of Data-driven MPC, PID and kinematics MPC with reference line.

C. Results Analysis

Fig. 4 shows the variation of the left and right front wheel steering angles over time under the control of DDMPC. As can be seen, the trends of the left and right front wheel steering angles are almost identical and change smoothly without severe fluctuations, remaining -5° to $+5^\circ$. This indicates that the algorithm allows for stable lane changes without excessively aggressive steering maneuvers, ensuring vehicle stability and comfort. Moreover, DDMPC can respond quickly in turning scenarios, ensuring vehicle control safety during emergency lane changes.

To verify the practical value for steering control of DDMPC, we compared it with PID and vehicle kinematics MPC algorithms. Fig. 3 and Fig. 5 show the global trajectory and tracking error of the three algorithms in the same scenario. All three algorithms can achieve trajectory tracking within a certain error range. However, the vehicle kinematics MPC and PID algorithms exhibit vehicle deviation from the track during the curve-to-straight transition, whereas DDMPC ensures a quick response in steering angles during this transition, allowing the vehicle to follow the desired trajectory continuously. Additionally, as shown in Fig. 5, the error variation range of DDMPC is relatively small and generally maintained between -0.1 m and 0.2 m with almost no outliers, which indicates that there are almost no severe deviations.

From Fig. 6, it can be observed that the computation time of DDMPC is almost half that of the vehicle kinematics MPC, since the computation time of it is only related to the data volume N and the prediction horizon $L + v$, and not to the complexity of the system. This shows that we can ensure control accuracy while minimizing computation time by choosing appropriate values for N , L , and v .

V. CONCLUSION

In this study, we researched the existing Data-driven Model Predictive Control method proposed by [18]–[21] and apply it to steering control of autonomous vehicle. Our experiments demonstrated that the algorithm could achieve stable front wheel angle control for tracking the reference trajectory, and compared to traditional MPC algorithms, it effectively reduces control errors and computation time. For more demonstrations of the effects of the experimental section go to: <https://john0915aaa.github.io/DDMPC-for-AV-steering/>.

Our future work will focus on enhancing the algorithm's robustness and real-time adaptability to further improve its effectiveness in diverse driving conditions.




Fig. 4. Front wheel steering.




図5. データ駆動MPC、PID、運動学MPCのトラッキングエラー。




Fig. 6. Computational time of Data-driven MPC, PID and kinematics MPC.

REFERENCES

- [1] Mohammed Al-Turki, Nedat T Ratrou, Syed Masiur Rahman, and Imran Reza. Impacts of autonomous vehicles on traffic flow characteristics under mixed traffic environment: Future perspectives. *Sustainability*, 13(19):11052, 2021.
- [2] Mohit Garg and Mélanie Bourgoche. Can connected autonomous vehicles improve mixed traffic safety without compromising efficiency in realistic scenarios? *IEEE Transactions on Intelligent Transportation Systems*, 2023.
- [3] Giampiero RM Mastinu, Giorgio Prevati, Fabio Della Rossa, Massimiliano Gobbi, and Marco Fainello. How drivers lose control of the car. *SAE International Journal of Vehicle Dynamics, Stability, and NVH*, 8(10-08-01-0007), 2024.
- [4] M Nadeem Ahangar, Qasim Z Ahmed, Fahd A Khan, and Maryam Hafeez. A survey of autonomous vehicles: Enabling communication technologies and challenges. *Sensors*, 21(3):706, 2021.
- [5] Yanmei Li, Tingting Li, and Shuangshuang Lu. Forecast of urban traffic carbon emission and analysis of influencing factors. *Energy Efficiency*, 14(8):84, 2021.
- [6] Jie Li, Lei Dou, Qi Zhao, Bin Qiao, Jiayong Liu, and Wei Zhang. Time domain analysis of ride comfort and energy dissipation characteristics of automotive vibration proportional-integral-derivative control. *SAE International Journal of Vehicle Dynamics, Stability, and NVH*, 8(10-08-01-0004), 2024.
- [7] Plamen Petrov and Fawzi Nashashibi. Modeling and nonlinear adaptive control for autonomous vehicle overtaking. *IEEE Transactions on Intelligent Transportation Systems*, 15(4):1643–1656, 2014.
- [8] Jacques Richalet, André Rault, JL Testud, and J Papon. Model predictive heuristic control. *Automatica (journal of IFAC)*, 14(5):413–428, 1978.
- [9] MCF Donkers, WPMH Heemels, Daniele Bernardini, Alberto Bemporad, and Vsevolod Shneer. Stability analysis of stochastic networked control systems. *Automatica*, 48(5):917–925, 2012.
- [10] Peng Hang, Sunan Huang, Xinbo Chen, and Kok Kiong Tan. Path planning of collision avoidance for unmanned ground vehicles: A nonlinear model predictive control approach. *Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering*, 235(2):222–236, 2021.
- [11] Peng Hang, Xin Xia, Guang Chen, and Xinbo Chen. Active safety control of automated electric vehicles at driving limits: A tube-based mpc approach. *IEEE Transactions on Transportation Electrification*, 8(1):1338–1349, 2021.
- [12] Luqi Tang, Fuwu Yan, Bin Zou, Kewei Wang, and Chen Lv. An improved kinematic model predictive control for high-speed path tracking of autonomous vehicles. *IEEE Access*, 8:51400–51413, 2020.
- [13] Fei Lai, Chaoqun Huang, and Chengyue Jiang. Comparative study on bifurcation and stability control of vehicle lateral dynamics. *SAE International Journal of Vehicle Dynamics, Stability, and NVH*, 6(10-06-01-0003):35–52, 2021.
- [14] XU Jian-Xin and HOU Zhong-Sheng. Notes on data-driven system approaches. *Acta Automatica Sinica*, 35(6):668–675, 2009.
- [15] Henk J Van Waarde, Jaap Eising, Harry L Trentelman, and M Kanat Camlibel. Data informativity: a new perspective on data-driven analysis and control. *IEEE Transactions on Automatic Control*, 65(11):4753–4768, 2020.
- [16] Claudio De Persis and Pietro Tesi. Formulas for data-driven control: Stabilization, optimality, and robustness. *IEEE Transactions on Automatic Control*, 65(3):909–924, 2019.
- [17] Valentina Breschi, Alessandro Chiuso, and Simone Formentin. Data-driven predictive control in a stochastic setting: A unified framework. *Automatica*, 152:110961, 2023.
- [18] Jeremy Coulson, John Lygeros, and Florian Dörfler. Data-enabled predictive control: In the shallows of the deepc. In *2019 18th European Control Conference (ECC)*, pages 307–312. IEEE, 2019.
- [19] Julian Berberich and Frank Allgöwer. A trajectory-based framework for data-driven system analysis and control. In *2020 European Control Conference (ECC)*, pages 1365–1370. IEEE, 2020.
- [20] Julian Berberich, Johannes Köhler, Matthias A Müller, and Frank Allgöwer. Robust constraint satisfaction in data-driven mpc. In *2020 59th IEEE Conference on Decision and Control (CDC)*, pages 1260–1267. IEEE, 2020.
- [21] Julian Berberich, Johannes Köhler, Matthias A Müller, and Frank Allgöwer. Data-driven model predictive control with stability and robustness guarantees. *IEEE Transactions on Automatic Control*, 66(4):1702–1717, 2020.
- [22] Jan C Willems, Paolo Rapisarda, Ivan Markovskiy, and Bart LM De Moor. A note on persistency of excitation. *Systems & Control Letters*, 54(4):325–329, 2005.
- [23] Xiaohui Lu, Jiachun Li, Detao Li, and Shaosong Li. Design of data-driven model predictive controller for vehicle lateral stability control. In *2023 7th CAA International Conference on Vehicular Control and Intelligence (CVCI)*, pages 1–6. IEEE, 2023.
- [24] Philipp Schmitz, Timm Faulwasser, and Karl Worthmann. Willems' fundamental lemma for linear descriptor systems and its use for data-driven output-feedback mpc. *IEEE Control Systems Letters*, 6:2443–2448, 2022.
- [25] Guillem Torrente, Elia Kaufmann, Philipp Föhn, and Davide Scaramuzza. Data-driven mpc for quadrotors. *IEEE Robotics and Automation Letters*, 6(2):3769–3776, 2021.




Fig. 5. Tracking error of Data-driven MPC, PID and kinematics MPC.




Fig. 6. Computational time of Data-driven MPC, PID and kinematics MPC.

REFERENCES

- [1] Mohammed Al-Turki, Nedat T Ratrou, Syed Masiur Rahman, and Imran Reza. Impacts of autonomous vehicles on traffic flow characteristics under mixed traffic environment: Future perspectives. *Sustainability*, 13(19):11052, 2021.
- [2] Mohit Garg and Mélanie Buroche. Can connected autonomous vehicles improve mixed traffic safety without compromising efficiency in realistic scenarios? *IEEE Transactions on Intelligent Transportation Systems*, 2023.
- [3] Giampiero RM Mastinu, Giorgio Prevati, Fabio Della Rossa, Massimiliano Gobbi, and Marco Fainello. How drivers lose control of the car. *SAE International Journal of Vehicle Dynamics, Stability, and NVH*, 8(10-08-01-0007), 2024.
- [4] M Nadeem Ahangar, Qasim Z Ahmed, Fahd A Khan, and Maryam Hafeez. A survey of autonomous vehicles: Enabling communication technologies and challenges. *Sensors*, 21(3):706, 2021.
- [5] Yanmei Li, Tingting Li, and Shuangshuang Lu. Forecast of urban traffic carbon emission and analysis of influencing factors. *Energy Efficiency*, 14(8):84, 2021.
- [6] Jie Li, Lei Dou, Qi Zhao, Bin Qiao, Jiayong Liu, and Wei Zhang. Time domain analysis of ride comfort and energy dissipation characteristics of automotive vibration proportional-integral-derivative control. *SAE International Journal of Vehicle Dynamics, Stability, and NVH*, 8(10-08-01-0004), 2024.
- [7] Plamen Petrov and Fawzi Nashashibi. Modeling and nonlinear adaptive control for autonomous vehicle overtaking. *IEEE Transactions on Intelligent Transportation Systems*, 15(4):1643–1656, 2014.
- [8] Jacques Richalet, André Rault, JL Testud, and J Papon. Model predictive heuristic control. *Automatica (journal of IFAC)*, 14(5):413–428, 1978.
- [9] MCF Donkers, WPMH Heemels, Daniele Bernardini, Alberto Bemporad, and Vsevolod Shneer. Stability analysis of stochastic networked control systems. *Automatica*, 48(5):917–925, 2012.
- [10] Peng Hang, Sunan Huang, Xinbo Chen, and Kok Kiong Tan. Path planning of collision avoidance for unmanned ground vehicles: A nonlinear model predictive control approach. *Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering*, 235(2):222–236, 2021.
- [11] Peng Hang, Xin Xia, Guang Chen, and Xinbo Chen. Active safety control of automated electric vehicles at driving limits: A tube-based mpc approach. *IEEE Transactions on Transportation Electrification*, 8(1):1338–1349, 2021.
- [12] Luqi Tang, Fuwu Yan, Bin Zou, Kewei Wang, and Chen Lv. An improved kinematic model predictive control for high-speed path tracking of autonomous vehicles. *IEEE Access*, 8:51400–51413, 2020.
- [13] Fei Lai, Chaoqun Huang, and Chengyue Jiang. Comparative study on bifurcation and stability control of vehicle lateral dynamics. *SAE International Journal of Vehicle Dynamics, Stability, and NVH*, 6(10-06-01-0003):35–52, 2021.
- [14] XU Jian-Xin and HOU Zhong-Sheng. Notes on data-driven system approaches. *Acta Automatica Sinica*, 35(6):668–675, 2009.
- [15] Henk J Van Waarde, Jaap Eising, Harry L Trentelman, and M Kanat Camlibel. Data informativity: a new perspective on data-driven analysis and control. *IEEE Transactions on Automatic Control*, 65(11):4753–4768, 2020.
- [16] Claudio De Persis and Pietro Tesi. Formulas for data-driven control: Stabilization, optimality, and robustness. *IEEE Transactions on Automatic Control*, 65(3):909–924, 2019.
- [17] Valentina Breschi, Alessandro Chiuso, and Simone Formentin. Data-driven predictive control in a stochastic setting: A unified framework. *Automatica*, 152:110961, 2023.
- [18] Jeremy Coulson, John Lygeros, and Florian Dörfler. Data-enabled predictive control: In the shallows of the deepc. In *2019 18th European Control Conference (ECC)*, pages 307–312. IEEE, 2019.
- [19] Julian Berberich and Frank Allgöwer. A trajectory-based framework for data-driven system analysis and control. In *2020 European Control Conference (ECC)*, pages 1365–1370. IEEE, 2020.
- [20] Julian Berberich, Johannes Köhler, Matthias A Müller, and Frank Allgöwer. Robust constraint satisfaction in data-driven mpc. In *2020 59th IEEE Conference on Decision and Control (CDC)*, pages 1260–1267. IEEE, 2020.
- [21] Julian Berberich, Johannes Köhler, Matthias A Müller, and Frank Allgöwer. Data-driven model predictive control with stability and robustness guarantees. *IEEE Transactions on Automatic Control*, 66(4):1702–1717, 2020.
- [22] Jan C Willems, Paolo Rapisarda, Ivan Markovsky, and Bart LM De Moor. A note on persistency of excitation. *Systems & Control Letters*, 54(4):325–329, 2005.
- [23] Xiaohui Lu, Jiachun Li, Detao Li, and Shaosong Li. Design of data-driven model predictive controller for vehicle lateral stability control. In *2023 7th CAA International Conference on Vehicular Control and Intelligence (CVCI)*, pages 1–6. IEEE, 2023.
- [24] Philipp Schmitz, Timm Faulwasser, and Karl Worthmann. Willems’ fundamental lemma for linear descriptor systems and its use for data-driven output-feedback mpc. *IEEE Control Systems Letters*, 6:2443–2448, 2022.
- [25] Guillem Torrente, Elia Kaufmann, Philipp Föhn, and Davide Scaramuzza. Data-driven mpc for quadrotors. *IEEE Robotics and Automation Letters*, 6(2):3769–3776, 2021.