

Waymoオープンシムエージェントの挑戦

Nico Montali John Lambert Paul Mougin Alex Kuefler Nicholas Rhinehart

Michelle Li Cole Gulino Tristan Emrich Zoey Yang Shimon Whiteson

Brandyn White

Dragomir Anguelov

Waymo LLC

Abstract

現実的でインタラクティブなエージェントによるシミュレーションは、自律走行ソフトウェア開発の重要なタスクである。本研究では、Waymo Open Sim Agents Challenge (WOSAC)を紹介する。WOSACは、このタスクに取り組む最初の公開チャレンジであり、対応するメトリクスを提案する。課題の目標は、自律走行のための行動モデルの評価と訓練に使用できる現実的なシミュレータの設計を刺激することである。評価方法の概要、多くの異なるベースラインシミュレーションエージェント手法の結果を示し、2023年3月16日から2023年5月23日までの2023年大会へのいくつかの投稿を分析する。WOSAC評価サーバーは投稿に対してオープンであり、タスクの未解決問題について議論する。

1 Introduction

シミュレーション環境は、自律走行行動システムの安価で迅速な評価を可能にし、同時に、潜在的に危険なソフトウェアリリースを物理システムに展開する必要性を低減する。合成センサーデータの生成はシミュレーションの初期目標[19, 43]であったが、知覚システムが成熟するにつれてユースケースは進化してきた。今日、シミュレーションの最も有望なユースケースの1つは、現実的にモデル化された交通参加者、すなわちシミュレーションエージェントを含むモンテカルロ試行による統計的モデル検査[1, 16]によるシステム安全性の検証である。

シミュレーションエージェントは、仮想世界で現実的な行動を行う制御対象である。この課題では、シミュレーションの計算負荷と複雑さを軽減するために、基礎となるセンサーデータ[13, 37, 62, 76]をシミュレートするのではなく、知覚システム出力、例えば物体の軌跡のような中間レベルの物体表現[2, 79]によって捕捉されるエージェントの行動をシミュレートすることに焦点を当てる(図1参照)。

シミュレーションにおいて現実的な挙動をモデル化するための要件は、シミュレーションエージェントが自律走行車(AV)の任意の挙動に対応する能力である。「ポーズダイバージェンス」または「シミュレーションドリフト」[3]は、走行ログにおけるAVの行動とシミュレーション中の行動との間の偏差として定義され、位置、方位、速度、加速度などの違いによって表現される。シーン内の他のすべてのオブジェクトのログ動作を直接再生する [32, 34, 35]




図1: WOSACは、シミュレーション問題をセンサーシミュレーションとしてではなく、中レベルの物体表現のシミュレーションとしてモデル化する。

表1:望ましい将来の物理状態のシーケンスを生成する3つの自律走行行動関連タスクの比較:軌道予測、計画、シミュレーション。観測値 $o_t \in \mathcal{O}$ には、模擬エージェントと環境の特性が含まれることに注意。

TASK	MULTIPLE OBJECT CATEGORIES	OUTPUTS	車両の運動学的制約	SYSTEM EVALUATION	SYSTEM OBJECTIVES
マルチエージェント軌道予測	✓	$((x_t, y_t, \theta_t, v_t^x, v_t^y))_{t=1}^T$	✗	OPEN-LOOP	運動学的精度とモードカバー安全性、
AV動作計画エージェントと	✗	$((x_t, y_t, \theta_t))_{t=1}^T$ or controls	✓	CLOSED-LOOP	快適性、分布的リアリズムの進展
環境シミュレーション	✓	$(o_t)_{t=1}^T; o_t \in \mathcal{O}$	✗	CLOSED-LOOP	

は、このポーズ発散のため、任意のAVプランニングの下では、限定的なりアルリズムを持つ可能性がある。このようなログプレイバックエージェントは、どのような状況下でも計画されたルートから逸脱しながらないため、実際のアクターの攻撃性を大幅に過大評価する傾向がある。一方、知能ドライバーモデル(IDM)[65]のようなヒューリスティックに従ったルールベースのエージェントは、過剰に収容され、反動的である。我々は、人間の行動の完全な分布に適合することを意味するリアリズムの定義を遵守し、中間に位置するシムエージェントの開発を評価し、奨励することを目指す。

我々の知る限り、シミュレーションエージェントの評価のための既存のベンチマークは今のところ存在しない。ベンチマークは、自律走行研究に関連する他の分野、特に知覚[6, 10, 24, 58]、運動予測[6, 10, 22, 72, 78]、運動計画[19]における注目すべき革新に拍車をかけている。我々は、標準化されたベンチマークが、シミュレーションエージェント開発の劇的な改善にも同様に拍車をかけることができると考えている。これらのベンチマークの中で、動き予測に焦点を当てたものは、おそらくシミュレーションに最も近いが、すべてオープンループ評価を含んでおり、我々のクローズドループ評価と比較すると明らかに不十分である。さらに、長期的な先物評価に適したリアリズム指標を紹介する。Waymo Open Motion Dataset (WOMD)[22]のような、実世界のエージェント行動例を含む関連データセットが現在存在し、WOSACを構築するためにWOMDの上に構築する。この課題では、例えば、信号機の状態や車両属性がモデル化されていないなど、可能な知覚出力のサブセットに焦点を当てるが、これは今後の研究に委ねる。

我々のベンチマークが提起する課題はユニークであり、もし我々がこのベンチマークを本当に進歩させることができれば、自動運転における難問の一つを解決したことを示すことができる。我々は多くの未解決の問題を抱えている: エージェント中心ではなく、シーン中心のシミュレーション手法に利点はあるのか?タスクに最も有用な生成モデリングフレームワークは何か?エージェントのポリシーにはどの程度のモーションプランニングが必要か、また、限界モーション予測はどこまで行えるか?シミュレーション手法をより効率的にするには?ベンチマークを設計し、様々なシミュレータ特性を強制するにはどうすればよいのか?WOSACチャレンジの最初の反復の間、ユーザーからの投稿は、これらの質問のサブセットに答えるのに役立った。例えば、ほとんどの手法は、最先端の限界運動予測手法、すなわちエージェント中心の手法に基づいて構築することが最も好都合であると感じることが観察された。

本研究では、交通シミュレーションと世界モデリングへの関心を喚起することを目的としたWaymo Open Sim Agents Challenge (WOSAC)について詳細に説明する。我々の貢献は以下の通りである:

- 自己回帰型トラフィックエージェントがログデータに割り当てる近似負対数尤度に基づく評価フレームワーク。
- 評価プラットフォーム、オンラインリーダーボード、 <https://waymo.com/open/challenges/2023/sim-agents/>で投稿可能。
- 様々なベースライン手法と、いくつかの外部投稿の実証的な評価と分析。

2 関連研究

マルチエージェント交通シミュレーションは、ALVINN [43]に遡り、数十年にわたり自律走行プランナの訓練と評価に使用されてきた。CARLA[19]、SUMO[33]、Flow[73]などのシミュレータは、シミュレータのための発見的な運転方針しか提供しないが、AV運動計画領域[11, 12, 15]での進歩は可能である。Nocturne[68]のような他の最近のシミュレータは、固定されたロードグラフと移動エージェントボックスからなる単純化された世界表現を使用している。

表2: シミュレーションエージェントの既存の評価方法項目はArxivタイムスタンプで時系列に並べられる。マルチエージェントシミュレーションをどのように評価すべきかについては、文献上ではコンセンサスが限られている。

Evaluation Protocol	ADE or minADE	Offroad Rate	Collision Rate	Instance-Level Distribution Matching	Dataset-Level Distribution Matching	Spatial Coverage or Diversity	Goal progress or Completion
ConvSocialPool [17]	✓			✓			
Trajectron [29]	✓			✓			
PRECOG [48]	✓			✓			
BARK [4]		✓	✓				✓
SMARTS [82]			✓				✓
TrafficSim [60]	✓	✓	✓			✓	
SimNet [3]	✓		✓				
Symphony [28]	✓	✓	✓		✓		
Nocturne [68]	✓		✓				✓
BITS [74]		✓	✓		✓	✓	
InterSim [59]	✓		✓				✓
MetaDrive [34]		✓	✓				✓
TrafficBots [79]	✓		✓	✓			
WOSAC (Ours)		✓	✓	✓			

シミュレーションエージェントのモデリングは、軌道予測の問題と密接に関連しており、シミュレーションエージェントは軌道予測のセットを計画として実行することができる[4, 59]。しかし、軌跡予測手法は伝統的にオープンループで学習されるため、クローズドループシミュレーション中に遭遇する領域外予測から回復する能力は限られている[51]。さらに、シーンレベルで一貫した共同将来サンプルを生成する予測手法はほとんどない[36, 48]。シムエージェントのモデリングは、各シムエージェントが独立してプランナーのレプリカを実行することができるため、プランニングとも関連している[4]。しかし、これら3つのタスクはそれぞれ、目的、出力、制約が大きく異なる(表1参照)。

学習されたシミュレータ文献の学習されたシミュレータは、入力モダリティだけでなく、ポリシーの協調、ダイナミクスモデルの制約、観測可能性などの仮定が大きく異なる。シーン中心のエージェントの協調的な行動は、オープンループの運動予測領域[8, 9, 57]で研究されているが、我々の知る限り、TrafficSim [60]は、学習されたシムエージェントがシーン中心の共同アクターポリシーを使用する唯一のクローズドループであり、他の全てのエージェントは協調することなく分散的に動作する[5, 28, 74]、すなわち、シーン内の各エージェントは、エージェント中心の推論を使用して同じモデルのレプリカによって独立に制御される。BITSとTrafficBots [74, 79]は一輪車ダイナミクスモデルを使用し、Nocturneは自転車ダイナミクスモデル[68]を使用するが、他のほとんどのものはそのような制約を指定していない。他の方法は、ラスタライズされたもの[3, 74]であれ、バクトル形式で提供されたもの[28, 79]であれ、入力のタイプが異なる。困難なシナリオの生成に特化した研究[47]もあれば、ユーザーベースの制御性を目的とした研究[81]もある。純粋な模倣学習[3]によって学習されたものもあれば、その失敗から回復するように学習するために、閉ループ敵対的損失[28, 60]やマルチエージェントRL[4, 34, 82]を含むものもある[51]。InterSim [4, 28, 59, 74, 79, 82]のようないくつかの研究は、ゴール条件付き問題定式化を用いているが、そうでないものもある[3]。

生成モデルの評価 Fréchet Inception Distance (FID) [26] を通して、分布マッチングは生成モデルを評価する一般的な方法となっている [18, 20, 27, 30, 31, 45, 46, 49, 52, 77]. Inception Score (IS) [53]のようなこれまでの評価手法は、条件付き分布と無条件分布のエントロピーを推論しているが、シミュレーション問題の多峰性のため、我々のケースでは適用できない。FIDは、生成された分布とデータ分布(シミュレーション領域では、ログに記録された分布)との差を測定する実世界のサンプルの統計量を使用することで、Inception Scoreを改善する。しかし、FIDはテストデータセット全体の統計量を単一の平均と共分散に集約するため、例ごとの感度は限定的である。

マルチエージェントシミュレーションの評価マルチエージェントシミュレーションをどのように評価すべきかについては、文献上ではコンセンサスが限られており(表2参照)、既存の主流ベンチマークは存在しない。安全性の重要性を考えると、既存のほとんど全てのシムエージェントの研究は、何らかの形で衝突率を測定しており[3, 28, 59, 60, 68, 74]、いくつかの多オブジェクト合同軌道予測手法も軌道の重なりを介してそれを測定している[36]。しかし、衝突率は静的な方針によって人為的にゼロに追いやることができるため、臨場感を測定することはできない。現実性の定量的評価には、ログデータとの比較が必要である。このような評価方法は、車両ダイナミクスの分布マッチング[28, 74]から、オフロード率の比較[28, 60, 74]、空間的カバレッジと多様性[60, 74]、ゴールまでの進捗[59, 68]まで、大きく異なる。しかし、目標は観測できないため、確実に抽出することは困難である。

平均変位誤差(ADE)のような指標によるログデータの直接再構成を要求することも提案されている[3, 68]が、AVやシムエージェントが任意の瞬間に取り得る現実的なアクションが複数あるため、その有効性は限定的である。この制限を克服するために、1つのオプションとして、15回のシミュレーションで最小平均変位誤差(minADE)を使用するTrafficSimのように、ユーザーがシミュレーションエージェントごとに複数の可能な軌道を提供できるようにすることである。[60].

近年、生成モデルに基づく評価は、主に分布マッチングメトリクスを通じて、シミュレーション領域でより一般的になってきている。Symphony [28]は軌跡の曲率に対するJensen-Shannon距離を用いる。NeuralNDE[75]は車速と車間距離の分布を比較し、BITS[74]はシーンごとに複数のロールアウトを使用してエージェントのシーン占有率に関するWasserstein距離を利用し、シミュレートされた速度と記録された速度の間のWasserstein距離と乗客の快適性をカプセル化できる2つの運動学的特徴をジャークする。後者はデータセットレベルでの分布間比較として計算されるが、この種のメトリックは我々の実験では限られた感度しか示していない。

尤度メトリクス(Likelihood metrics) 別の分布マッチングの枠組みは、点から分布への距離を測定することである。[17]と[29]は、同じ予測タイムステップの出力サンプルに対するカーネル密度推定(KDE)[42, 50]によって決定される、グランドトゥルースの軌跡の平均負対数尤度(NLL)として定義されるメトリックを導入している。このメトリックはある程度採用されている[54, 64]が、我々の研究では主にこのメトリックをベースにしている。PRECOG[48]やMFP[63]のような尤度ベースのシミュレーション生成モデルは、直接尤度を生成することに注意する。つまり、尤度を推定するためにサンプリングされた軌跡にKDEを使用する必要はなく、そのようなモデルクラスでは必要ではない。また、同時進行の研究[79]では、6つのロールアウトの下でGTシーンのNLLを測定している。

3 条件付き生成モデリングとしての交通シミュレーション

我々の目標は、データ駆動型評価フレームワークを定義し、一般にアクセス可能なデータでインスタンス化することで、交通シミュレータの設計を促進することである。我々は、オフボード知覚システムが固定され、与えられたものとして扱われる設定におけるエージェントの行動をシミュレートすることに焦点を当てる。

問題の定式化。ここで、 S は観測不可能な真世界状態の集合を表す、 O は観測値の集合、 $p(o_t | s_t)$ はサンプリング可能な放出分布、 $p(s_t | s_{t-1})$ は隠れマルコフ状態ダイナミクスを表す：隠れ状態がタイムステップ $t-1$ で s_{t-1} から時間 t で s_t に遷移する確率。各 $o_t \in O$ は、時間的に変化するAV中心成分と環境中心成分に分割できる： $o_t = [o_t^{AV}, o_t^{env}]$ 。 o_t^{env} は一般に豊富な特徴量を含むことができるが、我々の課題では非AVエージェントのポーズのみを含む。真の観測ダイナミクスを $p^{world}(o_t | s_{t-1}) = \mathbb{E}_{p(s_t | s_{t-1})} p(o_t | s_t)$ とする。

タスク $p^{world}(o_t | o_{<t}^c)$ の「世界モデル」 $q^{world}(o_t | s_{t-1})$ を構築するタスク、 $o_{<t}^c = [o_{<t}^{map}, o_{<t}^{signals}, o_{<t}^{H-1}, \dots, o_{t-1}]$ 、すなわち、静的マップ観測、交通信号観測、観測履歴のコンテキストを表し、履歴長は H である。

Task constraints:

1. q^{world} はTステップの自己回帰でなければならない。すなわち、シムエージェントモデルは10Hzのリサンプリング手順に従い、更新されたシーンを再観察し、以前の出力を消費しなければならない。
2. q^{world} は式1に従って因数分解しなければならない：

$$q^{world}(o_t | o_{<t}^c) = \pi(o_t^{AV} | o_{<t}^c) q(o_t^{env} | o_{<t}^c), \quad (1)$$

ここで、 $q(o_t^{env} | o_{<t}^c)$ は交通シミュレータ、 $\pi(o_t^{AV} | o_{<t}^c)$ はAV政策¹である。これらの特性の両方を満たさない提出物は、WOSAC リーダーボード上では考慮されない。

これは、現在の行動ではなく、次の観測に対して定義されるため、等価ではないが、行動に対する決定過程におけるポリシーの典型的な定式化に似ているので、ポリシーと呼ぶ。AVの行動空間 A を世界AVと等価と定義することで、標準政策 $\pi(a_t^{AV} | o_{<t}^c)$ と等価とすることができる。行動依存世界モデル $q(o_t | o_{<t}^c, a_{t-1}) = \delta(o_t^{AV} = a_{t-1}^{AV}) q(o_t^{env} | o_{<t}^c)$ を定義する。




図2: ベイズネットとしての必要因数分解のグラフィカルモデル: 式1からの2つの分布は自己回帰的にインターリーブされている: 1つはAVの「政策」 $\pi(o_t^{AV} | o_{<t}^c)$ を表し、もう1つは環境ダイナミクス $q(o_t^{env} | o_{<t}^c)$ を表す。グラフィカルモデルはこれら2つの分布を適用するTステップを表す。太い出射矢印は、すべての親ノードからすべての子ノードへの入力を受け渡しを示す。

チャレンジの提出報告書。生成的であることを要求することで、任意のトラフィックシミュレータとAVポリシーのペアからサンプリングすることができる。これら2つの性質は、[48]の図9を修正した図2の確率的グラフィカルモデルを意味する。アルゴリズム1と2は、有効な投稿と無効な投稿を示す。 p^{world} をモデル化する際の課題の多くは、多くの状況 $s_{t-1} \in S$ において、 p^{world} はシーン内のエージェントからの不確実性により複数の結果に密度を割り当てることにある。つまり、 $\pi(o_t^{AV} | o_{<t}^c)$ と $q(o_t^{env} | o_{<t}^c)$ はしばしば複数のモードを含む必要がある。 p^{world} の分布マッチングを、ログに記録された結果のデータセットと比較して評価する。AV観測空間政策と環境観測ダイナミクスへの必要因数分解 $q(o_t | o_{<t}^c) = \pi(o_t^{AV} | o_{<t}^c) q(o_t^{env} | o_{<t}^c)$ はかなり柔軟である。私たちは、その特定の構造にとらわれない。環境観測ダイナミクスの注目すべき選択肢の一つは「マルチエージェント」因数分解であり、 $q(o_t^{env} | o_{<t}^c) = \prod_{a=1}^{QA} \pi_a(o_t^{env,a} | o_{<t}^c)$ 、すなわち、環境観測ダイナミクスは、A個の観測空間ポリシーのシーケンスに因数分解される、 $o_t^{env} = [o_t^{env,1}, \dots, o_t^{env,A}]$ である。

アルゴリズム1 有効: 因数分解、閉ループ、エージェント中心シミュレーション

Input: Map o^{map} and traffic signals $o^{signals}$. Initial actor states $o_{-H-1:0} = \{o_{-H-1}, \dots, o_0\}$ where each $o_t^{env} = \{o_t^{env,1}, \dots, o_t^{env,A}\}$ for the A actors in the scene.

Output: Simulated observations $o_{1:T} = \{o_1, o_2, \dots, o_T\}$ for T simulation timesteps.

- 1: **for** $t = 1, \dots, T$ **do** ▷ Simulate for requested number of timesteps
 - 2: $o_t^{AV} \leftarrow \pi_{AV}(o_{<t}; o^{map}, o^{signals})$
 - 3: **for** $a = 1, \dots, A$ **do** 各タイムステップで各アクターの次の状態を生成する。
 - 4: $o_t^{env,a} \leftarrow \pi_a(o_{<t}; o^{map}, o^{signals})$
 - 5: $o_t = \{o_t^{env,a} : \forall a \in 1 \dots A\} \cup \{o_t^{AV}\}$
 - 6: **return** $o_{1:T} = \{o_1, o_2, \dots, o_T\}$
-

アルゴリズム2無効: 因数分解、オープンループ、エージェント中心シミュレーション

Input: Map o^{map} and traffic signals $o^{signals}$. Initial actor states $o_{-H-1:0} = \{o_{-H-1}, \dots, o_0\}$ where each $o_t^{env} = \{o_t^{env,1}, \dots, o_t^{env,A}\}$ for the A actors in the scene.

Output: Simulated observations $o_{1:T} = \{o_1, o_2, \dots, o_T\}$ for T simulation timesteps.

- 1: $o_{1:T}^{AV} \leftarrow \pi_{AV}(o_{<1}; o^{map}, o^{signals})$
 - 2: **for** $a = 1, \dots, A$ **do** 各アクターの将来のすべてのタイムステップで状態を生成する。
 - 3: $o_{1:T}^{env,a} \leftarrow \pi_a(o_{<1}; o^{map}, o^{signals})$
 - 4: **return** $o_{1:T} = \{o_{1:T}^{env,a} : \forall a \in 1 \dots A\} \cup \{o_{1:T}^{AV}\}$
-

4 ベンチマークの概要

4.1 Dataset

WOSACについては、Waymo Open Motion Dataset (WOMD) [22]のv1.2.0リリースのテストデータを使用する。WOMDを、各シナリオが履歴と未来のペア $(o_{-H-1:0}, o_{\geq 1})$ であるシナリオの集合Dとして扱う。

このデータセットは、最先端のオフボード知覚システムによって生成された、忠実度の高い物体の振る舞いと形状を大量に提供する。WOMDの9秒間の10Hzシーケンス(1.1秒間の履歴からH=11の観測、8秒間の未来のデータから80の観測からなる)を使用し、10Hzのオブジェクトトラックとシーケンスでカバーされる領域のマッピングデータを含む。データセット分割全体で、訓練で486,995、検証で44,097、テストで44,920のシナリオが存在する。これらの9.1秒のウィンドウは、20秒の103,354の採掘セグメントから、様々なオーバーラップでサンプリングされた。8秒間のシナリオ(80段階のシミュレーション)では、最大128 エージェント(うち1つはAVを表す必要がある)をシミュレートする必要がある。

エージェント定義:時刻 $t = 0$ 、すなわちシミュレーション開始前のログに記録された初期条件の最後のステップで有効な測定値を持つすべてのエージェントのシミュレーションが必要である。テスト分割データは隔離されているため、ユーザはハンドオーバー後に表示されるオブジェクトにアクセスできないため、シミュレーションを行うことは期待できない。3つのWOMDオブジェクトタイプ(車両、自転車、歩行者)のシミュレーションが必要である。オブジェクトの大きさは、履歴の最後のステップのように固定されたままです(元のデータでは変化します)。

提出物 x/y/zセントロイド座標とオブジェクトのボックスの方位をユーザが直接報告する必要があることを意味するモーションモデル(複数のエージェントタイプがあるためでもある)を強制しない(これは直接または適切なモーションモデルによって生成することができる)。投稿フォーマットに関する追加情報は付録を参照のこと。

ユーザが自らシミュレーションを作成できるようにすることで、評価サーバにコンテナ化されたソフトウェアを提出する必要がなくなり、ユーザの負担を軽減することができる。

4.2 Evaluation

エージェントは現実的な運転シナリオを確率的に生成すべきである。現実的なエージェント」とは、実走行中に観測されたシナリオの実際の分布と一致するエージェントと定義する。残念ながら、我々は分布の解析形式を知らないが、そこからWOMDを構成する例であるサンプルを持っている。そこで、エージェントによって誘導された分布の下で、実世界のサンプルの近似負対数尤度(NLL)を用いて、投稿を評価する。

我々が最小化したいNLLは次式で与えられる:

$$NLL^* = -\frac{1}{|\mathcal{D}|} \sum_{i=1}^{|\mathcal{D}|} \log q^{\text{world}}(o_{\geq 1,i} | o_{< 1,i}) \quad (2)$$

しかし、我々の問題設定において、式2を正確に最小化しようとする、2つの問題がある。まず、 $o_{\geq 1}$ は高次元である。そのため、より少ない数のコンポーネントメトリクスでシナリオをパラメータ化し(セクション4.2.1参照)、それらを複合NLLメトリクスに集約する(セクション4.2.2参照)。第二に、エージェントはサンプリングをサポートするが、ポイントワイズ尤度推定をサポートしないことがある[41]。実際、我々は、チャレンジ参加者がエージェントからサンプルを提出することだけを要求するため、異なるエージェントの提出の下でログに記録されたシナリオの正確な可能性を知る方法がない。この問題を回避するために、我々は、エージェント先物の提出された32のサンプルにヒストグラムをフィッティングすることによってNLL計算を標準化し、ヒストグラムを正規化することによって誘導されるカテゴリ分布の下でNLLを計算する。

4.2.1 成分メトリクス

NLL*をコンポーネントメトリクスに分割することには、いくつかの利点がある。セクション4.2で説明した次元の呪いを軽減する。また、評価に解釈可能性を追加し、研究者が異なるタイプのエラーをトレードオフできるようにする。

時系列NLL:シミュレーションデータの時系列的な性質を考えると、与えられたランセグメントに対して、与えられたオブジェクトに対して複数のタイムステップにわたってサンプルをどのように扱うかについて、2つの選択肢が浮かび上がる:それらを時間に依存しないサンプルとして扱うか、または時間に依存するサンプルとして扱うか。後者の場合、ユーザはログデータに存在する一般的な行動を1回のロールアウトで再構築するだけでなく、全く同じ時間間隔でそれらの行動を再現することが期待される。エージェントの行動をより柔軟にするために、NLLを計算する際に前者の定式化を使用し、各コンポーネントメトリック m を平均として定義する。

(in log-space) over the time-axis, masked by validity v_t : $m = \exp \left(- \frac{1}{\sum_t \mathbb{1}\{v_t\}} \sum_t \mathbb{1}\{v_t\} NLL_t \right)$.

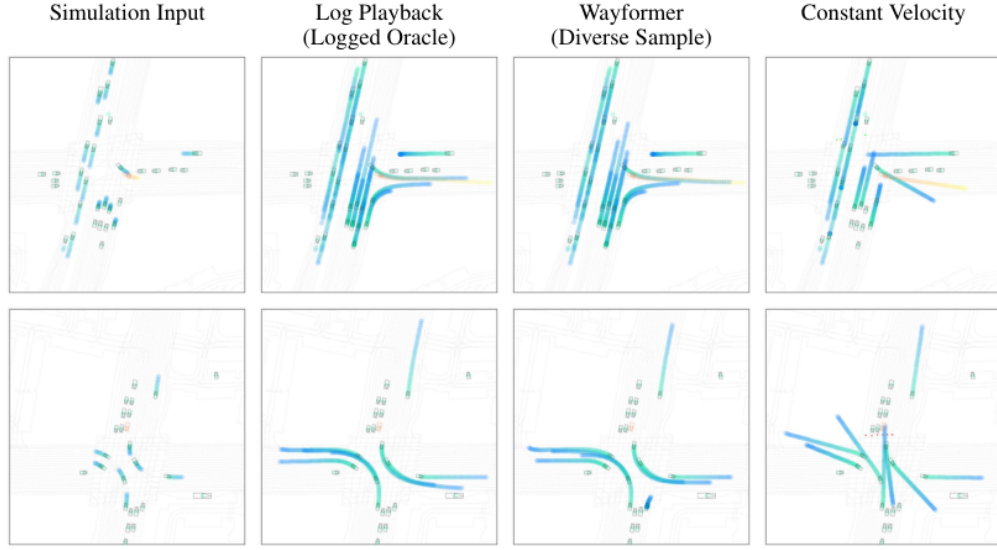


図3:2つの別々のWOMDシーン(上、下)におけるシミュレーション結果の視覚化。様々なベースライン手法の結果をWOMDの検証分割で2dで示す。シミュレーション入力」は文脈履歴 $0_{-H-1:0}$ を表し、他の列はすべて両方を可視化する($0_{-H-1:0}$, $0_{\geq 1}$)。1つはAVが左折の実行を完了するシーン(上段)、もう1つはAVが赤信号で停止したままのシーン(下段)である。2列目と3列目の各レンダリングは、シーンの全期間を描写している。環境模擬エージェントの軌跡は青緑色のグラデーションで描かれ、AVエージェントの軌跡は赤黄色のグラデーションで描かれます(それぞれ時間的な色勾配の中の円の並びとして描かれます)。

しかし、その結果、ログオラクルは1.0の尤度を達成しないのに対し、後者の定式化ではログオラクルは1.0の尤度を達成することに注意する。

定義 9つの測定値についてNLLを計算する:運動学的メトリクス(線速度、直線加速度、角速度、角加速度の大きさ)、物体相互作用メトリクス(最も近い物体までの距離、衝突、衝突までの時間)、地図ベースのメトリクス(道路端までの距離、道路逸脱)。完全な説明と追加の実装の詳細については、付録のセクションA.6を参照してください。

4.2.2 複合指標

各測定値の成分メトリクスを得た後、それらを単一の合成メトリクス \mathcal{M}^K に集約して、提出物を評価する:

$$\mathcal{M}^K = \frac{1}{NM} \sum_{i=1}^N \sum_{j=1}^M w_j m_{i,j}^K, \quad \sum_{j=1}^M w_j = 1 \quad (3)$$

ここで、 N はシナリオの数、 $M = 9$ はコンポーネントメトリクスの数である。成分メトリクス m と合成メトリクス \mathcal{M} もサンプル数 $K = 32$ でパラメータ化される。値 $m_{i,j}$ は i^{th} 番目の例における j^{th} 番目のメトリックの尤度を表す。メトリック M は、 j^{th} 番目のメトリックの重み w_j が手動で設定される、コンポーネントメトリック上の単純な凸結合(すなわち、加重平均)である。安全性を促進するために、衝突と道路出発のNLLの重み付けは、他のコンポーネントメトリクスの重み付けよりも2倍大きくなるように設定されている。

5 実験結果

図4と表3に、いくつかの手法の定量的な結果を示す。以下の各セクションで、各手法についてより詳細に説明する。




図4:WOMDのテストスプリットにおける各種ベースラインのチャレンジコンポジットメトリックの結果。

5.1 Baselines

ランダムエージェント: ランダムな軌道 $\{(x_t, y_t, \theta_t)\}$ $T_t=1$, for $T = 80$, AVの座標系において、 $x, y, \theta \sim N(\mu, \sigma^2)$, $\mu = 1.0$, $\sigma = 0.1$. 等速エージェント: 与えられたコンテキスト/履歴に記録された最後の方位と速度を使って軌跡を外挿するエージェント。有効な測定値に基づいて2段階の差を計算できない場合(例えば、オブジェクトはコンテキストの最終ステップにのみ現れる)、そのようなエージェントにはゼロ速度を設定する。
Wayformer (Identical Samples) エージェント: Wayformer[40]の動作予測モデルを用いて、モデル推論を2Hzで自己回帰的に実行することにより、オープンループとクローズドループのハイブリッドデータを生成するエージェント。エージェントは5つのシミュレーションステップでポリシーを実行し、その後再計画を行う。代わりに10Hzのリプランレートを用いた結果も表3に示し、リプランレートに関するアブレーションは付録に記載した。各エージェントの最尤軌跡を32回繰り返し、32個のサンプルを生成する。各エージェントはエージェント中心のフレームで同じポリシーによって実行され、推論のためにバッチ化されるため、必要な因数分解に従う。Wayformer (Diverse Samples) エージェント: Wayformer[40]が生成した軌跡も利用するが、尤度に応じてK個の可能な軌跡から多様なエージェント計画をサンプリングするエージェント。ログ付きオラクル:WOMDテスト分割から軌跡を直接コピーするエージェントで、32回の繰り返しがある。

5.2 外部からの投稿

エージェントシミュレーションのためのマルチバース変換器(MVTA)[71]: MTR[55, 56]にインスパイアされた手法で、クローズドループで学習・実行される。MVTAはGMMヘッドを持つ「後退地平」政策を用い、ベクトル入力を消費する。

MVTE: MVTA[71]の拡張版で、ロールアウト間のシミュレーションの多様性を高めるために、モデルのバリエーションのプールからMVTAモデルをサンプリングする。

MTR+++ [44]: MTR[55, 56]にヒントを得て、非衝突将来軌道のグラフの中で最も密度の高い部分グラフを探索する、0.5Hzの再計画率を持つハイブリッド開ループ/閉ループ法。

その他の外部投稿の評価については、付録のセクションA.4を参照のこと。

5.3 2023年チャレンジからの学び

CVPR 2023 Workshop on Autonomous Drivingに関連する2023年WOSACチャレンジ(2023年3月16日~2023年5月23日)の過程で、10チームから24のテストセット提出と16の検証セット提出を受けた。新しいチームが新しいメソッドを提出するため、常設リーダーボードの評価サーバーへの提出クエリを引き続き受信する。

トレンド投稿論文では、いくつかのトレンドが見られた。まず、チャレンジチャンピオンであるMVTA/MVTE[71]は、クローズドループトレーニングを利用し、その恩恵を受ける唯一の方法であった。MTR+++[44]や我々のWayformer-derived[40]ベースラインのようなオープンループで学習された他の手法では、高い複合メトリック結果を得るために必要な遅い再計画率で動作することがわかった(表3参照)。

表3: 尤度を表すWOMDのテスト分割におけるコンポーネントごとのメトリック結果。方法は、前のV0リーダーボードではなく、V1リーダーボード上の複合メトリックによってランク付けされている; ベストの1%以内の数字は太字である(「ログ付きオラクル」を除く)。* は、2023 年 5 月 23 日以降に受領した方法を示し、CVPR 2023 コンペティションの終了を意味する。

AGENT POLICY	LINEAR SPEED (\uparrow)	LINEAR ACCEL- (\uparrow)	ANG. SPEED (\uparrow)	ANG. ACCEL- (\uparrow)	DIST. TO OBJ. (\uparrow)	COLLISION (\uparrow)	TTC (\uparrow)	DIST. TO ROAD EDGE (\uparrow)	OFFROAD (\uparrow)	COMPOSITE METRIC (\uparrow)	ADE (\downarrow)	MINADE (\downarrow)
RANDOM AGENT	0.002	0.044	0.074	0.120	0.000	0.000	0.734	0.178	0.287	0.155	50.739	50.706
CONSTANT VELOCITY	0.074	0.058	0.019	0.035	0.208	0.345	0.737	0.454	0.455	0.287	7.923	7.923
CONSTANT VELOCITY (+ GAUSSIAN NOISE)	0.157	0.119	0.019	0.035	0.247	0.411	0.775	0.502	0.463	0.324	7.594	7.237
WAYFORMER (IDENTICAL SAMPLES, 10 HZ REPLAN) [40]	0.202	0.144	0.248	0.312	0.192	0.449	0.766	0.379	0.305	0.338	6.823	6.823
SBTA-ADIA [35]	0.317	0.174	0.478	0.463	0.265	0.337	0.770	0.557	0.483	0.420	4.777	3.611
WAYFORMER (DIVERSE SAMPLES, 10 HZ REPLAN) [40]	0.233	0.212	0.345	0.330	0.241	0.635	0.797	0.424	0.413	0.421	6.866	5.761
CAD [14]	0.349	0.253	0.432	0.310	0.332	0.568	0.789	0.637	0.834	0.531	3.334	2.308
JOINT-MULTIPATH++* [70]	0.434	0.230	0.515	0.452	0.345	0.567	0.812	0.639	0.682	0.533	5.293	2.049
WAYFORMER (IDENTICAL SAMPLES, 2 HZ REPLAN) [40]	0.331	0.098	0.413	0.406	0.297	0.870	0.782	0.592	0.866	0.575	2.498	2.498
MTR++* [44]	0.414	0.107	0.484	0.436	0.347	0.861	0.797	0.654	0.895	0.608	2.125	1.679
MVTA [71]	0.439	0.220	0.533	0.480	0.374	0.875	0.829	0.654	0.893	0.636	3.925	1.866
MVTE [71]	0.445	0.222	0.535	0.481	0.383	0.893	0.832	0.664	0.908	0.645	3.859	1.674
LOGGED ORACLE	0.561	0.330	0.563	0.489	0.485	1.000	0.881	0.713	1.000	0.722	0.000	0.000

第二に、LSTMとMCGブロック[66]を使用したJointMultiPath++を除き、ほぼすべての投稿がTrans formerベースの手法[67]を使用していた。第三に、すべての手法は、既存のモーションプラン ニングや文献にあるシムエーション手法ではなく、主に既存のモーション予測作品の上に構築さ れている。MVTA/MVTE[71]という1つの手法のみが、既存のシミュレーションエージェントの研究 であるTrafficSim[60]の側面と、後退する水平線計画ポリシーを実装する運動計画技術を組み込 んでいる。このように、第四に、プランニングに基づく手法を動作予測フレームワークに組み込 むことの利点が観察された。第五に、ほとんどの手法(JointMultipath++ [70]を除く)は、2022 CVPR Waymo Open Motion Prediction challenge cholderであるMTR [55, 56]をベースにしてい る。最後に、すべての投稿は、シーン表現から同時にサンプリングするのではなく、エージェン ト中心の座標フレームで動作した。

尤度メトリクスの報酬多様性我々は、尤度ベースのメトリクスが多様な未来を生み出すモデルに報酬を与える ことを発見した。例えば、Wayformerモデルでシーンあたり32の多様なロールアウトを生成すると、シーンあた り32の同一のロールアウトを生成するWayformerモデルよりも、我々の評価指標で11%良いパフォーマンスを示 す(図4参照)。

アルゴリズム目標としての衝突最小化 MTR++[44]は衝突のない未来の軌跡の無向グラフで徒党探索を 用い、CAD[14]は衝突を生じたオープンループの未来で拒絶サンプリングを用いるなど、衝突の少ない 未来を決定するアルゴリズム構成要素を設計した手法がいくつかある。この目的は人間の好みに沿っ たものであるが、実際の運転データ分布では密接な呼び出しや衝突が発生するため、この目的のため に最適化することは、分布の尾を削ることになる。日常的な実走行では、注意散漫なドライバーは一 般的に存在する。また、特定のシナリオでは、低品質のプランナーはパフォーマンスが低く、シムエ ーションと衝突することが予想されるため、現実的なシミュレーションを生成するためには、その ようなことを考慮する必要がある。これは、実走行のテール分布からの例が少ないWOMD[22]の限界を 示唆しており、衝突データをアップサンプリングする努力は有用であることが証明できる。さらに、C AD[14]のようなオープンループ手法では、事後的に衝突を除去することで、模擬エージェントではな くAVによる衝突を除去することができ、AVの性能を誤解を招くような楽観的な見方が得られる。

複合指標 vs. (min-)ADEとADE: テストセットへの投稿のうち、ADEとminADEによる順位と、我々のNLL複合指 標による順位は一致しないことがわかる。しかし、minADEが低い手法は、合成スコアが高い傾向にあり、ADE はそのような傾向を示さない。

複合指標結果図4と表3に示す順序順位は、学習された確率的シミュレーションエージェントが、発見的ベースライン だけでなく、学習された決定論的シミュレーションエージェントも上回ることを示している。オラクル経由でテスト データにアクセスすることになるため、サブミッションの実用的な上限として、複合メトリックスコア0.722を考慮 する。

コンポーネントメトリックの結果表3では、複合メトリックをコンポーネントメトリックの結果に 分解している。予想通り、「logged oracle」ベースラインは、9つのコンポーネントメトリクスの それぞれにおいて、最も高い尤度を達成した。最高性能の手法であるMVTE [71]は、1つの成分 指標(線形加速度尤度)を除くすべての指標で最高得点を獲得し、CAD [14]はMVTEを12%上回った(尤度0.253対0.222)。意外なことに、MVTE [71]は角加速度尤度が「対数オラクル」のパーセンテ ージポイント以内です(0.481対0.489)。

衝突尤度(0.893対1.000)と最近距離物体尤度(0.383対0.485)の両方において、トップパフォーマンス学習法(MVTE)と「ログ付きオラクル」の間のギャップは、対話的メトリクスに関する今後の研究において、改善の余地が大きいことを示している。

5.4 定性的結果

図3では、2つのWOMDシナリオにおける様々なベースラインの定性的比較を示す。この結果は、交差点内の行動の複雑さが、単純なヒューリスティックの予測能力をはるかに上回っていることを示している。両例とも、等速ベースラインから衝突が見られる。他のシミュージェント手法による追加の定性的な例は、付録のセクションA.5に示されている。

6 Discussion

限界 2023年のチャレンジでは、各チームのレポートで議論されている因数分解とクローズドループの要件に従って、各提出物の妥当性を手動で検証し、技術的なルールが微妙であることを確認した。オープンループ法やハイブリッドオープンループ/クローズドループ法を用いた投稿は、シミュレーションアプリケーションによっては適用範囲が限定的である可能性がある。

出力軌跡の提出をアップロードする代わりに、Dockerコンテナ化されたソフトウェアの提出に基づくベンチマークを確立していたとしても、アルゴリズム的かつ自動的に要件を強制することは依然として困難である。Dockerizedソフトウェアへの関数呼び出しの多くの特性は、ユーザーが任意の状態を維持する限り、例えばレイテンシを測定することができるが、システムは関数呼び出しの閉ループ性の詳細についてはすべて強制することができなかった。その結果、ユーザーから提出されたシミュレーションエージェントソフトウェアは、厳格なステートレス入出力データAPIを遵守しなければならない。そうすることで、衝突を事後的に除去する手法が閉ループとして適格かどうかに関する曖昧さを取り除くことができる。

ユーザーがコンテナ化されたシミュレータの提出物を提供する場合、我々の要求事項の遵守を促し、クローズドループ行動をさらに奨励するための一つのアプローチは、ユーザーが制御しないAVポリシーを提供し、対話することである。我々のベンチマークでは、ユーザーは独立したポリシーによってAVを制御することができた。独立した、保留されたAVモーションプランニングポリシーと新しいシナリオでシミュレータの提出を評価する能力は、さらなる貴重な分析を可能にする。

今後の課題 Object の挿入と削除はシミュレーション問題の重要な側面であるが、ユーザにとって WOSAC 課題の最初の反復の複雑さを軽減するために、意図的にオブジェクトの挿入や削除がないという仮定を導入した。シミュレータで訓練または評価されたモーションプランナーは、どのタイムステップでも新しいオブジェクトが出現する可能性のあるオクルージョンの領域に関して注意を払う能力を持たなければならない。この課題の将来の反復では、適切にモデル化されたオブジェクトの挿入と削除に報酬を与えるリアリズムメトリクス、例えば、各フレームに現れる車両の数や消える車両の数、自律走行車からのシミュレーションオブジェクトの距離に関する分布メトリクスを導入する予定である。WOMDデータセットのデータ分布には、すでにこのようなオブジェクトの挿入と削除が含まれている。

さらに、ユーザのモデリング課題を単純化するために、WOSACの最初の反復で、時間不変のオブジェクト次元の仮定を意図的に導入した。時変オブジェクト次元は、車両属性の一種と考えることができ、オブジェクト次元は、WOMDデータセットで提供される基礎データ分布において実際に変化する。今後の反復において、時変オブジェクト次元予測をベンチマークの一側面として含めることを期待する。

セクション5.3で議論したように、提出物の中に衝突最小化アルゴリズムコンポーネントが広く存在することを考えると、衝突はWOMD [22]データではあまり表現されていないか、我々のメトリクスが何らかの形で制限されると推定されるかもしれない。もう一つのアプローチは、合成された困難な初期条件[3, 21, 23, 47, 61, 69]を生成したり、実際の走行データからより近いコールや衝突をマイニングしたりすることで、評価データ分布の「尾を引く」ことである。

結論。本研究では、シミュレーションエージェントの評価に関する新たな課題を導入し、我々が必要とする様々な基準の根拠を説明した。研究コミュニティの継続的な参加を要請する。

謝辞および資金調達の開示について

本研究を直接支援するため、第三者からの資金提供を受けていない。課題作成にあたり、有益なフィードバックをいただいたBen Sapp氏に感謝する。Mustafa Mustafa, Kratarth Goel, Rami Al-Rfouには、我々の研究を加速させるコンサルテーション、モデル、インフラを提供していただいた。評価サーバーの開発・保守に協力してくれたAlexander Gorbanに感謝する。著者はすべてWaymo LLCの社員である。

References

- [1] Gul Agha and Karl Palmskog. A survey of statistical model checking. *ACM Transactions on Modeling and Computer Simulation (TOMACS)*, 28(1):1–39, 2018.
- [2] Mayank Bansal, Alex Krizhevsky, and Abhijit S. Ogale. ChauffeurNet: Learning to drive by imitating the best and synthesizing the worst. In *Robotics: Science and Systems XV*, 2019.
- [3] Luca Bergamini, Yawei Ye, Oliver Scheel, Long Chen, Chih Hu, Luca Del Pero, Błażej Osipiński, Hugo Grimmet, and Peter Ondruska. SimNet: Learning reactive self-driving simulations from real-world observations. In *ICRA*, 2021.
- [4] Julian Bernhard, Klemens Esterle, Patrick Hart, and Tobias Kessler. BARK: Open behavior benchmarking in multi-agent environments. In *IROS*, 2020.
- [5] Raunak P Bhattacharyya, Derek J Phillips, Blake Wulfe, Jeremy Morton, Alex Kuefler, and Mykel J Kochenderfer. Multi-agent imitation learning for driving simulation. In *IROS*, 2018.
- [6] Holger Caesar, Varun Bankiti, Alex H Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuScenes: A multimodal dataset for autonomous driving. In *CVPR*, pages 11621–11631, 2020.
- [7] Holger Caesar, Juraj Kabzan, Kok Seang Tan, Whye Kit Fong, Eric Wolff, Alex Lang, Luke Fletcher, Oscar Beijbom, and Sammy Omari. Nuplan: A closed-loop ml-based planning benchmark for autonomous vehicles. In *CVPR ADP3 workshop*, 2021.
- [8] Sergio Casas, Cole Gulino, Renjie Liao, and Raquel Urtasun. SpAGNN: Spatially-aware graph neural networks for relational behavior forecasting from sensor data. In *ICRA*, pages 9491–9497, 2020.
- [9] Sergio Casas, Cole Gulino, Simon Suo, Katie Luo, Renjie Liao, and Raquel Urtasun. Implicit latent variable model for scene-consistent motion forecasting. In *ECCV*, 2020.
- [10] Ming-Fang Chang, John Lambert, Patsorn Sangkloy, Jagjeet Singh, Slawomir Bak, Andrew Hartnett, De Wang, Peter Carr, Simon Lucey, Deva Ramanan, and James Hays. Argoverse: 3d tracking and forecasting with rich maps. In *CVPR*, June 2019.
- [11] ディアン・チェン、ブレイディ・ズー、ヴラドレン・コルトウン、フィリップ・クレーヘンビュール。不正行為による学習。ロボット学習学会, 66–75 ページ。PMLR, 2020.
- [12] ディアン・チェン、ヴラドレン・コルトウン、フィリップ・クレーヘンビュール。鉄道で世界から車で走ることを学ぶ。ICCV, 15590–15599ページ, 2021.
- [13] 陳雲、榮フリーダ、Shivam Duggal、王深龍、嚴新晨、Sivabalan Manivasagam、雪尚傑、Ersin Yumer、Raquel Urtasun。Geosim: 自動運転のためのジオメトリ認識合成によるリアルなビデオシミュレーション。CVPR, ページ 7230–7240, 2021 年 6 月。
- [14] Hsu-kuang Chiu and Stephen F. Smith. Collision avoidance detour: A solution for 2023 waymo open dataset challenge - sim agents. Technical report, Carnegie Mellon University, 2023.
- [15] フェリペ・コデヴィラ、マティアス・ミュラー、アントニオ・ロペス、ヴラドレン・コルトウン、アレクセイ・ドソヴィツキー。条件付き模倣学習によるエンドツーエンドの運転。ICRA, ページ4693–4700で。IEEE, 2018.
- [16] アンソニー・コロソ、ロバート・モス、マーク・コーレン、リッチー・リー、ミケル・コッヘンダーファー。サイバーフィジカルシステムのブラックボックス安全性検証のためのアルゴリズムのサーベイ。人工知能研究, 72: 377–428, 2021.
- [17] Nachiket Deo and Mohan M. Trivedi. Convolutional social pooling for vehicle trajectory prediction. In *CVPR Workshops*. Computer Vision Foundation / IEEE Computer Society, 2018.

- [18] Prafulla Dhariwal and Alexander Nichol. Diffusion models beat gans on image synthesis. In *NeurIPS*, 2021.
- [19] Alexey Dosovitskiy, German Ros, Felipe Codevilla, Antonio Lopez, and Vladlen Koltun. CARLA: An open urban driving simulator. In *CoRL*, 2017.
- [20] Patrick Esser, Robin Rombach, and Bjorn Ommer. Taming transformers for high-resolution image synthesis. In *CVPR*, 2021.
- [21] Nick Roy Ethan Pronovost, Kai Wang. Generating driving scenes with diffusion. In *ICRA Workshop on Scalable Autonomous Driving*, June 2023.
- [22] Scott Ettinger, Shuyang Cheng, Benjamin Caine, Chenxi Liu, Hang Zhao, Sabeek Pradhan, Yuning Chai, Ben Sapp, Charles R. Qi, Yin Zhou, Zoey Yang, Aurélien Chouard, Pei Sun, Jiquan Ngiam, Vijay Vasudevan, Alexander McCauley, Jonathon Shlens, and Dragomir Anguelov. Large scale interactive motion forecasting for autonomous driving: The waymo open motion dataset. In *ICCV*, 2021.
- [23] Lean Feng, Quanyi Li, Zhenghao Peng, Shuhan Tan, and Bolei Zhou. トラフィックジェン: 多様で現実的な交通シナリオを生成するための学習. 2023年ICRAにて.
- [24] Andreas Geiger, Philip Lenz, and Raquel Urtasun. Are we ready for autonomous driving? the kitti vision benchmark suite. In *CVPR*, 2012.
- [25] E.G. Gilbert, D.W. Johnson, and S.S. Keerthi. A fast procedure for computing the distance between complex objects in three-dimensional space. *IEEE Journal on Robotics and Automation*, 4(2):193–203, 1988.
- [26] マーティン・ホイゼル、ヒューバート・ラムサウアー、トーマス・ウンターティナー、ベルンハルト・ネスラー、セップ・ホクライター. 2つの時間スケールの更新規則で学習されたガンは、局所的なナッシュ均衡に収束する. 第31回神経情報処理システム国際会議講演論文集, 2017.
- [27] ジョナサン・ホー、アジェイ・ジャイン、ピーテル・アペール. ノイズ除去拡散確率モデル *NeurIPS*, 2020.
- [28] マクシミリアン・イグル、ダウウ・キム、アレックス・クフラー、ボール・ムーギン、ブニット・シャー、キリアコス・シアリス、ドラゴミール・アンゲロフ、マーク・パラトウッチ、ブランディン・ホワイト、シモン・ホワイトソン. 交響曲: 自律走行シミュレーションのための現実的で多様なエージェントの学習. 2022年ICRAにて.
- [29] Boris Ivanovic and Marco Pavone. The trajotron: Probabilistic multi-agent trajectory modeling with dynamic spatiotemporal graphs. In *ICCV*, October 2019.
- [30] テロ・カラス、サムリ・レイン、ティモ・アイラ. 生成的敵対ネットワークのためのスタイルベースの生成器アーキテクチャ. *CVPR*, 2019.
- [31] Tero Karras, Samuli Laine, Miika Aittala, Janne Hellsten, Jaakko Lehtinen, and Timo Aila. Analyzing and improving the image quality of stylegan. In *CVPR*, 2020.
- [32] パルト・コタリ、クリスチャン・ペローネ、ルカ・ベルガミニ、アレクサンドル・アラヒ、ピーター・オンドルスカ. Drivergym: 自律走行のための強化学習の民主化. *arXiv プレプリント arXiv:2111.06889*, 2021.
- [33] Daniel Krajzewicz, Georg Hertkorn, Christian Rössel, and Peter Wagner. Sumo (simulation of urban mobility)-an open-source traffic simulation. In *Proceedings of the 4th middle East Symposium on Simulation and Modelling (MESM20002)*, pages 183–187, 2002.
- [34] Quanyi Li, Zhenghao Peng, Lan Feng, Qihang Zhang, Zhenghai Xue, and Bolei Zhou. Metadrive: Composing diverse driving scenarios for generalizable reinforcement learning. *TPAMI*, 2022.
- [35] Yiren Lu, Justin Fu, George Tucker, Xinlei Pan, Eli Bronstein, Becca Roelofs, Benjamin Sapp, Brandyn White, Aleksandra Faust, Shimon Whiteson, et al. Imitation is not enough: Robustifying imitation with reinforcement learning for challenging driving scenarios. In *IROS*, 2023.
- [36] Wenjie Luo, Cheol Park, Andre Cornman, Benjamin Sapp, and Dragomir Anguelov. Jfp: Joint future prediction with interactive multi-agent modeling for autonomous driving. In *CoRL*, 2023.
- [37] Sivabalan Manivasagam, Shenlong Wang, Kelvin Wong, Wenyuan Zeng, Mikita Sazanovich, Shuhan Tan, Bin Yang, Wei-Chiu Ma, and Raquel Urtasun. Lidarsim: Realistic lidar simulation by leveraging the real world. In *CVPR*, June 2020.
- [38] Xiaoyu Mo, Haochen Liu, Zhiyu Huang, and Chen Lv. Simulating behaviors of traffic agents for autonomous driving via interactive autoregression. Technical report, Nanyang Technological University, 2023.

- [39] 李浩晨、陳呂。Xiaoyu Mo, Yang Xing, Haochen Liu, and Chen Lv. 階層型グラフニューラルネットワークを用いたマップ適応型マルチモーダル軌跡予測。IEEEロボティクスとオートメーションレターズ, 8(6):3685–3692, 2023.
- [40] Nigamaa Nayakanti, Rami Al-Rfou, Aurick Zhou, Kratarth Goel, Khaled S Refaat, and Benjamin Sapp. Wayformer: Motion forecasting via simple & efficient attention networks. In *ICRA*, 2023.
- [41] Sebastian Nowozin, Botond Cseke, and Ryota Tomioka. f-gan: Training generative neural samplers using variational divergence minimization. *Advances in neural information processing systems*, 29, 2016.
- [42] Emanuel Parzen. On estimation of a probability density function and mode. *The annals of mathematical statistics*, 33(3):1065–1076, 1962.
- [43] Dean A. Pomerleau. Alvin: An autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems*, 1988.
- [44] Cheng Qian, Di Xiu, and Minghao Tian. A simple yet effective method for simulating realistic multi-agent behaviors. Technical report, 2023.
- [45] Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. Zero-shot text-to-image generation. In *ICML*, 2021.
- [46] アディティヤ・ラメシュ、ブラフル・ダリワル、アレックス・ニコル、ケイシー・チュウ、マーク・チェン。クリップ潜在を用いた階層的テキスト条件付き画像生成。arXivプレプリントarXiv:2204.06125, 1(2):3, 2022.
- [47] デイビス・レンベ、ジョナ・フィリオン、レオニダス・J・ギバス、サンジャ・フィドラー、オル・リタニー。学習された交通事前分布を介した、事故が起りやすい運転シナリオの生成。CVPR, 2022年6月。
- [48] Nicholas Rhinehart, Rowan McAllister, Kris Kitani, and Sergey Levine. Precog: Prediction conditioned on goals in visual multi-agent settings. In *ICCV*, October 2019.
- [49] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *CVPR*, 2022.
- [50] Murray Rosenblatt. Remarks on some nonparametric estimates of a density function. *The annals of mathematical statistics*, pages 832–837, 1956.
- [51] Stephane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, 2011.
- [52] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Raphael Gontijo-Lopes, Burcu Karagol Ayan, Tim Salimans, Jonathan Ho, David J. Fleet, and Mohammad Norouzi. Photorealistic text-to-image diffusion models with deep language understanding. In *NeurIPS*, 2022.
- [53] ティム・サリマンス、イアン・グッドフェロー、ヴォイチェ・ザレンバ、ヴィッキー・チャン、アレック・ラドフォード、シー・チェン。ガンのトレーニングのための改良されたテクニック第30回神経情報処理システム国際会議講演文集, 2016.
- [54] ティム・ザルツマン、ボリス・イワノビッチ、プナルジェイ・チャクラヴァーティ、マルコ・パヴォネ。Trajectory++: 異種データによる動的に実現可能な軌道予測。ECCV, 2020.
- [55] 志小雪、江麗、戴登信、ベルント・シエレ。Mtr-a: 2022年waymoオープンデータセットチャレンジの1位ソリューション - 動き予測, 2022.
- [56] Shaoshuai Shi, Li Jiang, Dengxin Dai, and Bernt Schiele. Motion transformer with global intention localization and local movement refinement. In *Advances in Neural Information Processing Systems*, 2022.
- [57] DiJia Su, Bertrand Douillard, Rami Al-Rfou, Cheolho Park, and Benjamin Sapp. 行動予測モデルにおける座標フレームギャップの狭め: シーン中心の効率的で正確な動き予測のための蒸留。arXiv:2206.03970, 2022.
- [58] Pei Sun, Henrik Kretschmar, Xerxes Dotiwalla, Aurelien Chouard, Vijaysai Patnaik, Paul Tsui, James Guo, Yin Zhou, Yuning Chai, Benjamin Caine, et al. Scalability in perception for autonomous driving: Waymo open dataset. In *CVPR*, 2020.
- [59] Qiao Sun, Xin Huang, Brian Williams, and Hang Zhao. InterSim: Interactive traffic simulation via explicit relation modeling. In *IROS*, 2022.

- [60] サイモン・スオ、セバスチャン・レガラード、セルジオ・カサス、ラクエル・ウルタスン。TrafficSim: 現実的なマルチエージェントの行動をシミュレートするための学習。CVPR, 2021.
- [61] トラン・シュハン、ウォン・ケルビン、ワン・シェンロン、シババラン・マニヴァサガム、レン・メンジー、ウルタスン・ラクエル。Scenegen: 現実的な交通シーンを生成するための学習。CVPR, 2021年6月。
- [62] マシュー・タンシック、ヴィンセント・カッサー、シンチェン・ヤン、サブエック・ブラダン、ベン・ミルデンホール、プラトゥル・P・スリニヴァサン、ジョナサン・T・パロン、ヘンリック・クレツツシュマル。ブロック・ナーフ: スケーラブルな大シーンニューラルビュー合成。CVPR, 2022.
- [63] Charlie Tang and Russ R Salakhutdinov. Multiple futures prediction. In *NeurIPS*, 2019.
- [64] Luca Anthony Thiede and Pratik Prabhanjan Brahma. Analyzing the variety loss in the context of probabilistic trajectory prediction. In *ICCV*, October 2019.
- [65] Martin Treiber, Ansgar Hennecke, and Dirk Helbing. Congested traffic states in empirical observations and microscopic simulations. *Physical review E*, 62(2):1805, 2000.
- [66] Balakrishnan Varadarajan, Ahmed Hefny, Avikalp Srivastava, Khaled S. Refaat, Nigamaa Nayakanti, Andre Cornman, Kan Chen, Bertrand Douillard, Chi Pang Lam, Dragomir Anguelov, and Benjamin Sapp. Multipath+: Efficient information fusion and trajectory aggregation for behavior prediction. In *ICRA*, 2022.
- [67] アシシュ・ヴァスワニ、ノーム・シャゼール、ニキ・パルマー、ヤコブ・ウスコレイト、リオン・ジョーンズ、エイダン・N・ゴメス、L・ウカシュ・カイザー、イリア・ポロスヒン。アテンションがあればいい。神経情報処理システムの進歩, 2017.
- [68] Eugene Vinitsky, Nathan Lichtlé, Xiaomeng Yang, Brandon Amos, and Jakob Foerster. Nocturne: a scalable driving benchmark for bringing multi-agent learning one step closer to the real world. In *NeurIPS Datasets and Benchmarks Track*, 2022.
- [69] Jingkan Wang, Ava Pun, James Tu, Sivabalan Manivasagam, Abbas Sadat, Sergio Casas, Mengye Ren, and Raquel Urtasun. Advsim: Generating safety-critical scenarios for self-driving vehicles. In *CVPR*, 2021.
- [70] 王文錫、陳浩天。シミュレーションエージェントのためのジョイントマルチパス++。技術報告書、2023年
- [71] 王宇、趙鉄リオ、李範。マルチバーストランスフォーマー: ウェイモオープンシムエージェントチャレンジ2023の1位ソリューション。テクニカルレポート、ペガサス、2023年。
- [72] ベンジャミン・ウィルソン、ウィリアム・チー、タンメイ・アガルワル、ジョン・ランバート、ジャズート・シン、シッデシュ・カandelワル、ボーエン・パン、ラトネシュ・クマール、アンドリュー・ハートネット、ジョニー・ケースモデル・ポンテス、デヴァ・ラマナン、ピーター・カー、ジェームズ・ヘイズ。アルゴリズム2: 自動運転の知覚と予測のための次世代データセット。データセットとベンチマークに関する神経情報処理システムトラック(NeurIPS Datasets and Benchmarks 2021)予稿集, 2021.
- [73] Cathy Wu, Aboudy Kreidieh, Kanaad Parvate, Eugene Vinitsky, and Alexandre M Bayen. Flow: Architecture and benchmarking for reinforcement learning in traffic control. *arXiv preprint arXiv:1710.05465*, 10, 2017.
- [74] Danfei Xu, Yuxiao Chen, Boris Ivanovic, and Marco Pavone. Bits: Bi-level imitation for traffic simulation. In *ICRA*, 2023.
- [75] Xintao Yan, Zhengxia Zou, Shuo Feng, Haojie Zhu, Haowei Sun, and Henry X Liu. Learning naturalistic driving environment with statistical realism. *Nature Communications*, 14(1):2037, 2023.
- [76] Zhenpei Yang, Yuning Chai, Dragomir Anguelov, Yin Zhou, Pei Sun, Dumitru Erhan, Sean Rafferty, and Henrik Kretschmar. Surfegan: Synthesizing realistic sensor data for autonomous driving. In *CVPR*, June 2020.
- [77] 于建瑞、徐元中、甲静宇、黄天、白群健、王紫瑞、ヴィジャイ・ヴァスデバン、アレクサンダー・クー、楊銀飛、ブルク・カラゴル・アヤン、ベン・ハッチンソン、ウェイ・ハン、ザラナ・パレック、シン・リー、ハン・チャン、ジェイソン・バルドリッジ、ウー・ヨンホイ。内容豊富なテキストから画像への生成のための自己回帰モデルのスケーリング。機械学習研究論文集, 2022.
- [78] 張偉、孫立廷、王ディ、石浩傑、オーブリー・クラウゼ、マクシミリアン・ナウマン、ジュリアス・クメルレ、ヘンドリック・ケーニヒショフ、クリストフ・シュタイラー、アルノー・デ・ラ・フォルテル、富塚雅義。INTERACTIONデータセット: セマンティックマップを用いた対話型運転シナリオにおける、国際的、敵対的、協調的な運動データセット。arXiv:1910.03088[cs, eess], 2019.

- [79] 張哲軍、アレクサンダー・リニガー、戴登信、フィッシャー・ユー、リュック・ヴァン・グール。トラフィックボット：自律走行シミュレーションと運動予測のための世界モデルに向けて。2023年ICRAにて。
- [80] 中志遠、Davis Rempe、陳玉暁、Boris Ivanovic、曹玉龍、徐丹飛、マルコ・パヴォネ、レイ・バイシャビ。シーンレベルの拡散による言語ガイド付き交通シミュレーション。2023年、CoRLにて。
- [81] 趙紫源、Davis Rempe、徐丹飛、陳玉暁、Sushant Veer、Tong Che、Baishakhi Ray、Marco Pavone。制御可能な交通シミュレーションのためのガイド付き条件付き拡散。2023年ICRAにて。
- [82] 周明、羅淳、ジュリアン・ヴィルエラ、楊ヤオドン、デビッド・ルス、ミャオ・ジアユー、張偉南、モンゴメリー・アルバン、IMAN FADAKAR、陳正、黃重西、溫英、キミア・ハッサンザデ、ダニエル・グレイブス、朱正邦、ニ・イーハン、ナット・グエン、モハメド・エルザイ、ハイサム・アンマル、アレクサンダー・コーウェン=リパース、サンジーバン・アヒラン、チェン・ティアン、ダニエル・パレニチェック、カスラ・レザエ、ペイマン・ヤドメラット、クン・シャオ、ドン・チェン、張宝安、張宏波、ハオ・ジアンエ、劉武龍、王淳。スマート：自律走行のためのオープンソースのスケラブルなマルチエージェントRLトレーニングスクール。CoRL, 2020.

A Appendix


この付録では、Wayformer由来の[40]シミュレーションエージェントのベースラインの再計画率がテスト分割に与える影響と、2023年のCVPRコンペティションからの追加学習について調査したアブレーションを提供する。また、外部からのチャレンジ提出による手法の説明、そのような手法の対応する定性的結果、我々が使用する9つのコンポーネントメトリクスの実装の詳細も追加で含める。最後に、使用するデータセットの分割の詳細について説明し、リーダーボードの提出指示を与える。

ベンチマークバージョン 2023年12月、衝突尤度とオフロード尤度の計算精度を向上させ、ほとんどの衝突尤度スコア、オフロード尤度スコア、複合メトリックの結果を改善した。本稿では、CVPR 2023の自律走行ワークショップで発表された前回のV0スコアではなく、更新されたスコア(ベンチマークのV1バージョン)について説明する。リーダーボードの両バージョンはオンラインで入手可能である(V1リーダーボード、V0リーダーボード)。


A.1 再計画率アブレーション結果

本論文の表3に示すように、またセクション5で議論したように、WOMDテストセットにおけるオープンループ学習済みモデルの複合メトリック性能に対する再計画率の影響のアブレーションを実行する。我々は、シーンごとに複数の多様なロールアウトがサンプリングされるか、シーンごとに32の同一のロールアウトが生成されるかに関係なく、より頻繁な再計画率がWayformerベースの[40]エージェントに悪影響を与えることを示す。同一サンプル生成エージェントの場合、2Hzのリプランニングから10Hzのリプランニングに移行すると、41.2%の相対的な性能低下(0.575対0.338の複合スコア)が見られる。


図5では、同じ同一サンプル生成エージェントについて、100msから1100msの再計画間隔からいくつかの追加データを可視化している。



(a) WOSAC 複合指標と再計画率の比較。



(b) ADE対再計画率。



(c) 成分尤度メトリクスと再計画率。

図5:WayformerベースラインのWOSACテストセットにおける様々な再計画率での結果(32回のロールアウトで同一サンプルを生成)。再計画率が1Hzから2Hz、そして10Hzに増加するにつれて、性能の滑らかな劣化が観察される。

A.2 2023年CVPRコンペティションからの追加学習

生成モデリング生成モデルには多くのファミリーが存在するが、ほとんどのチャレンジ参加者は、そのようなモデルの狭いクラス、すなわちGMMにモデリングを制限した。我々の知る限り、2023年のCVPRチャレンジにおいて、フロー、GAN、変分オートエンコーダ(VAE)モデルの正規化、または拡散モデルのノイズ除去によって生成されたシムエージェントの振る舞いを提出したユーザーはいなかったが、このような拡散技術は最近シミュレーションエージェントの文献でより一般的になっている[80, 81]。WOSACチャレンジへの参加者が増えるにつれて、将来的にこの状況は変わると予想される。

さらに定量的な分析 JointMultiPath++[70]とCAD[14]の2つのオープンループの提出物を上回り、表4に示すように、上位4つの実行方法は、クローズドループ(MVTE[71]、MVTA)またはハイブリッド方式(MTR++[44]、Wayformer[40])で完全に実行されたことに注目する。このギャップは、衝突尤度メトリックにおいて、非開ループ法と開ループ法の間で特に明確である。

我々が評価した全てのベースラインの中で、角ベースの尤度に関しては、等速ベースラインが最も弱い。例えば、MVTE法が同じ2つの成分指標でそれぞれ0.54と0.38の尤度を達成するのに対して、角速度(0.02)と角加速度(0.04)の両方でゼロに近い尤度を達成する。この結果は、我々の等速モデルがヨーレートを考慮していないため、直感的である。

A.3 自律走行行動に関する他のベンチマークとの追加比較

表4では、我々のWOSACベンチマークを、自律走行のための行動モデルの評価に使用される他のベンチマークと比較する。

BENCHMARK NAME	TASK
Argoverse [10]	Trajectory Forecasting
INTERPRET (INTERACTION) [78]	Trajectory Forecasting
Argoverse2 [72]	Trajectory Forecasting
nuScenes [6]	Trajectory Forecasting
WOMD [22]	Trajectory Forecasting
CARLA [19]	Motion Planning
nuPlan [7]	Motion Planning
WOSAC (Ours)	Multi-Agent Simulation

表4: 自律走行のための行動モデルの評価のための既存のベンチマーク。

A.4 外部チャレンジの提出による方法に関する追加情報

エージェントシミュレーションのためのマルチバーストランスフォーマー(MVTA)[71]: TrafficSim[60]にインスパイアされた手法で、クローズドループで学習・実行され、WOSACの因数分解と自己回帰の要件を遵守している。後続の地平線」ポリシー(すなわち、1秒間の未来の動きを予測するが、次の100ミリ秒のみを使用する)を使用する。MTR[55, 56]に触発され、MVTAは変換器ベースのエンコーダとデコーダ(MTRで実装されているのと同じエンコーダ/デコーダ層を採用)の上にガウス混合モデル(GMM)ヘッドを配置し、ベクトル入力を消費する。MVTAは、固定長の履歴をコンテキストとして利用するのではなく、可変長の履歴を利用することで、過去のデータをすべて利用できる可能性がある。入力エージェントエンコーディングは、エージェントの履歴運動状態(すなわち、位置、オブジェクトサイズ、方位角、速度)と、各エージェントのワンホットカテゴリマスクを含む。予測ヘッドには、5つのGMMパラメータ(μ_x , μ_y , σ_x , σ_y , ρ)を出力する回帰ヘッドと、タイムステップの速度(v_x , v_y)と方位($\sin(\theta)$, $\cos(\theta)$)の予測値、確率 p を出力する分類ヘッドが含まれる。両ヘッドとも、クエリ内容特徴量($\text{num_query} \times \text{hidden}$ 特徴量次元)を入力とする。

MVTE: MVTA[71]の拡張版で、3種類のMVTAを学習し、ランダムに選択して32のシミュレーションを生成し、ロールアウト間のシミュレーションの多様性を高める。

MTR++ [44]: 0.5Hzの再計画率と2秒の予測ホライズンを持つハイブリッド手法。MTR++は10Hzのレートで再プランニングしないため、WOSACのクローズドループ要件に完全には従わないことに注意。MTR++もワールド対AVポリシーが分離されていないため、ポリシー因数分解の要件に従わない。MTR [55, 56]に触発され、この方法はMTRの2つの重要な限界、すなわち不正確な方位予測と、限界予測だけで発生する過剰な衝突に対処する。最初の問題を克服するために、著者らはx/yの軌跡から見出しを推定している。

第二に、衝突を最小化するために、著者らはMTRによってエージェントごとに予測される $K = 6$ 個の軌道を考慮し、貪欲な方法で指数関数的な数の先物を刈り込む。 6^N の組み合わせに対する総当り的な網羅的探索は計算不可能であるため、MTR+++は、非衝突将来の軌道のグラフの中で最も密な部分グラフを探索する。

まず、 $6N \times 6N$ の距離行列 D が構築され、エントリ $D_{6m+i-1, 6n+j-1}$ は、エージェント m の i 番目に高い軌道とエージェント n の j 番目に高い軌道の間の最小L2距離を示す。次に、距離行列は、オブジェクトの広がりに応じて、どの距離が衝突に対応するかを評価することによって、2値化される。最後に、徒党探索ヒューリスティック法は、サイズ N の密な部分グラフを見つける。32個の微調整されたMTRモデルのアンサンプルが32個のロールアウトを作成するために採用され、各モデルは1個のロールアウトを生成する。

衝突回避デツァー(CAD)[14]: 既存の運動予測手法であるMTR[55, 56]を基に、限界軌道予測を行い、将来のエージェント衝突が予想される場合には、最大試行回数が枯渇するまで、将来全体を再サンプリングするオープンループ手法。CADは因数分解の要件を遵守しているが、WOSACの閉ループ要件には準拠していない。世界対AVポリシーの因数分解は、2つのエージェントグループに対してMTR運動予測モデルの異なるチェックポイントを使用することで達成され、非評価エージェントの運動は等速モデルを使用してシミュレートされる。

Joint-Multipath++ [70]: MultiPath++[66]をベースに、オープンループでシーンセンタリックな手法で、1つのモデルで32回のロールアウトを行い、それぞれが全長80の軌跡を表す。JointMultiPath++はAV対ワールドポリシーを因数分解しないため、WOSACのポリシー因数分解要件に完全には従わない。エージェント履歴情報(全エージェントの位置と方位)はAVの座標フレームに変換され、最も近い車線情報は各エージェントに選択される。JointMultiPath++は、そのエンコーダにおいて、2つのLSTMと1つのMultiContextGating(MCG)[66]ブロックの出力を連結して、エージェントごとの埋め込みを形成する。1つのLSTMはエージェント履歴をエンコードするために使用され、もう1つのLSTMはエージェント履歴のステップごとの違いをエンコードするために使用され、MCGブロックは対応するタイムステップを持つエージェント履歴をエンコードするために使用される。後続のMCGブロックは、エージェントごとの情報を道路網(ポリライン)の埋め込みと融合させる。デコーダでは、一連のMLPブロックが、 n 個のエージェント毎の埋め込みを、 $n \times 32 \times 80 \times 3$ の出力テンソルとして表されるロールアウトに変換する²。

SBTA-ADIA Moら[38]: 既存の動き予測手法[39]をベースに構築。この階層的な手法は、GNNシーンエンコーダに基づくマルチエージェントゴール予測の第一段階と、ゴール閉ループを達成しようとする単純な計画方針に問題を分割する。

A.5 外部チャレンジの提出による追加の定性的結果

図6と図7では、外部チャレンジの提出によるシミュレーション結果の定性的な例を追加で示している。

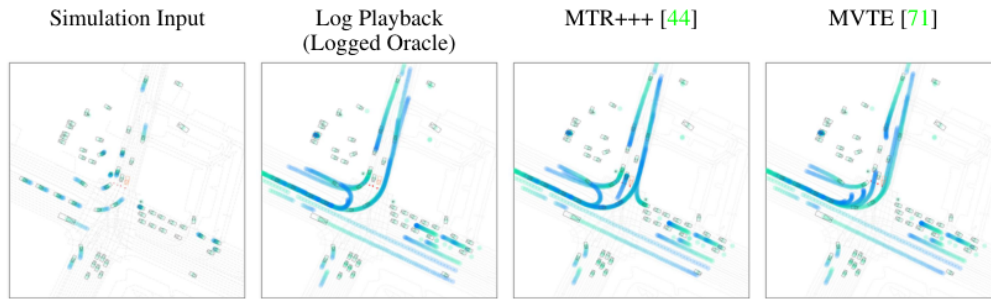


図6: WOMBのテストスプリットにおけるシミュレーション結果の2次元可視化。MVTEは衝突を示し、MTR+++はニアミスを生成する。シミュレーション入力「文脈履歴 $0_{-H-1:0}$ を表し、他の列はすべて両方を可視化する($0_{-H-1:0}$, $0_{\geq 1}$)。AVが赤い信号で停止したまま、提出された32のロールアウトから選択された、1つのシーンに対する1つの可能な未来が表現される。2, 3, 4列の各レンダリングは、シーンの全期間を表している。環境模擬エージェントの軌跡は、緑青のグラデーションで描かれる(それぞれ、時間的な色のグラデーションの中の円のシーケンスとして描かれる)。AVエージェントはオレンジ色で描かれている。

²Code available at <https://github.com/wangwenxi-handsome/Joint-Multipathpp>.



図7:様々なベースライン手法を用いたWOMDのテスト分割による単一シーンでのシミュレーション結果の2次元可視化。この1つのシーンで考えられる4つの未来が表現され(1行に1つ)、32の提出されたロールアウトから選択される。シミュレーション入力」は文脈履歴 $0_{-H-1:0}$ を表し、他の列はすべて両方を可視化する($0_{-H-1:0}$, $0_{\geq 1}$)。2列目、3列目、4列目の各レンダリングは、シーンの全期間を表している。環境模擬エージェントの軌跡は青緑色のグラデーションで描かれ、AVエージェントの軌跡は赤黄色のグラデーションで描かれます(それぞれ時間的な色勾配の中の円の並びとして描かれます)。AVエージェントはオレンジ色で描かれている。

A.6 コンポーネントメトリクスの実装詳細

1. 直線速度: 一次導関数の符号なし大きさ $\Delta v \Delta = \Delta_t^{x_t+1-x_t} \Delta_2$ ここで、 $x_t = [x_t, y_t, z_t]$, 3次元軌跡点間の1ステップ差として計算される3次元の直線速度。速度は、エゴエージェントの方位に対して定義することも、北に対する道路の向きに基づいて、速度の方向が都市固有である可能性のあるグローバル座標系に対して定義することもできるため、速度ではなく速度を採用する。これは逆に動く物体を捉えることはできないが、稀な動作であるため、簡略化のため省略する。
2. 線形加速度の大きさ: 二次微分の符号付き大きさ、物体の速度の1ステップ差として計算される3D。 v_t^{t+1} 。
3. 角速度: 符号付き一次導関数 $\omega = \frac{d(\theta_t+1, \theta_t)}{dt}$ 、ここで $d(-)$ は単位円上の2つの角度間の最小角度差を表す、 $d(-)$ は $S^1(2)$ 上の距離メトリックで、 $\theta_t, \theta_{t+1} \in [0, 2\pi]$ で $\min\{|\theta_{t+1} - \theta_t|, 2\pi - |\theta_{t+1} - \theta_t|\}$ として計算される。
4. 角度加速度の大きさ: 角速度 ω の1ステップ差として計算される2次微分で、 $\frac{d^2(\theta_t+1, \theta_t)}{dt^2}$ 。
5. 最も近いオブジェクトまでの距離: シーン内の最も近いオブジェクトまでの符号付き距離(メートル)。Gilbert-Johnson-Keerthi(GJK)距離アルゴリズム[25]の簡略版に従って、ボックスポリゴンのミンコフスキー差分を使用する。
6. 衝突: 衝突: 任意の時点で、他のオブジェクトと衝突したオブジェクトを示すカウント。つまり、上述のように最も近いオブジェクトへの符号付き距離が負の値になったとき。
7. 衝突までの時間(TTC): 衝突までの時間(TTC): 物体が物体と衝突するまでの時間(秒)。物体とは、方位と横方向の距離から得られるアライメント条件に基づき、物体追従(tailgating)動作を示すものと定義される。
8. 道路端までの距離: シーン内の最も近い道路端までの符号付き距離(メートル)。
9. 道路の出発: オブジェクトがどの時点で道路から外れたかを示すブール値 [60]。

サポートがゼロのヒストグラムビンから未定義のスコアを防ぐために、0.1の擬似カウントでラプラス平滑化を採用する。

挿入オブジェクトと削除オブジェクトの処理評価時に、ログに記録されたデータ分布とシミュレートされたデータ分布の間のオブジェクトの挿入/削除バイアスを防ぐため、ログに記録されたデータ分布を計算する際に、ログに記録されたテストセットから新たに生成されたオブジェクト(履歴間隔の後に出現)を破棄する。WOMDデータセットのデータ分布には、すでにこのようなオブジェクトの挿入と削除が含まれている。

A.6.1 評価ソースコードの参照

このセクションでは、本論文のセクション4.2.1で議論した9つのメトリクスの具体的な実装へのポイントを提供する:

- キネマティックベースの特徴: 線速度、直線加速度の大きさ、角速度、角加速度の大きさ(メトリクス1, 2, 3, 4): [コード]
- 相互作用に基づく特徴量: TTCと最近接物体までの距離(メトリクス5, 6, 7): [Code]と修正GJKアルゴリズム実装[Code]。
- 地図ベースの特徴量: 道路の出発と道路端までの距離(メトリクス8, 9): [コード]

時系列ベースのNLL計算の実装はこちら: [コード]。

A.6.2 評価コードのライセンスと依存関係

WOMD [22]データセット自体は、非商用ライセンス(www.waymo.com/open/terms)、Waymo Open Sim Agents Challenge(WOSAC)の評価コードはBSD+限定特許ライセンスで公開されている。<https://github.com/waymo-research/waymo-open>

n-dataset/blob/master/src/waymo_open_dataset/wdl_limited/sim_agents_metrics/PATENTSおよびhttps://github.com/waymo-research/waymo-open-dataset/blob/master/src/waymo_open_dataset/wdl_limited/sim_agents_metrics/LICENSE.

使用した依存関係には、NumPy(numpy)、Waymo Open Datasetリポジトリ(waymo-open-dataset-tf-2-11-0==1.5.2)、TensorFlow(tensorflow)、TensorFlow Probability(tensorflow_probability)、Matplotlib(matplotlib)、TQDM(tqdm)、Protocol Buffers(google.protobuf)、Python標準ライブラリインポート(os、tarfile、dataclasses)が含まれる。

A.7 使用したWOMD分割に関する追加情報

シナリオのプロトタイプとtf.Exampleのフォーマット間でオブジェクト数の不一致があるため、評価から401の実行セグメントを除外した。これは、ちょうど128のオブジェクトスロットを持つ固定形状のtf.Exampleテンソルからオブジェクト数の切り捨てが発生するためである。また、マップが欠落している9つのテスト実行セグメントを評価から除外する(ただし、検証セットに存在する各シナリオにマップが存在する)³。

表5:使用したWOMDデータセット[22]の分割の統計。

	DATASET SPLIT	
	VALIDATION	TESTING
ALL SCENARIO COUNTS	44097	44920
EVALUATED SCENARIO COUNTS	43696	44520

A.8 提出フォーマット

提出物は、シリアル化されたSimAgentsChallengeSubmissionプロトコルのバッファデータ⁴としてアップロードする必要があります(「プロト」)。投稿内の各シナリオロールアウトプロトには、1つのシナリオからのシミュレーションデータの8秒間のロールアウトが32個含まれていなければならない。検証セットまたはテストセットの提出は、評価サーバーに提出することができる。

Jupyterノートブックチュートリアルに、データセット分割のための投稿生成方法に関する指示と例を追加して提供する。我々は、数万のファイルを持つtar.gzファイルの作成を防ぐために、各バイナリプロトファイル(すなわち、各SimAgentsChallengeSubmissionファイル)に複数のScenarioRolloutを保存することを推奨する。これらのファイルの命名規則については、チュートリアルノートブックを参照してください。提出データは、tar.gzのアーカイブとして圧縮し、単一ファイルとしてアップロードしてください。

³WOMD download instructions available at https://waymo.com/intl/en_us/open/download.

⁴<https://protobuf.dev/>