

DeepFM: CTR予測のための因数分解マシンベースのニューラルネットワーク

Huifeng Guo^{*1}, Ruiming Tang², Yunming Ye^{†1}, Zhenguo Li², Xiuqiang He²¹Shenzhen Graduate School, Harbin Institute of Technology, China²Noah's Ark Research Lab, Huawei, China¹huifengguo@yeah.net, yeyunming@hit.edu.cn²{tangruiming, li.zhenguo, hexiuqiang}@huawei.com

Abstract

推薦システムにおいて、ユーザの行動の背後にある洗練された特徴の相互作用を学習することは、CTRを最大化するために重要である。大きな進歩にもかかわらず、既存の手法は低次または高次の相互作用に強いバイアスを持つか、専門的な特徴工学を必要とするようである。本論文では、低次と高次の特徴相互作用の両方を重視したエンドツーエンドの学習モデルを導出できることを示す。提案モデルDeepFMは、新しいニューラルネットワークアーキテクチャにおいて、推薦のための因数分解マシンと特徴学習のためのディープラーニングの力を組み合わせたものである。Googleの最新のWide & Deepモデルと比較して、DeepFMは「広い」部分と「深い」部分への入力を共有しており、生の特徴以外に特徴エンジニアリングは必要ない。ベンチマークデータと商用データの両方を用いて、CTR予測における既存のモデルに対するDeepFMの有効性と効率性を実証するために、包括的な実験を実施した。

1 Introduction

クリックスルー率(CTR)の予測は推薦システムにおいて重要であり、ユーザが推薦されたアイテムをクリックする確率を推定することが課題である。多くのレコメンダーシステムでは、クリック数を最大化することが目標であり、そのためユーザーに返却されたアイテムは推定CTRによってランク付けすることができる。一方、オンライン広告のような他のアプリケーションシナリオでは、収益を改善することも重要であるため、ランキング戦略はすべての候補にわたってCTR×bidとして調整することができる。いずれの場合も、CTRを正しく推定することが鍵であることは明らかである。

CTR予測では、ユーザーのクリック行動の背後にある暗黙の特徴の相互作用を学習することが重要である。アプリの主流市場における我々の調査では、人々は食事時に食品を提供するアプリをダウンロードすることが多いことがわかり、アプリのカテゴリとタイムスタンプの間の(次数-2)相互作用が示唆された。

^{*}This work is done when Huifeng Guo worked as intern at Noah's Ark Research Lab, Huawei.

[†]Corresponding Author.

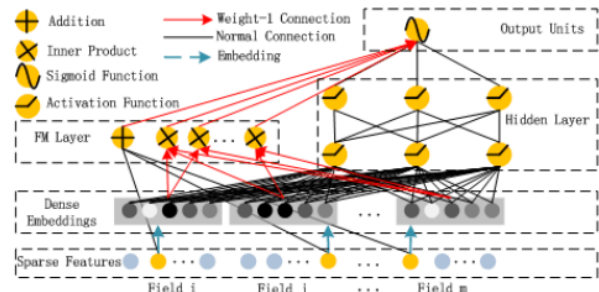


図1: DeepFMのワイド&ディープアーキテクチャ。ワイドコンポーネントとディープコンポーネントは同じ入力生特徴ベクトルを共有することで、DeepFMは入力生特徴から低次特徴と高次特徴の相互作用を同時に学習することができる。

はCTRの信号として使用できる。第二の観察として、男性ティーンエイジャーはシューティングゲームやRPGゲームが好きであり、これはアプリケーション、ユーザーの性別、年齢の(次数-3)相互作用がCTRのもう一つのシグナルであることを意味する。一般に、このようなユーザーのクリック行動の背後にある特徴の相互作用は高度に洗練される可能性があり、低次と高次の両方の特徴の相互作用が重要な役割を果たすはずである。GoogleからのWide & Deepモデル[Cheng et al., 2016]の洞察によると、低次と高次の特徴相互作用を同時に考慮することで、どちらか一方だけを考慮する場合よりもさらに改善される。

重要な課題は、特徴の相互作用を効果的にモデル化することである。特徴的な相互作用の中には、簡単に理解できるものがあり、専門家が設計することができる(上記のインスタンスのように)。しかし、他のほとんどの特徴相互作用はデータに隠されており、先験的に識別することが困難である(例えば、古典的な連想規則「ディアパーとビール」は、専門家によって発見されるのではなく、データから採掘される)。理解しやすいインタラクションであっても、特に特徴量が多い場合、専門家が網羅的にモデル化する可能性は低いと思われる。

FTRL [McMahan et al., 2013]のような一般化線形モデルは、その単純さにもかかわらず、実際に適切な性能を示している。しかし、線形モデルには特徴相互作用を学習する能力がなく、一般的な手法として、特徴ベクトルにペアワイズ特徴相互作用を手動で含めることが挙げられる。このような方法は、高次の特徴相互作用や、学習データに現れない、あるいはほとんど現れない相互作用をモデル化するために一般化することは困難である[Rendle, 2010]。

因数分解マシン(FM)[Rendle, 2010]は、特徴間の潜在ベクトルの内積としてペアワイズ特徴相互作用をモデル化し、非常に有望な結果を示す。原理的にはFMは高次の特徴相互作用をモデル化できるが、実際には複雑性が高いため、通常はorder2の特徴相互作用のみが考慮される。特徴表現を学習する強力なアプローチとして、ディープニューラルネットワークは高度な特徴相互作用を学習する可能性を持っている。CTRの予測のためにCNNとRNNを拡張するアイデアもあるが[Liu et al., 2015; Zhang et al., 2014]、CNNベースのモデルは隣接する特徴間の相互作用に偏り、RNNベースのモデルは逐次依存性を持つクリックデータにより適している。[Zhang et al., 2016]は特徴表現を研究し、因数分解マシンサポートニューラルネットワーク(FNN)を提案している。このモデルはDNNを適用する前にFMを事前学習するため、FMの能力によって制限される。特徴相互作用は[Qu et al., 2016]で研究されており、埋め込み層と完全連結層の間に積層を導入し、積ベースのニューラルネットワーク(PNN)を提案している。Cheng et al., 2016]で述べられているように、PNNとFNNは、他のディープモデルと同様に、CTR予測にも不可欠な低次の特徴相互作用をほとんど捉えない。低次と高次の特徴相互作用の両方をモデル化するために、[Cheng et al., 2016]は、線形(「ワイド」)モデルとディープモデルを組み合わせた興味深いハイブリッドネットワーク構造(Wide & Deep)を提案している。このモデルでは、「ワイドパート」と「ディープパート」にそれぞれ2つの異なる入力が必要であり、「ワイドパート」の入力は依然として専門知識特徴工学に依存している。

既存のモデルは、低次または高次の特徴相互作用に偏っているか、特徴工学に依存していることがわかる。本論文では、生の特徴量以外の特徴量工学を用いず、全ての次数の特徴量相互作用をエンドツーエンドで学習できる学習モデルを導出できることを示す。我々の主な貢献は以下のように要約される：

- FMとディープニューラルネットワーク(DNN)のアーキテクチャを統合した新しいニューラルネットワークモデルDeepFM(図1)を提案する。FMのような低次の特徴相互作用をモデル化し、DNNのような高次の特徴相互作用をモデル化する。広・深層モデル[Cheng et al., 2016]とは異なり、DeepFMは特徴工学なしでエンドツーエンドで学習できる。
- DeepFMは、[Cheng et al., 2016]とは異なり、その広い部分と深い部分が同じ入力と埋め込みベクトルを共有するため、効率的に学習することができる。Cheng et al., 2016]では、入力ベクトルは、その広い部分の入力ベクトルに手動で設計されたペアワイズ特徴相互作用を含むため、巨大なサイズになる可能性があり、これもその複雑さを大幅に増加させる。
- ベンチマークデータと商用データの両方でDeepFMを評価した結果、CTR予測において既存のモデルよりも一貫した改善が見られた。

2 Our Approach

ここで、 χ は通常ユーザーとアイテムのペアを含む m フィールドのデータレコードであり、 $y \in \{0, 1\}$ はユーザーのクリック行動を示す関連ラベルである($y = 1$ はユーザーがアイテムをクリックしたことを意味し、それ以外は $y = 0$)。

χ はカテゴリーフィールド(例:性別、場所)および連続フィールド(例:年齢)を含むことができる。各カテゴリーフィールドはワンホットエンコーディングのベクトルとして表現され、各連続フィールドは値そのもの、または離散化後のワンホットエンコーディングのベクトルとして表現される。ここで、 $x = [x_{field1}, x_{field2}, \dots, x_{fieldj}, \dots, x_{fieldm}]$ は d 次元ベクトルであり、 x_{fieldj} は χ の j 番目の場のベクトル表現である。通常、 x は高次元で非常に疎である。CTR予測のタスクは、ユーザーが与えられたコンテキストで特定のアプリをクリックする確率を推定するため、予測モデル $\hat{y} = \text{CTR model}(x)$ を構築することである。

2.1 DeepFM

低次と高次の特徴相互作用を学習することを目的とする。この目的のために、因数分解マシンベースのニューラルネットワーク(DeepFM)を提案する。図1¹に示すように、DeepFMはFMコンポーネントとディープコンポーネントの2つのコンポーネントから構成され、同じ入力を共有する。特徴 i について、スカラー w_i を用いて次数-1の重要度を重み付けし、潜在ベクトル V_i を用いて他の特徴との相互作用の影響を測定する。 V_i はFM成分で次数2の特徴相互作用をモデル化し、深層成分で高次特徴相互作用をモデル化する。 w_i, V_i , ネットワークパラメータ(以下の $W^{(l)}, b^{(l)}$)を含む全てのパラメータは、結合予測モデルに対して共同で学習される：

$$\hat{y} = \text{sigmoid}(y_{FM} + y_{DNN}), \quad (1)$$

ここで、 $\hat{y} \in (0, 1)$ は予測CTR、 y_{FM} はFM成分の出力、 y_{DNN} は深層成分の出力である。

FM Component




図2: FMのアーキテクチャ

FMコンポーネントは、推薦のための特徴相互作用を学習するために[Rendle, 2010]で提案された因数分解マシンである。FMは、特徴間の線形(次数-1)相互作用の他に、各特徴潜在ベクトルの内積として、ペアワイズ(次数-2)特徴相互作用をモデル化する。

本論文のすべての図において、黒字の「正常な接続」は学習すべき重みとの接続を意味し、「重み-1接続」(赤矢印)はデフォルトで重み1との接続を意味する；「埋め込み」(青破線矢印)は学習すべき潜在ベクトルを意味する；「加算」はすべての入力を足し合わせることを意味する；「内積」と「外積」を含む「積」は、このユニットの出力が2つの入力ベクトルの積であることを意味する；「シグモイド関数」はCTR予測の出力関数として使用される；「活性化関数」はreluとtanhは、信号を非線形に変換するために使用される。

特にデータセットが疎な場合、従来のアプローチよりもはるかに効果的にオーダー2特徴の相互作用を捉えることができる。これまでのアプローチでは、特徴*i*と特徴*j*の相互作用のパラメータは、特徴*i*と特徴*j*の両方が同じデータレコードに現れる場合にのみ学習させることができる。FMでは、潜在ベクトル V_i と V_j の内積で測定される。この柔軟な設計のおかげで、FMは*i*(または*j*)がデータレコードに現れるたびに潜在ベクトル V_i (V_j) を学習することができる。したがって、学習データに現れない、あるいはほとんど現れない特徴相互作用は、FMによってよりよく学習される。

図2が示すように、FMの出力は、加算ユニットと多数の内積ユニットの和である：

$$y_{FM} = \langle w, x \rangle + \sum_{j_1=1}^d \sum_{j_2=j_1+1}^d \langle V_{i_1}, V_{j_2} \rangle x_{j_1} \cdot x_{j_2}, \quad (2)$$

ここで、 $w \in \mathbb{R}^d$ 、 $V_i \in \mathbb{R}^k$ (k は与えられる)²。Addition ユニットの $\langle w, x \rangle$ はオーダー1特徴の重要性を反映し、Inner Product ユニットの $\langle V_i, V_j \rangle$ はオーダー2特徴の相互作用の影響を表す。

Deep Component




図3：DNNのアーキテクチャ

ディープコンポーネントはフィードフォワードニューラルネットワークであり、高次の特徴相互作用を学習するために使用される。図3に示すように、データレコード(ベクトル)がニューラルネットワークに供給される。画像[He et al., 2016]や音声[Boulanger-Lewandowski et al., 2013]のデータを入力とするニューラルネットワークと比較すると、純粋に連続的で密なCTR予測の入力は全く異なっており、新しいネットワークアーキテクチャ設計が必要である。具体的には、CTR予測のための生の特徴入力ベクトルは、通常、非常に疎³、超高次元⁴、カテゴリ-連続-混合、フィールド(性別、場所、年齢など)にグループ化されている。これは、最初の隠れ層にさらに入力する前に、入力ベクトルを低次元の密な実数値ベクトルに圧縮する埋め込み層を示唆している。そうでなければ、ネットワークは訓練に圧倒される可能性がある。

図4は、入力層から埋め込み層までのサブネットワーク構造を強調したものである。このネットワーク構造の2つの興味深い特徴を指摘したい：1)異なる入力フィールドベクトルの長さは異なる可能性がある、

²We omit a constant offset for simplicity.
各フィールドベクトルに対して1つのエントリのみが非ゼロである。

⁴E.g., in an app store of billion users, the one field vector for user ID is already of billion dimensions.




図4：埋め込み層の構造について

2) FMの潜在特徴ベクトル(V)は、ネットワーク重みとしてサーパ化され、学習され、入力フィールドベクトルを埋め込みベクトルに圧縮するために使用される。Zhang et al., 2016]では、 V はFMによって事前に学習され、初期化として使用される。本研究では、[Zhang et al., 2016]のようにFMの潜在特徴ベクトルを用いてネットワークを初期化するのではなく、他のDNNモデルに加えて、FMモデルを全体的な学習アーキテクチャの一部として含める。そのため、FMによる事前学習の必要性を排除し、代わりにエンドツーエンドでネットワーク全体を共同学習する。埋め込み層の出力を次のように表す：

$$a^{(0)} = [e_1, e_2, \dots, e_m], \quad (3)$$

ここで、 e_i は*i*番目のフィールドの埋め込み、 m はフィールドの数である。次に、 $a^{(0)}$ をディープニューラルネットワークに入力し、順方向処理を行う：

$$a^{(l+1)} = \sigma(W^{(l)}a^{(l)} + b^{(l)}), \quad (4)$$

ここで、 l は層の深さ、 σ は活性化関数である。 $a^{(l)}$ 、 $W^{(l)}$ 、 $b^{(l)}$ は1番目の層の出力、モデルの重み、バイアスである。その後、密な実数値特徴ベクトルが生成され、最終的にCTR予測のためのシグモイド関数に供給される： $y_{DNN} = \sigma(W^{(H+1)}a^{(H)} + b^{(H+1)})$ 、ここで H は隠れ層の数である。

FMコンポーネントとディープコンポーネントは同じ特徴埋め込みを共有しており、2つの重要な利点をもたらすことを指摘しておく：1)生の特徴から低次と高次の両方の特徴相互作用を学習する。2)Wide & Deep [Cheng et al., 2016]で要求されるように、入力の専門知識特徴工学は必要ない。

2.2 他のニューラルネットワークとの関係

様々なアプリケーションにおける深層学習の大きな成功に触発され、最近、CTR予測のためのいくつかの深層モデルが開発されている。本節では、提案するDeepFMと既存のCTR予測用ディープモデルとの比較を行う。FNN：図5(左)が示すように、FNNはFM初期化フィードフォワードニューラルネットワークである[Zhang et al.]FMの事前学習戦略には2つの限界がある：1)埋め込みパラメータがFMの影響を受けすぎる可能性がある、2)事前学習段階で導入されるオーバーヘッドによって効率が低下する。また、FNNは高次の特徴的な相互作用のみを捉える。一方、DeepFMは事前学習を必要とせず、高次と低次の特徴相互作用を学習する。PNN：高次の特徴的な相互作用を捉えることを目的とした

ション、PNNは埋め込み層と最初の隠れ層の間に積層を課す[Qu et al., 2016]。異なるタイプの積演算によると、3つのバリエーションがある：IPNN、OPNN、PNN*の3種類があり、IPNNはベクトルの内積、OPNNは外積、PNN*は内積と外積の両方に基づいている。

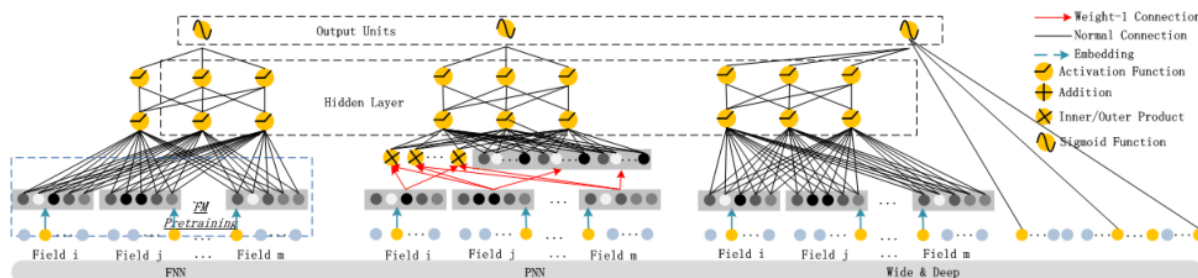


図5:CTR予測のための既存のディープモデルのアーキテクチャ：FNN、PNN、Wide & Deep Model

表1:CTR予測のためのディープモデルの比較

	No Pre-training	High-order Features	Low-order Features	No Feature Engineering
FNN	×	✓	×	✓
PNN	✓	✓	×	✓
Wide & Deep	✓	✓	✓	×
DeepFM	✓	✓	✓	✓

計算をより効率的にするために、著者らは内積と外積の両方の近似計算を提案した：1) 内積はいくつかのニューロンを除去することで近似的に計算される。2) 外積はm個のk次元特徴ベクトルを1個のk次元ベクトルに圧縮することで近似的に計算される。しかし、外積の近似計算では情報があまり失われるため、結果が不安定になり、外積の信頼性が内積よりも低くなることがわかる。内積はより信頼性が高いが、積層の出力が第1隠れ層の全ニューロンに接続されているため、計算量が多くなるという問題がある。PNNとは異なり、DeepFMの積層の出力は最終出力層(1ニューロン)にしか接続されない。FNNと同様に、全てのPNNは低次の特徴相互作用を無視する。

Wide & Deep: Wide & Deep (図5(右))は、低次と高次の特徴相互作用を同時にモデル化するためにGoogleによって提案された。Cheng et al., 2016]に示されているように、「ワイド」な部分への入力に専門知識特微工学が必要である(例えば、アプリ推薦におけるユーザーのインストールアプリとインプレッションアプリのクロスプロダクト)。一方、DeepFMは、入力された生の特徴から直接学習することで、入力を処理するためのそのような専門知識を必要としない。

このモデルの簡単な拡張は、LRをFMに置き換えることである(セクション3でもこの拡張を評価する)。この拡張はDeepFMに似ているが、DeepFMはFMとdeepコンポーネントの間で特徴埋め込みを共有する。特徴埋め込みの共有戦略は、低次と高次の両方の特徴相互作用によって特徴表現に(バックプロパゲータ的に)影響を与え、表現をより正確にモデル化する。

要約: 要約すると、DeepFMと他のディープモデルとの関係を4つの側面から表1に示す。見てわかるように、DeepFMは事前学習と特微工学を必要とせず、低次と高次の両方の特徴相互作用を捉える唯一のモデルである。

3 Experiments

本節では、提案するDeepFMと他の最先端モデルを経験的に比較する。評価結果は、我々の提案するDeepFMが他のどの最先端モデルよりも効果的であり、DeepFMの効率は他のモデルの中で最も良いものと同等であることを示している。

3.1 実験セットアップ

Datasets

提案するDeepFMの有効性と効率性を以下の2つのデータセットで評価する。

1) Criteoデータセット: Criteoデータセット⁵には4500万人のユーザーのクリックレコードが含まれる。13個の連続特徴量と26個のカテゴリ特徴量がある。データセットをランダムに2つに分割する: 90%はトレーニング用、残りの10%はテスト用である。

2) Company* データセット: 実際の産業用CTR予測におけるDeepFMの性能を検証するため、Company*データセットで実験を行った。Company* App Storeのゲームセンターから、連続7日間のユーザーのクリック記録を収集し、トレーニングに使用し、次の1日間のテストに使用する。収集したデータセット全体では、約10億レコードのレコードがある。このデータセットには、アプリの特徴(識別、カテゴリなど)、ユーザーの特徴(ユーザーのダウンロードアプリなど)、コンテキストの特徴(操作時間など)がある。

評価指標

実験では2つの評価指標を使用する: AUC(ROC下面積)とLogloss(クロスエントロピー)である。

モデルの比較

実験では9つのモデルを比較した: LR, FM, FNN, PNN(3つのバリエーション)、Wide & Deep, DeepFM。Wide & Deep モデルでは、特微工学的な労力を省く目的で、LR を FM に置き換えたオリジナルの Wide & Deep モデルもワイド部分として適応させる。WideとDeepの2つの変種を区別するために、それぞれLR&DNN、FM&DNNと名付ける⁶。

Parameter Settings

Criteoデータセットでモデルを評価するために、FNNとPNNについて[Qu et al., 2016]のパラメータ設定に

<http://labs.criteo.com/ダウンロード/2014-kaggle>

Googleが公開しているWide & Deep API⁷は、その実装の効率が非常に低いため使用しない。WideとDeepを、DeepとWideの両方に対して共有オプティマイザで簡略化することで、我々自身で実装する。

従う:(1)ドロップアウト: 0.5; (2) ネットワーク構造: 400-400-400; (3) オプティマイザ: (4)活性化関数:IPNNはtanh、他のディープモデルはrelu。公平を期すため、提案するDeepFMも同じ設定を用いる。LRとFMのオプティマイザはそれぞれFTRLとAdamであり、FMの潜在次元は10である。Company*データセットにおいて、個々のモデルで最高の性能を達成するために、3.3節で説明するパラメータスタディを慎重に実施した。

3.2 性能評価

本節では、3.1節で挙げたモデルを2つのデータセットで評価し、その有効性と効率性を比較する。

効率性の比較

ディープラーニングモデルの効率は、実世界のアプリケーションにとって重要である。Criteoデータセットにおける各モデルの効率を以下の式で比較する: ディープCT Rモデルの学習時間CPU(左)とGPU(右)である。テストを含む、LRの学習時間を示す: 1)FNNの事前学習は効率が悪い、2)GPU上でのIPNNとPNN*の高速化は他のモデルより高いが、内積演算が非効率的であるため、計算コストが高い、3)DeepFMはどちらのテストでもほぼ最も効率的である。




図6: 時間の比較。

有効性の比較

CriteoデータセットとCompany*データセットにおける異なるモデルのCTR予測性能を表2に示すが、以下のような観察結果が得られている:

- 特徴量の相互作用を学習することで、CTR予測モデルの性能が向上する。この観察は、LR(特徴の相互作用を考慮しない唯一のモデルである)が他のモデルよりも性能が悪いという事実によるものである。最良のモデルとして、DeepFMはCompany*とCriteoデータセットにおいて、AUCで0.86%と4.18%(Loglossで1.15%と5.60%)LRを上回った。
- 高次特徴量と低次の特徴量の相互作用を同時に学習することで、CTR予測モデルの性能を適切に向上させることができる。DeepFMは、低次の特徴相互作用のみを学習するモデル(すなわち、FM)や高次の特徴相互作用のみを学習するモデル(すなわち、FNN、IPNN、OPNN、PNN*)を凌駕する。2番目に良いモデルと比較して、DeepFMはCompany*とCriteoデータセットにおいて、AUCで0.37%以上と0.25%以上(Loglossで0.42%と0.29%)を達成した。
- 高次特徴量と低次特徴量の相互作用を同時に学習し、高次特徴量と低次特徴量の相互作用を学習するために同じ特徴量の埋め込みを共有することで、CTR予測モデルの性能が向上する。

DeepFMは、特徴埋め込みを分離して高次と低次の特徴相互作用を学習するモデル(すなわち、LR & DNNとFM & DNN)を凌駕する。これら2つのモデルと比較して、DeepFMはCompany*とCriteoデータセットにおいて、AUCで0.48%以上と0.33%以上(Loglossで0.61%と0.66%)を達成した。

表2: CTR予測のパフォーマンス

	Company*		Criteo	
	AUC	LogLoss	AUC	LogLoss
LR	0.8640	0.02648	0.7686	0.47762
FM	0.8678	0.02633	0.7892	0.46077
FNN	0.8683	0.02629	0.7963	0.45738
IPNN	0.8664	0.02637	0.7972	0.45323
OPNN	0.8658	0.02641	0.7982	0.45256
PNN*	0.8672	0.02636	0.7987	0.45214
LR & DNN	0.8673	0.02634	0.7981	0.46772
FM & DNN	0.8661	0.02640	0.7850	0.45382
DeepFM	0.8715	0.02618	0.8007	0.45083

全体として、我々の提案するDeepFMモデルは、Company*データセットにおいて、AUCで0.37%以上、Loglossで0.42%以上競合に勝っている。実際、オフラインAUC評価のわずかな改善は、オンラインCTRの大幅な増加につながる可能性が高い。Cheng et al., 2016]で報告されているように、LRと比較して、Wide & DeepはAUCを0.275%改善し(オフライン)、オンラインCTRの改善は3.9%である。Company*のApp Storeの1日の売上高は百万ドルであるため、CTRが数パーセント上昇しても毎年数百万ドル余分に増加する。

3.3 ハイパーパラメータの研究

我々は、Company*データセットにおいて、異なるディープモデルの異なるハイパーパラメータの影響を研究する。次式が成り立つ: 1) 活性化関数、2) ドロップアウト率、3) 1層あたりのニューロン数、4) 隠れ層の数、5) ネットワーク形状。

活性化関数

Qu et al., 2016]によると、reluとtanhはシグモイドよりもディープモデルに適している。本論文では、reluとtanhを適用した場合のディープモデルの性能を比較する。図7に示すように、IPNNを除く全てのディープモデルにおいて、tanhよりもreluの方が適切である。考えられる理由は、reluがスパース性を誘導するためである。




図7: 活性化関数のAUCとLoglossの比較。

Dropout

Dropout [Srivastava et al., 2014] は、ニューロンがネットワークに保持される確率を指す。Dropoutは、ニューラルネットワークの精度と複雑さを妥協する正則化手法である。ドロップアウトを1.0、0.9、0.8、0.7、0.6、0.5とした。

図8に示すように、ドロップアウトを適切に設定した場合(0.6から0.9まで)、全てのモデルがそれぞれ最高の性能に到達することができ。この結果は、モデルに妥当なランダム性を加えることで、モデルの頑健性を強化できることを示している。




図8: ドロップアウトのAUCとLoglossの比較。

層あたりのニューロン数

他の要因が同じままの場合、層あたりのニューロン数を増やすと複雑さが生じる。図9からわかるように、ニューロン数を増やしても必ずしも効果が期待できるわけではない。例えば、DeepFMは層あたりのニューロン数を400から800に増やした場合、安定した性能を発揮する。さらに悪いことに、OPNNはニューロン数を400から800に増やした場合、性能が悪くなる。これは、複雑すぎるモデルはオーバーフィットしやすいからである。我々のデータセットでは、1層あたり200ニューロンまたは400ニューロンが良い選択である。




図9: ニューロン数のAUCとLoglossの比較。

隠れレイヤーの数

図10に示すように、隠れ層の数を増やすと、初期にはモデルの性能が向上するが、隠れ層の数が増え続けると性能が低下する。この現象もオーバーフィッティングによるものである。




図 10: 層数の AUC と Logloss の比較。

Network Shape

定、増加、減少、菱形という4つの異なるネットワーク形状をテストする。ネットワーク形状を変更すると、隠れ層の数とニューロンの総数が固定される。例えば、隠れ層の数が3、ニューロンの総数が600の場合、一定(200-200-200)、増加(100-300)、減少(300-200-100)、菱形(150-300-150)の4種類の形状となる。

図11からわかるように、「一定の」ネットワーク形状は、他の3つの選択肢よりも経験的に優れており、これは先行研究[Larochelle et al., 2009]と一致している。




図11: ネットワーク形状のAUCとLoglossの比較。

4 関連研究

本論文では、CTR予測のための新しいディープニューラルネットワークを提案する。最も関連性の高いドメインは、CTR予測と推薦システムにおける深層学習である。このセクションでは、これら2つの領域における関連研究について述べる。

CTR予測は推薦システムにおいて重要な役割を果たす[Richardson et al., 2007; Juan et al., 2016; McMahan et al., 2013]。一般化線形モデルやFMの他に、ツリーベースモデル[He et al., 2014]、テンソルベースモデル[Rendle and Schmidt-Thieme, 2010]、サポートベクターマシン[Chang et al., 2010]、ページアンモデル[Graepel et al., 2010]など、CTR予測のためのモデルがいくつか提案されている。

もう一つの関連領域は、推薦システムにおける深層学習である。セクション1とセクション2.2では、CTR予測のためのいくつかのディープラーニングモデルについて既に述べたので、ここではそれらについて議論しない。CTR予測以外の推薦タスクにおいて、いくつかの深層学習モデルが提案されている(例えば、[Covington et al., 2016; Salakhutdinov et al., 2007; van den Oord et al., 2013; Wu et al., 2016; Zheng et al., 2016; Wu et al., 2017; Zheng et al., 2017])。[Salakhutdinov et al., 2007; Sedhain et al., 2015; Wang et al., 2015]は、深層学習による協調フィルタリングの改善を提案している。Wang and Wang, 2014; van den Oord et al., 2013]の著者らは、音楽推薦のパフォーマンスを向上させるために、ディープラーニングによってコンテンツ特徴を抽出している。[Chen et al., 2016]は、画像特徴とディスプレイ広告の基本特徴の両方を考慮するディープラーニングネットワークを考案している。[Covington et al., 2016]は、YouTube動画推薦のための2段階の深層学習フレームワークを開発している。

5 Conclusions

本論文では、CTR予測のための因数分解マシンベースのニューラルネットワークであるDeepFMを提案し、最先端モデルの欠点を克服し、より良い性能を達成する。DeepFMは、ディープコンポーネントとFMコンポーネントを合同で学習する。これらの利点により、性能向上が期待できる: 1) 事前学習が不要であること、2) 高次と低次の特徴相互作用を学習すること、3) 特徴工学を回避するために特徴埋め込みの共有戦略を導入していること。我々は、DeepFMと最先端モデルの有効性と効率性を比較するために、2つの実世界データセット(Criteoデータセットと市販のApp Storeデータセット)で広範な実験を行った。

我々の実験結果は、1)DeepFMが両データセットにおいて、AUCとLoglossの点で最先端モデルを上回ること、2)DeepFMの効率は、最先端において最も効率的なディープモデルに匹敵すること、を実証している。今後の研究の方向性として、2つの興味深いものがある。最も有用な高次特徴相互作用の学習能力を強化するために、いくつかの戦略(プーリング層の導入など)を模索している。もう一つは、大規模問題に対するGPUクラスタ上でDeepFMを学習させるものである。

References

- [Boulanger-Lewandowski *et al.*, 2013] Nicolas Boulanger-Lewandowski, Yoshua Bengio, and Pascal Vincent. Audio chord recognition with recurrent neural networks. In *ISMIR*, pages 335–340, 2013.
- [Chang *et al.*, 2010] Yin-Wen Chang, Cho-Jui Hsieh, Kai-Wei Chang, Michael Ringgaard, and Chih-Jen Lin. Training and testing low-degree polynomial data mappings via linear SVM. *JMLR*, 11:1471–1490, 2010.
- [Chen *et al.*, 2016] Junxuan Chen, Baigui Sun, Hao Li, Hongtao Lu, and Xian-Sheng Hua. Deep CTR prediction in display advertising. In *MM*, 2016.
- [Cheng *et al.*, 2016] Heng-Tze Cheng, Levent Koc, Jeremiah Harmsen, Tal Shaked, Tushar Chandra, Hrishikesh Aradhye, Glen Anderson, Greg Corrado, Wei Chai, Mustafa Ispir, Rohan Anil, Zakaria Haque, Lichan Hong, Vihan Jain, Xiaobing Liu, and Hemal Shah. Wide & deep learning for recommender systems. *CoRR*, abs/1606.07792, 2016.
- [Covington *et al.*, 2016] Paul Covington, Jay Adams, and Emre Sargin. Deep neural networks for youtube recommendations. In *RecSys*, pages 191–198, 2016.
- [Graepel *et al.*, 2010] Thore Graepel, Joaquin Quiñero Candela, Thomas Borchert, and Ralf Herbrich. Web-scale bayesian click-through rate prediction for sponsored search advertising in microsoft’s bing search engine. In *ICML*, pages 13–20, 2010.
- [He *et al.*, 2014] Xinran He, Junfeng Pan, Ou Jin, Tianbing Xu, Bo Liu, Tao Xu, Yanxin Shi, Antoine Atallah, Ralf Herbrich, Stuart Bowers, and Joaquin Quiñero Candela. Practical lessons from predicting clicks on ads at facebook. In *ADKDD*, pages 5:1–5:9, 2014.
- [He *et al.*, 2016] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, pages 770–778, 2016.
- [Juan *et al.*, 2016] Yu-Chin Juan, Yong Zhuang, Wei-Sheng Chin, and Chih-Jen Lin. Field-aware factorization machines for CTR prediction. In *RecSys*, pages 43–50, 2016.
- [Larochelle *et al.*, 2009] Hugo Larochelle, Yoshua Bengio, Jérôme Louradour, and Pascal Lamblin. Exploring strategies for training deep neural networks. *JMLR*, 10:1–40, 2009.
- [Liu *et al.*, 2015] Qiang Liu, Feng Yu, Shu Wu, and Liang Wang. A convolutional click prediction model. In *CIKM*, 2015.
- [McMahan *et al.*, 2013] H. Brendan McMahan, Gary Holt, David Sculley, Michael Young, Dietmar Ebner, Julian Grady, Lan Nie, Todd Phillips, Eugene Davydov, Daniel Golovin, Sharat Chikkerur, Dan Liu, Martin Wattenberg, Arnar Mar Hrafnkelsson, Tom Boulos, and Jeremy Kubica. Ad click prediction: a view from the trenches. In *KDD*, 2013.
- [Qu *et al.*, 2016] Yanru Qu, Han Cai, Kan Ren, Weinan Zhang, Yong Yu, Ying Wen, and Jun Wang. Product-based neural networks for user response prediction. *CoRR*, abs/1611.00144, 2016.
- [Rendle and Schmidt-Thieme, 2010] Steffen Rendle and Lars Schmidt-Thieme. Pairwise interaction tensor factorization for personalized tag recommendation. In *WSDM*, pages 81–90, 2010.
- [Rendle, 2010] Steffen Rendle. Factorization machines. In *ICDM*, 2010.
- [Richardson *et al.*, 2007] Matthew Richardson, Ewa Dominowska, and Robert Ragno. Predicting clicks: estimating the click-through rate for new ads. In *WWW*, pages 521–530, 2007.
- [Salakhutdinov *et al.*, 2007] Ruslan Salakhutdinov, Andriy Mnih, and Geoffrey E. Hinton. Restricted boltzmann machines for collaborative filtering. In *ICML*, pages 791–798, 2007.
- [Sedhain *et al.*, 2015] Suvash Sedhain, Aditya Krishna Menon, Scott Sanner, and Lexing Xie. Autorec: Autoencoders meet collaborative filtering. In *WWW*, pages 111–112, 2015.
- [Srivastava *et al.*, 2014] Nitish Srivastava, Geoffrey E. Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: a simple way to prevent neural networks from overfitting. *JMLR*, 15(1):1929–1958, 2014.
- [van den Oord *et al.*, 2013] Aäron van den Oord, Sander Dieleman, and Benjamin Schrauwen. Deep content-based music recommendation. In *NIPS*, pages 2643–2651, 2013.
- [Wang and Wang, 2014] Xinxi Wang and Ye Wang. Improving content-based and hybrid music recommendation using deep learning. In *ACM MM*, pages 627–636, 2014.
- [Wang *et al.*, 2015] Hao Wang, Naiyan Wang, and Dit-Yan Yeung. Collaborative deep learning for recommender systems. In *ACM SIGKDD*, pages 1235–1244, 2015.
- [Wu *et al.*, 2016] Yao Wu, Christopher DuBois, Alice X. Zheng, and Martin Ester. Collaborative denoising autoencoders for top-n recommender systems. In *ACM WSDM*, pages 153–162, 2016.
- [Wu *et al.*, 2017] Chao-Yuan Wu, Amr Ahmed, Alex Beutel, Alexander J. Smola, and How Jing. Recurrent recommender networks. In *WSDM*, pages 495–503, 2017.
- [Zhang *et al.*, 2014] Yuyu Zhang, Hanjun Dai, Chang Xu, Jun Feng, Taifeng Wang, Jiang Bian, Bin Wang, and Tie-Yan Liu. Sequential click prediction for sponsored search with recurrent neural networks. In *AAAI*, 2014.

- [Zhang *et al.*, 2016] Weinan Zhang, Tianming Du, and Jun Wang. Deep learning over multi-field categorical data - - A case study on user response prediction. In *ECIR*, 2016.
- [Zheng *et al.*, 2016] Yin Zheng, Yu-Jin Zhang, and Hugo Larochelle. A deep and autoregressive approach for topic modeling of multimodal data. *IEEE Trans. Pattern Anal. Mach. Intell.*, 38(6):1056–1069, 2016.
- [Zheng *et al.*, 2017] Lei Zheng, Vahid Noroozi, and Philip S. Yu. Joint deep modeling of users and items using reviews for recommendation. In *WSDM*, pages 425–434, 2017.