

自律走行のための占有予測ガイド付きニューラルプランナー

Haochen Liu, Zhiyu Huang, and Chen Lv*, *Senior Member, IEEE*

概要 複雑な交通シナリオにおける周囲の交通参加者のスケーラブルな将来状態を予測することは、安全で実現可能な意思決定を可能にするため、自律走行車にとって重要な能力である。学習ベースの予測とプランニングにおける最近の成功は、2つの主要な課題を導入している：環境のための正確な共同予測の生成と、プランニング目的のための予測ガイダンスの統合。これらの課題に対処するために、我々はOPGPと呼ばれる2段階の統合ニューラルプランニングフレームワークを提案する。OPGPは、占有予測からの共同予測ガイダンスを組み込んでいる。予備計画フェーズでは、統一されたTransformer構造の中で、共有された相互作用、シーンコンテキスト、アクターダイナミクスを考慮しながら、模倣学習目標に基づいて、様々なタイプのトラフィックアクターの予測占有率を同時に出力する。その後、変換された占有予測は、Frenet座標の下での安全で滑らかなプランニングにさらに情報を提供するために、最適化を導く。大規模な実走行データセットを用いてプランナーを訓練し、オープンループ構成で検証する。提案するプランナーは、強力な学習ベースの手法を凌駕し、占有予測ガイダンスにより性能が向上する。

I. INTRODUCTION

複数の交通参加者（エージェント）が意思決定モジュールに情報を提供するために、頑健で社会的に適合性のある共同先物を正確に予測することは、自律走行システム（ADS）にとって極めて重要な能力である[1]–[3]。しかし、予測とプランニングを統合することは、いくつかの要因から大きな課題がある。まず、ADSは、社会的に相互作用する異種交通参加者の組み合わせを特徴とする、膨大な数の複雑な交通シーンを処理しなければならない[4]。第二に、運動予測器は、近傍の多数の交通アクターの将来の状態の共同パターンを管理しなければならない[5]。さらに、経路レベルのプランニング決定には、ADSの安全で滑らかなプランニング性能を実行するために、共同予測から実現可能なガイダンスが必要である。

最適な予測ガイダンスを達成するために、予測研究の大部分は、選択された周囲の参加者の将来の位置の共同シーケンスを直接マッピングするマルチエージェント軌跡予測（MATP）に焦点を当てている[6]、[7]。しかし、このアプローチは探索コストによって妨げられ、探索コストは参加者数とともに線形に増加し、限界運動予測では指数関数的に増加する[8]。最近、研究者は占有グリッドの予測に目を向けている[9]。視覚表現として、占有予測は複数の参加者に対してより効率的でスケーラブルな形式を提供する。

Code is available at: <https://github.com/georgeliu233/OPGP>

H. Liu, Z. Huang, and C. Lv are with the School of Mechanical and Aerospace Engineering, Nanyang Technological University, 639798, Singapore. (E-mails: {haochen002, zhiyu001}@e.ntu.edu.sg, lyuchen@ntu.edu.sg)

This work was supported in part by the A*STAR under MTC IRG Grant (No. M22K2c0079) and the SUG-NAP Grant (No. M4082268.050) of Nanyang Technological University, Singapore.

*Corresponding author: C. Lv

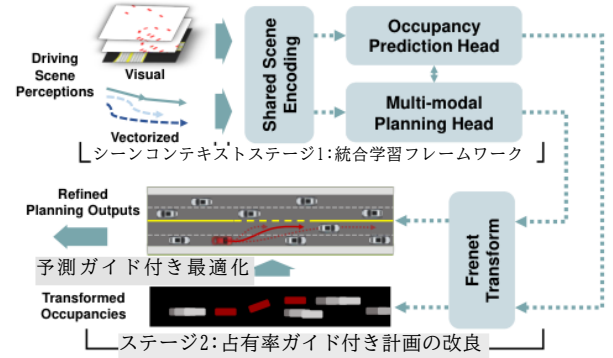


図1. 提案する2段階占有予測誘導型ニューラルプランナー(OPGP)。統合学習ベースのフレームワークから予測される占有率とマルチモーダル計画出力。次に、予測ガイド付き最適化により、変換された予測と計画から計画を洗練させる。

さらに、様々な参加者の共同将来を一目で予測することができ[10]、計画決定を統合する際にMATPと比較してオクルージョン予測可能性の安全性が向上する。しかし、共同占有率予測の文脈で、すべての対話的アクターの社会的認識を捉えることは、依然として未解決の問題である。

逆に、学習ベースのモーションプランニングは、ますます注目されている[11]。統一されたニューラルネットワークを使用することで、多様な運転シナリオに対応できる素晴らしい結果を達成した。それにもかかわらず、学習ベースの計画の頑健性と安全性は不安定性によって損なわれる可能性がある。この問題に対処するために、予測ガイダンスを統合することが、この学習構造の標準的なアプローチとして浮上している[12]–[14]。隣接する予測に基づいて能動的な応答と運動制約を学習することで、より安全で、よりロバストで、社会的に適合した計画システムが期待される[15]。一般的な方法の1つは、周囲のアクターの将来の軌跡を計画に利用することで予測を統合することである[16]、[17]。関節軌道のモデル化にMATPを使用することは困難であるにもかかわらず、予測ガイダンスのソースとして占有率を探索した研究は限られている。共同将来占有率の予測は、計画のためのニューラルネットワーク内に視覚ベースの予測特徴を統合する際に、かなりの課題を提示する。さらに、情報量の多い予測占有率を実現可能な計画結果に変換することは、さらなる調査が必要な課題である。

これらの課題に取り組むために、図1に示すように、将来の占有率と運動計画のための共同予測と予測ガイダンスを統合する2段階学習ベースのフレームワーク（OPGPと命名）を提案する。第一段階では、Transformerのバックボーン上に、占有予測ガイド付きプランニングの統合ネットワークが確立される。我々の以前の研究[18]に基づき、すべてのタイプのトラフィック参加者の占有予測は同時に出力される、

視覚的特徴とベクトル化されたコンテキストの両方に対する相互作用の認識を考慮する。一方、エンコードされたシーン特徴と占有率はプランナヘッドで共有され、条件付きで問い合わせられ、ADSの軌道に対してマルチモーダルな運動計画を行う。第2段階は、最適化可能な方法で、モーションプランニングの洗練のための占有予測からの明示的なガイダンスをモデル化することに焦点を当てる。より具体的には、Frenet空間[19]において、変換された占有予測を用いた計画洗練のための最適化パイプラインを構築する。我々の提案するフレームワークの貢献は以下のようにまとめられる：

- 1) 2段階の占有予測ガイド付きニューラルプランナパイプラインを提案する。第一段階は、統合された占有予測ガイド付き運動計画フレームワークを含む。予測された占有率は、交通参加者間の社会的相互作用とシーンコンテキストを考慮した、Transformerベースの構造におけるマルチモーダルな計画軌道と組み合わせられる。
- 2) 第2段階では、計画性能をさらに向上させるために、計画洗練のための変換された占有予測ガイド付き最適化を設計する。
- 3) 大規模な実走行データセットを用いて2段階のフレームワークを検証し、提案するパイプラインは説得力のある性能を達成する。

II. RELATED WORK

A. 関節運動予測

関節運動予測のための学習ベースの技術が開発されつつあり、非常に効果的であることが証明されている[1]。これは、ディープニューラルネットワーク、特にTransformersとGNN[20]が、複数の相互作用する参加者と多様なシーンコンテキストを含む複雑なトラフィックシナリオを処理する能力に起因する。エージェント中心の手法は、検出された各交通参加者に固定されたマルチエージェント単位の未来軌道(MATP)を予測する。DenseTNT [6]、M2I [21]、HEAT [22]は、GNNバックボーンを持つ各アクターについて、マージナルな組み合わせで共同予測をスコアリングする。各アクターに対して精度を示す一方で、時折矛盾が生じる計算コストも高くなる。ジョイント法[23]、[24]は、ヒートマップのスコアリングやサンプリングから、すべてのアクターの将来の分布を直接推定する。しかし、これらの方法は、最大数の予測を必要とし、特に混雑した都市部では、複数のエージェントで線形的なコスト増加を持つ。将来の運動を予測するための占有グリッドの使用は、自律走行で数年前から採用されている技術である。注目すべき例として、ChauffeurNet [25]があり、これは占有マップを利用して将来の動きを予測し、行動計画を容易にする。StopNet[10]はさらに、スケーラブルでリアルタイムな予測のために、統合された軌跡と占有予測を行う。我々の以前の手法[18]に基づき、予測学習時に学習フレームワークに計画情報を組み込む。我々は、すべてのタイプの交通参加者を含むように、占有予測パイプラインを改良し、シーンコンテキスト内でのそれらの相互作用を考慮し、プランニングをガイドするための強化を行った。

B. 予測ガイダンスによる動作計画

モーションプランニングは、時代とともに広範な研究が行われてきた、確立された分野である。経路最適化[26]、サンプリング[27]、そして最近では学習ベースの技術[11]、[28]など、様々なアプローチによって発展してきた。しかし、インタラクティブで洗練された交通で安全に巡航するためには、参加者の行動の予測状態からさらにガイダンスが必要である。PiP[29]は、サンプリングに基づく計画再スケジューリングを繰り返し条件付き予測を行うが、これは限界的な未来のみを考慮し、生成された計画経路によって制限される。DIPP [16]は、微分可能な計画目標を共同軌道予測と結びつけ、応答的な計画を可能にする。これまでの手法では、エージェント中心の方法で予測ガイダンスに焦点を当てていたが、我々は、成長するアクターに対するスケーラビリティと不変性の観点から、シーン中心のガイダンスを追求する。Prediction Net[30]は、プランニングと制御のための後処理された軌跡を持つ占有予測ガイダンスを示す。しかし、交通シミュレーションのための占有率予測に重点を置いており、特に計画のための統合を設計していない。MP3[31]やInterfuser[32]のようなエンドツーエンドの手法は、生の視覚入力から予測と計画を直接マッピングする。とはいえ、彼らは知覚部分を予測に統一することに重点を置いており、計画出力は単に広範な軌跡記憶から取り出されるだけである。我々の研究では、提案するニューラルプランナの両段階を導くために、占有率予測を活用する。具体的には、予測特徴は学習ベースの計画デコーダによって対話的に照会され、その結果得られた予測は実行可能な方法で計画を洗練するために利用される。

III. METHODOLOGY

A. 問題の定式化

図1に示すように、占有予測ガイド付きニューラルプランナは2つのステージから構成される。第一段階では、占有予測ガイダンスを用いた運動計画決定は、マルチタスク学習パラダイムとして定式化することができる。シーンコンテキスト S を入力として、統合学習フレームワーク f は、占有予測 $0^*1:T$ と、将来の水平線 T におけるマルチモーダル模倣計画軌道 $Y^{el}1:T$ を同時に出力する。その後、第2段階は、予測と計画の両方にFrenet変換[19]を利用し、洗練された計画出力 τ^* を生成し、定義されたコスト C を最小化する、達成可能な予測ガイド付き最適化を達成する：

$$\begin{aligned} \hat{Y}_{1:T}^e, \hat{O}_{1:T} &= f(S|\theta), \\ \tau^* &= \arg \min_{\tau} C(\hat{Y}_{1:T}^T, \hat{O}_{1:T}^T, S), \end{aligned} \quad (1)$$

ここで、 θ はモデルパラメータを表す。より具体的には、入力シーンコンテキスト S は、履歴地平 T_h の下で複数のモダリティから構成され、詳細な定式化は以下の通りである：1) 視覚的特徴：特定のシナリオの下での交通参加者の空間的・時間的狀態を表す、履歴占有グリッド $0_{T_h:0}$ とラスタライズされたBEVロードマップ M [33]から組み合わせを構築する。




図2. OPGPにおける占有予測・計画学習統合フレームワークの概要。エンコードされたシーン特徴は、すべてのタイプの占有予測 $\hat{O}_{1:T}$ に対する占有予測ヘッドと、後続ステージの初期計画出力 $\hat{y}_{1:T}^e$ に対するマルチモーダル計画ヘッドによって分配される。

各占有率 O_t は3種類の交通参加者(車両、歩行者、自転車)を個別に含み、さらに現在未見のアクターに対する予測 $\hat{O}_{1:T}$ のためのオクルージョン次元を追加する。2) ベクトル特徴: ベクトル化されたコンテキストは、まず、自律走行車 $X_{-T_h:0} = X_{-T_h:0}^{ego}$, $X_{-T_h:0}^1, \dots, X_{-T_h:0}^n$ を中心とする最大 $n_x + 1$ 人のアクターからの動的コンテキストに関係し、それぞれが過去の運動シーケンスを表す: (x, y, v_x, v_y, θ) 。ワンホットエンコーディングはそれぞれのタイプに関連する。自律走行車(エゴ)の地図コンテキストを提供するために、 m 個のウェイポイント W_m と参照ルート l を含むLanelets[34]のグラフ検索を使用して地図データを収集する。各地図セグメントには、座標情報だけでなく、道路タイプ、制限速度、近くの信号機の現在の状態などの道路特徴も含まれる。

B. 統合予測・計画フレームワーク

図2は、我々の学習ベースのフレームワークの全体構造を示しており、占有予測とプランニングを統合し、3つのモジュールから構成されている。まず、マルチモーダルなシーン入力 S に対して、我々の先行研究の別符号化を採用する。エンコードされた視覚特徴量とベクトル特徴量は、その後、占有予測ヘッドとプランナーヘッドに配信される。占有ヘッドについては、以前の集約と復号のパイプラインを維持し、エンコードされたベクトルと視覚的特徴の後期融合を行う。予測ヘッドは最終的に、未来の地平線の各秒について、すべてのタイプの占有予測 $\hat{O}_{1:T}$ を出力する。マルチモーダル計画ヘッドについては、Transformerデコーダのパラダイムに従い、マルチモーダル経路計画 $\hat{y}_{1:T}^e$ に対して単層復号ヘッドを採用する。

より具体的には、最初に k 個の計画アンカー K_1, \dots, K_k のセットを導入し、計画ヘッドの k 個のモードをガイドする。各アンカー K は、静的な終点クラスター、計画解釈を発見的に導く学習可能な埋め込みのための動的な終点クラスターのどちらかである。これらのアンカーは、自己アテンション後に符号化された視覚的特徴とベクトル特徴に対するコンテキストクエリ Q として機能する。

マルチヘッドクロスアテンションモジュール(MHCA)では、エゴ車両の視覚的コンテキスト、ベクトル化されたダイナミクス、シーントポロジーから、インタラクションを考慮した特徴を適応的に得ることを目的とする。これは、連結された注意ヘッドを考慮すると、パディングされた視覚的特徴の長さが注意スコアリングを疎にするためである。その後のフィードフォワードネットワーク(FFN)の後、各モードは計画経路 $\hat{y}_{1:T}^k$ とそれに対応する模倣尤度の確率 p_k の出力にデコードする。

我々は、第一段階の学習フレームワークをマルチタスク学習パラダイムとして定式化し、大規模データセットを用いて目的をオフラインで共同更新する。占有予測では、各グリッドセルがある将来の地平線の下で占有確率を予測するため、アクターのタイプごとに占有サンプルのバランスをとるためにフォーカルロス[35]を採用する:

$$\mathcal{L}_{pred} = \frac{1}{HWTU} \sum_{x,y,t,u}^{H,W,T,U} \text{FL}(\hat{O}_t^u(x,y), O_t^u(x,y)), \quad (2)$$

ここで、 H, W は占有スケール、 U はアクタータイプを表す。マルチモーダル計画では、模倣は

学習目標は以下のように更新される：

$$\mathcal{L}_{plan} = \arg \min_k \frac{1}{T} \sum_t \text{SL}_1(\hat{y}_t^k - y_t^k) - p_k \log \hat{p}_k, \quad (3)$$

ここで、 SL_1 は滑らかなL1損失を表し、グランドトゥールズまでの距離が最小となる計画モードは、初期計画経路 $\hat{Y}_{1:T}^e$ に対して更新される。

C. 予測ガイド付き計画の改良

シーン交通参加者の占有予測 $\hat{0}_{1:T}$ とマルチモーダル初期計画結果 $\hat{Y}_{1:T}^e$ が与えられると、OPGPの第2ステージは、計画洗練のための予測ガイドパイプラインを構築する。まず、本節では、予測と計画の両方にFrenet [19]座標を用いた変換パラダイムを設計する。次に、変換された占有予測によって導かれる計画最適化を導入する。

変換：我々は、Frenet座標を変換ターゲットに活用する。これは、最適化計画の難しさを緩和するためである。生成された参照経路 l を仮定すると、各参照点 $r \in l$ は接線ベクトルと法線ベクトルによって曲線フレームで動的に割り当てられる： $[\tilde{t}_r, \tilde{n}_r]$ 。そして、現在の直交座標 $\tilde{y} = (x, y)$ は、次の関係に従って、変換 $F: \tilde{y} \rightarrow \tilde{r}$ を通してFrenet $\tilde{r} = (s, d)$ に変換することができる。

$$\tilde{y}(s(t), d(t)) = \tilde{r}(s(t)) + d(t)\tilde{n}_r(s(t)). \quad (4)$$

初期計画結果 $\hat{Y}_{1:T}^e$ に対して、まずトップスコア軌道 $\hat{Y}_{1:T}^e = \arg \max_{pk} \hat{Y}_{1:T}^k$ を選択し、 $\hat{Y}_{1:T}^T = F(\hat{Y}_{1:T}^e)$ で変換する。予測された占有率 $\hat{0}_{1:T}$ に対して、我々の目的は、 l を中心とした占有率予測をフィルタリングし、Frenetフレーム下の占有率にストレッチすることである。この変換は、スケラブルな占有率の探索空間を、オクルージョンのない計画に焦点を当てる。さらに、Frenet変換された占有率は、計画最適化のための凸性を緩和する。より具体的には、Frenetフレーム上の定義済みメッシュグリッドインデックスが与えられる： $l_{sd}, s \in [0, S]; d \in [-\frac{D}{2}, \frac{D}{2}]$ 、この手続きは、まずFrenetから F^{-1} だけデカルトフレームに逆変換する。次に、直交格子から占有格子への関係に従って、画素 (w, h) を P とする：

$$(w, h) = \text{int}(\frac{1}{n}(x - x_0^e, y - y_0^e)), \quad (5)$$

ここで、 int は丸め関数、 n はメートルあたりの画素数を表す。変換された占有予測 $\hat{0}_{1:T}^T$ は、次式で集められる：

$$\begin{aligned} \hat{\mathbf{0}}_{1:T}^T(s, d) &= \hat{\mathbf{0}}_{1:T}(\mathbf{I}_w, \mathbf{I}_h), \\ [\mathbf{I}_w; \mathbf{I}_h] &= \mathcal{P}(\mathcal{F}^{-1}(\mathbf{I}_{sd})). \end{aligned} \quad (6)$$

OPGPパイプラインでは、出力変換された計画 $\hat{Y}_{1:T}^T$ は、計画洗練のために $\hat{0}_{1:T}^T$ からの予測のガイダンスで最適化される。

最適化：計画結果の安全性と運動性能を向上させるために、ここでは有限ホライズン下でのオープンループ最適化問題を定式化する。最適化は、変換された占有予測 $\hat{0}_{1:T}^T$ によって導かれるコスト

関数集合 \mathcal{C} を最小化する最適なシーケンス $\tau^* = \{\tau_1, \dots, \tau_T\}$ を探索する。より具体的には、 \mathcal{C} はコスト関数 c_i の集合の重み付き ω_i 二乗和である：

$$\begin{aligned} \tau^* &= \arg \min_{\tau} C(\tau, \hat{\mathbf{0}}_{1:T}^T, \mathcal{S}), \\ C &= \sum_i \|\omega_i c_i(\tau^i, \hat{\mathbf{0}}_{1:T}^T, \mathcal{S})\|^2, \tau^i \subseteq \tau. \end{aligned} \quad (7)$$

コスト関数集合 \mathcal{C} は、運転進捗、運転快適性、ルールの遵守、そして最も重要な運転安全性など、様々な計画性能を考慮した慎重に設計された重み ω_i を持つ様々なコスト項 c_i を包含する。コストセットは以下のように明示的にカタログ化されている：

1) 運転の進捗：効率的な運転を促進するために、制限速度 v_{limit}^s 以内の縦方向の速度コストを一定に保ち、より多くのオンロードの進捗を可能にする：

$$\mathbf{c}_t^{\text{progress}} = \dot{s}_t - v_{limit}^s. \quad (8)$$

2) 走行の快適性：計画の快適性と運転の滑らかさを促進するために、加速度とジャークの最小化を導入する：

$$\mathbf{c}_t^{\text{comfort}} = \ddot{s}_t + \ddot{d}_t + \ddot{s}_t. \quad (9)$$

3) ルールの遵守：設計されたADSは交通ルールに適合し、基準車線内に留まることが期待される。そこで、 (s, d) の最大マージン目標に基づくオフルートコストと信号機コストをそれぞれ提案する：

$$\mathbf{c}_t^{\text{route}} = d_t. \quad (10)$$

$$\mathbf{c}_t^{\text{tl}} = \begin{cases} \mathbf{1}(s_{\text{red}})(s_t - s_{\text{red}}), & s_t > s_{\text{red}}, \\ 0, & \text{otherwise.} \end{cases} \quad (11)$$

赤47、予測ガイド付き安全性と計画精緻化のための運転安全性を高めるために、安全な運転のための動的障害物として、変換された占有予測 $\hat{0}_{1:T}^T$ のガイダンスを活用する。占有率予測は、アクタータイプによって重み付けされた潜在的な衝突コストとみなされる：

$$\mathbf{c}_t^{\text{ogm}}(s, d) = \sum_u \lambda_u \hat{\mathbf{0}}_t^{\text{T}u}(s, d), \quad (12)$$

フレーム間の占有率が保たれているという問題から、占有率の予測されるアクターは、長い尾を引いて拡大する可能性がある。ADSの過保守運転につながる可能性がある。そこで、閾値以上の確信衝突コストに対して、確信安全距離 s_t^{safe} を設計する：

$$s_t^{\text{safe}} = \min_s \left(\sum_d^D \mathbf{c}_t^{\text{ogm}}(s, d) > \epsilon \right), \quad (13)$$

最適化を簡単にするため、計画精密化のための縦断的なガイダンスのみを行う。前方符号距離を考慮すると

$$\text{sgnd}(s_t) = (s_t - \mathbf{I}_s)\mathbf{1}(s_t > \mathbf{I}_s), \quad (14)$$

予測ガイド付き安全コストは、符号距離が s_t^{safe} を超える場合の加重予測衝突コスト和としてモデル化される：

$$\mathbf{c}_t^{safe} = \sum_s \sum_d \text{sgnd}(s_t) \mathbf{c}_t^{\text{ogm}}(s, d) \mathbf{1}(s > s_t^{safe}). \quad (15)$$

この非線形最適化問題を解くには、式(4)のようになる。7. $\mathbf{Y}_{1:T}^T$ を初期値として計画変数 τ を繰り返し精緻化するガウス・ニュートン法[37]を採用する。

IV. 実験

A. 実験セットアップ

我々はWaymo Open Motion Dataset (WOMD) [38]を利用する。WOMDは50万以上のサンプルを含み、実世界の幅広い運転シナリオをカバーしている。車両、自転車、歩行者など、様々なタイプの交通エージェント間の複雑な相互作用とダイナミクスを捉えることができる。第1段階でのシーンコンテキスト S を入力として、各アクターの履歴状態を過去1秒間10Hzでサンプリングし($T_h = 10$)、予測と計画の目的は将来5秒間で予測に1Hz、計画に10Hzである($T = 50$)。入出力のBEV画像解像度は $H, W = 128$ で、実世界では $n = 1.6$ ピクセル/mをレンダリングする。隠れ次元を96とする。ベクトル入力の場合、AVまでの平均距離でソートされた最大 $n_x = 31$ の周囲アクターを維持する。標準的な尺度に従い、マルチモーダル計画復号化におけるアンカー $k = 6$ を設定する。OPGPの第2ステージでは、参照ルート l は0.1mごとに滑らかに交差し、変換された占有予測 0^{\sim}_t のサイズは $S = 1000$, $D = 20$ である。計画のために、記録された20秒間のWOMDをランダムに分割し、トレーニング用に297,669サンプル、検証とテスト用に関心のあるシナリオを選択した(各47,728)。メトリクス OPGPの性能を総合的に評価するため、占有率予測には、チャレンジ[9]で提案された標準的なメトリクスを採用した。予測指標には $0^{\sim}_{1:T}$ のAUCと $s\text{IOU}$ が含まれる。計画指標としては、人間らしさ、運動能力、テスト中の安全性に関する運転性能に注目する。

ベースライン OPGPフレームワークの予測性能と計画性能を検証するために、いくつかの強力なベースラインと比較する。1) 占有予測のために、プランニングヘッドを持たないバニラSTrajNet [18]と、Swin Transformerボトルネック[39]を用いた簡略化された集約とエンコーディングを持つ改良されたベースライン予測器であるVectorFlow-SwinTを提供する。2) オープンループ計画については、OPGPの第1段のみであるVanilla ILや、OPGPのボトルネックで考案したDIM[36]と比較する。これらのベースラインは、OPGPで提案されたモジュールをいくつか用いないアブレーション手法としても機能する。

B. 実装の詳細

GELU活性化関数を選択し、オーバーフィッティングの問題を軽減するために、各層の後に0.1のドロップアウト率を適用する。

データ量が多いため、4つのNVIDIA A100 GPUで分散戦略を採用し、総バッチサイズは64である。AdamWオプティマイザを初期学習率 $1e-4$ で使用し、コサインアニーリング学習率戦略を採用した。学習エポックの総数を30とする。

C. 定量的結果

1) 予測性能 OPGPのテスト性能を他の強力なベースラインと比較して報告する。表IIに示すように、占有予測タスクのために特別に設計されたバニラSTrajNetと比較すると、OPGPの予測性能はわずかに低下している。これは、OPGPが予測ヘッドと計画ヘッドの両方を持つマルチタスク学習パイプラインであるためである。さらに重要なことは、現在の設計では、予測から計画への特徴ガイダンスのみを考慮していることである。その結果、マルチモーダル計画の学習目的は、占有率予測のためのデコーディングヘッドへの更なる貢献が必要となる。

2) 計画性能：オープンループ計画テストを実施する。表Iに示すように、OPGPの第1段を採用したVanilla ILは、最も低い計画誤差を達成し、 k 個のアンカーを用いたマルチモーダル構成の性能向上を実証している。一方、DIMの模倣計画のためのユニモーダルガウシアンは、複雑なシナリオの不確実性を解決できない。提案するOPGPは、ILと比較して安全性を高めながら、低い計画誤差をもたらす。第2ステージの占有率予測ガイド付き最適化により、衝突率とオフルート率は大幅に改善される。よく設計されたコスト関数は、モーションメトリクスのジャークを減少させることで、運転の快適性を促進する。

D. Qualitative Results

OPGPの有効性をより深く理解するために、まず、占有率予測の可視化を採用し、テスト中の複数の代表的な運転シナリオにおける性能を評価する。図3に示すように、提案手法は、観測されたアクター(a, c, d)と高オクルージョンリスクシナリオ(a, c)の両方を効果的に処理する。予測精度は車両に対してよく維持されているが、現在の手法では、より小さなアクター(b, d)に対してのみ3sの予測性能を確保することができる。計画のための予測誘導能力を実証するために、計画結果と対応する変換された占有予測を表示する。

図4に示すように、シアン色で表示されたプランニングは、予測された歩行者の接近により、AV(赤)を停止させる。さらに、赤い点線円で示すように、OPGPにおける占有率予測は、エージェント単位の手法では見逃されるような未検出のアクターを予測することができる。

E. 限界と今後の課題

現在の2段階OPGPは有望な結果を示しているが、さらなる改善が必要なトピックもいくつかある。最初の問題は、マルチタスク学習における占有予測性能のわずかな低下である。ネットワーク設計から学習スキームへの共同インタラクションが必要である。

TABLE I

(WAYMOモーションデータセットにおけるベンチマークテスト結果)

Models	Safety (%)			Motion (ms^{-2} , ms^{-3})			Planning errors (m)		
	Collisions	Off route	Red light	Jerk	Acc.	Lat.Acc.	1s	3s	5s
Vanilla-IL	7.575	2.76	1.671	4.323	0.676	0.129	0.195	1.076	2.759
DIM-OPGP [36]	9.275	14.27	3.246	7.226	0.977	0.252	0.407	1.865	4.473
Vanilla-Test	-	-	-	4.02	0.692	0.167	-	-	-
OPGP	3.018	1.809	0.501	3.869	0.551	0.156	0.226	1.21	3.184

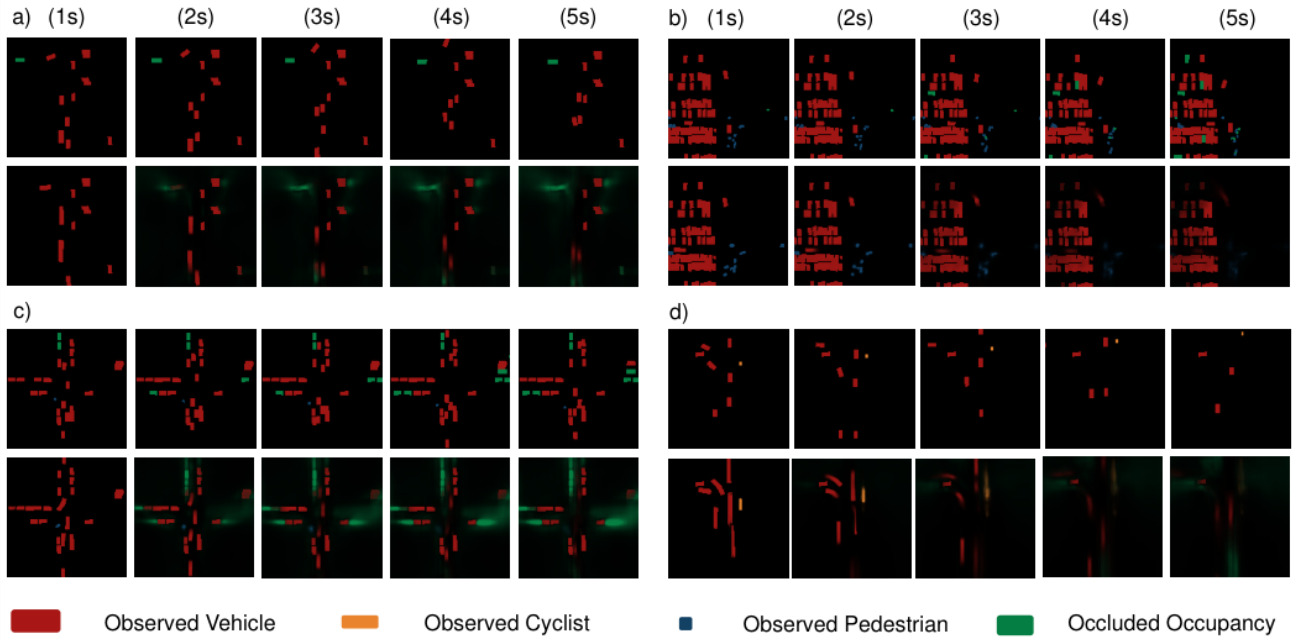


図3. テストセットからの占有率予測の定性的結果。この図には、a)合流を伴うT字路、b)多数の歩行者がいる駐車場、c)閉塞した交差点、d)隣接する自転車とのフォークロード、とい ったいくつかの運転シナリオが示されている。

TABLE II

T占有率予測に関するテスト結果

Models	Vec-AUC	Vec-sIOU	Occ-AUC	Occ-sIOU
STrajNet [18]	0.856	0.696	0.146	0.023
VectorFlow [39]	0.813	0.656	0.112	0.017
OPGP	0.854	0.679	0.128	0.02




図4. ガイダンスに対応する変換された占有率予測による洗練された計画結果の例。歩行者に接近したため、AV(赤)が停止する。赤い点で囲まれた予測結果は、エージェント中心の手法における未検出のアクターを指す。

を予測・計画に利用する。また、手作業による重み付けや保守的な予測ガイダンスのチューニングにコストがかかるため、手動で安全距離を定義する必要がある。占有率予測は、難解なピクセルを除去するための追加ガイダンスを必要とする。

今後の課題としては、OPGPパイプラインに基づくネットワーク構造の改善により、これらの問題を解決することである。

V. CONCLUSIONS

本論文では、予測ガイダンスによって学習ベースのプランニングを共同で改良する2段階の占有予測誘導型ニューラルプランナー(OPGP)を紹介する。我々は、包括的な占有予測とマルチモーダルな計画目標のために設計された、Transformerバックボーンを持つ統合学習ベースのフレームワークを開発する。予測と計画のための第一段階の出力に続いて、曲線フレーム上に構築された変換された占有ガイド付き最適化は、手作りのコスト関数設計の使用を通じて、直接的な計画の洗練を達成する。予測性能と計画性能は、大規模な実世界データセット(WOMD)を用いて広範囲に検証されている。バニラの強力な予測ベースラインと比較して、ロバストな性能を示すプランニング結果は、安全性と運転の滑らかさの向上を示している。さらに、定性的な結果は、変換された占有予測ガイダンスの有効性を立証し、エージェント単位の方法と比較して、検出されず、隠蔽されたアクターを扱う際のスケラビリティの向上を明らかにする。

REFERENCES

- [1] S. Mozaffari, O. Y. Al-Jarrah, M. Dianati, P. Jennings, and A. Mouzakitis, "Deep learning-based vehicle behavior prediction for autonomous driving applications: A review," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 1, pp. 33–47, 2020.
- [2] L. Chen, Y. Li, C. Huang, B. Li, Y. Xing, D. Tian, L. Li, Z. Hu, X. Na, Z. Li *et al.*, "Milestones in autonomous driving and intelligent vehicles: Survey of surveys," *IEEE Transactions on Intelligent Vehicles*, 2022.
- [3] C. Badue, R. Guidolini, R. V. Carneiro, P. Azevedo, V. B. Cardoso, A. Forechi, L. Jesus, R. Berriel, T. M. Paixao, F. Mutz *et al.*, "Self-driving cars: A survey," *Expert Systems with Applications*, vol. 165, p. 113816, 2021.
- [4] W. Wang, L. Wang, C. Zhang, C. Liu, L. Sun *et al.*, "Social interactions for autonomous driving: A review and perspectives," *Foundations and Trends® in Robotics*, vol. 10, no. 3-4, pp. 198–376, 2022.
- [5] X. Mo, Y. Xing, and C. Lv, "Interaction-aware trajectory prediction of connected vehicles using cnn-lstm networks," in *IECON 2020 The 46th Annual Conference of the IEEE Industrial Electronics Society*. IEEE, 2020, pp. 5057–5062.
- [6] J. Gu, C. Sun, and H. Zhao, "Densetnt: End-to-end trajectory prediction from dense goal sets," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 15 303–15 312.
- [7] T. Salzmann, B. Ivanovic, P. Chakravarty, and M. Pavone, "Trajectron++: Dynamically-feasible trajectory forecasting with heterogeneous data," in *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XVIII 16*. Springer, 2020, pp. 683–700.
- [8] Z. Huang, H. Liu, and C. Lv, "Gameformer: Game-theoretic modeling and learning of transformer-based interactive prediction and planning for autonomous driving," *arXiv preprint arXiv:2303.05760*, 2023.
- [9] R. Mahjourian, J. Kim, Y. Chai, M. Tan, B. Sapp, and D. Anguelov, "Occupancy flow fields for motion forecasting in autonomous driving," *IEEE Robotics and Automation Letters*, vol. 7, no. 2, pp. 5639–5646, 2022.
- [10] J. Kim, R. Mahjourian, S. Ettinger, M. Bansal, B. White, B. Sapp, and D. Anguelov, "Stopnet: Scalable trajectory and occupancy prediction for urban autonomous driving," *arXiv preprint arXiv:2206.00991*, 2022.
- [11] H. Zhou, J. Laval, A. Zhou, Y. Wang, W. Wu, Z. Qing, and S. Peeta, "Review of learning-based longitudinal motion planning for autonomous vehicles: research gaps between self-driving and traffic congestion," *Transportation research record*, vol. 2676, no. 1, pp. 324–341, 2022.
- [12] S. Aradi, "Survey of deep reinforcement learning for motion planning of autonomous vehicles," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 2, pp. 740–759, 2020.
- [13] H. Liu, Z. Huang, X. Mo, and C. Lv, "Augmenting reinforcement learning with transformer-based scene representation learning for decision-making of autonomous driving," *arXiv preprint arXiv:2208.12263*, 2022.
- [14] J. Ngiam, B. Caine, V. Vasudevan, Z. Zhang, H.-T. L. Chiang, J. Ling, R. Roelofs, A. Bewley, C. Liu, A. Venugopal *et al.*, "Scene transformer: A unified architecture for predicting multiple agent trajectories," *arXiv preprint arXiv:2106.08417*, 2021.
- [15] J. L. V. Espinoza, A. Liniger, W. Schwarting, D. Russ, and L. Van Gool, "Deep interactive motion prediction and planning: Playing games with motion prediction models," in *Learning for Dynamics and Control Conference*. PMLR, 2022, pp. 1006–1019.
- [16] Z. Huang, H. Liu, J. Wu, and C. Lv, "Differentiable integrated motion prediction and planning with learnable cost function for autonomous driving," *arXiv preprint arXiv:2207.10422*, 2022.
- [17] A. Cui, S. Casas, A. Sadat, R. Liao, and R. Urtasun, "Lookout: Diverse multi-future prediction and planning for self-driving," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 16 107–16 116.
- [18] H. Liu, Z. Huang, and C. Lv, "Strajnet: Occupancy flow prediction via multi-modal swin transformer," *arXiv preprint arXiv:2208.00394*, 2022.
- [19] M. Werling, J. Ziegler, S. Kammel, and S. Thrun, "Optimal trajectory generation for dynamic street scenarios in a frenet frame," in *2010 IEEE International Conference on Robotics and Automation*. IEEE, 2010, pp. 987–993.
- [20] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Lio, and Y. Bengio, "Graph attention networks," *arXiv preprint arXiv:1710.10903*, 2017.
- [21] Q. Sun, X. Huang, J. Gu, B. C. Williams, and H. Zhao, "M2i: From factored marginal trajectory prediction to interactive prediction," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 6543–6552.
- [22] X. Mo, Z. Huang, Y. Xing, and C. Lv, "Multi-agent trajectory prediction with heterogeneous edge-enhanced graph attention network," *IEEE Transactions on Intelligent Transportation Systems*, 2022.
- [23] T. Gilles, S. Sabatini, D. Tsishkou, B. Stanciulescu, and F. Moutarde, "Gohome: Graph-oriented heatmap output for future motion estimation," in *2022 International Conference on Robotics and Automation (ICRA)*. IEEE, 2022, pp. 9107–9114.
- [24] —, "Thomas: Trajectory heatmap output with learned multi-agent sampling," *arXiv preprint arXiv:2110.06607*, 2021.
- [25] M. Bansal, A. Krizhevsky, and A. Ogale, "Chauffeurnet: Learning to drive by imitating the best and synthesizing the worst," *arXiv preprint arXiv:1812.03079*, 2018.
- [26] P. Hang, C. Lv, C. Huang, J. Cai, Z. Hu, and Y. Xing, "An integrated framework of decision making and motion planning for autonomous vehicles considering social behaviors," *IEEE transactions on vehicular technology*, vol. 69, no. 12, pp. 14 458–14 469, 2020.
- [27] Z. Huang, J. Wu, and C. Lv, "Driving behavior modeling using naturalistic human driving data with inverse reinforcement learning," *IEEE Transactions on Intelligent Transportation Systems*, 2021.
- [28] D. González, J. Pérez, V. Milanés, and F. Nashashibi, "A review of motion planning techniques for automated vehicles," *IEEE Transactions on intelligent transportation systems*, vol. 17, no. 4, pp. 1135–1145, 2015.
- [29] H. Song, W. Ding, Y. Chen, S. Shen, M. Y. Wang, and Q. Chen, "Pip: Planning-informed trajectory prediction for autonomous driving," in *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXI 16*. Springer, 2020, pp. 598–614.
- [30] A. Kamenev, L. Wang, O. B. Bohan, I. Kulkarni, B. Kartal, A. Molchanov, S. Birchfield, D. Nistér, and N. Smolyanskiy, "Predictionnet: Real-time joint probabilistic traffic prediction for planning, control, and simulation," in *2022 International Conference on Robotics and Automation (ICRA)*. IEEE, 2022, pp. 8936–8942.
- [31] S. Casas, A. Sadat, and R. Urtasun, "Mp3: A unified model to map, perceive, predict and plan," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, pp. 14 403–14 412.
- [32] H. Shao, L. Wang, R. Chen, H. Li, and Y. Liu, "Safety-enhanced autonomous driving using interpretable sensor fusion transformer," in *Conference on Robot Learning*. PMLR, 2023, pp. 726–737.
- [33] Z. Huang, X. Mo, and C. Lv, "Recoat: A deep learning-based framework for multi-modal motion prediction in autonomous driving application," *arXiv preprint arXiv:2207.00726*, 2022.
- [34] P. Bender, J. Ziegler, and C. Stiller, "Lanelets: Efficient map representation for autonomous driving," in *2014 IEEE Intelligent Vehicles Symposium Proceedings*. IEEE, 2014, pp. 420–425.
- [35] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 2980–2988.
- [36] N. Rhinehart, R. McAllister, and S. Levine, "Deep imitative models for flexible inference, planning, and control," *arXiv preprint arXiv:1810.06544*, 2018.
- [37] M. Bhardwaj, B. Boots, and M. Mukadam, "Differentiable gaussian process motion planning," in *2020 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2020, pp. 10 598–10 604.
- [38] S. Ettinger, S. Cheng, B. Caine, C. Liu, H. Zhao, S. Pradhan, Y. Chai, B. Sapp, C. R. Qi, Y. Zhou *et al.*, "Large scale interactive motion forecasting for autonomous driving: The waymo open motion dataset," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021, pp. 9710–9719.
- [39] X. Huang, X. Tian, J. Gu, Q. Sun, and H. Zhao, "Vectorflow: Combining images and vectors for traffic occupancy and flow prediction," *arXiv preprint arXiv:2208.04530*, 2022.